Data Science

Dr. Konrad Völkel, Sommersemester 2026

Übungen: Dr. Michael Heck

Dr. Konrad Völkel
Dr. Michael Heck

Kommunikation über

Rocket.Chat: #datascience2026

Mail: vldatascience@hhu.de

ILIAS ← Übungsbetrieb

Python | Mathematik | Motivische Homotopietheorie Wissensmodelle | Wikipedia | Algebraische Geometrie | Topologie | Symmetriegruppen Topologische Datenanalyse | Maschinelles Lernen



Dr. Konrad Völkel

konrad.voelkel@hhu.de #datascience2026
Gebäude 25.12
Raum 01.24
Sprechstunde nach Vereinbarung Fr 9-12

Das machen wir heute:

Heinrich Heine
Universität Düsseldorf

Was ist Data Science?

Was machen wir in der Vorlesung?

Wo geht die Reise hin?

Was können wir hinterher?

Was müssen Studierende tun?
(Übungsaufgaben,
Übungsgruppen,
Klausur)

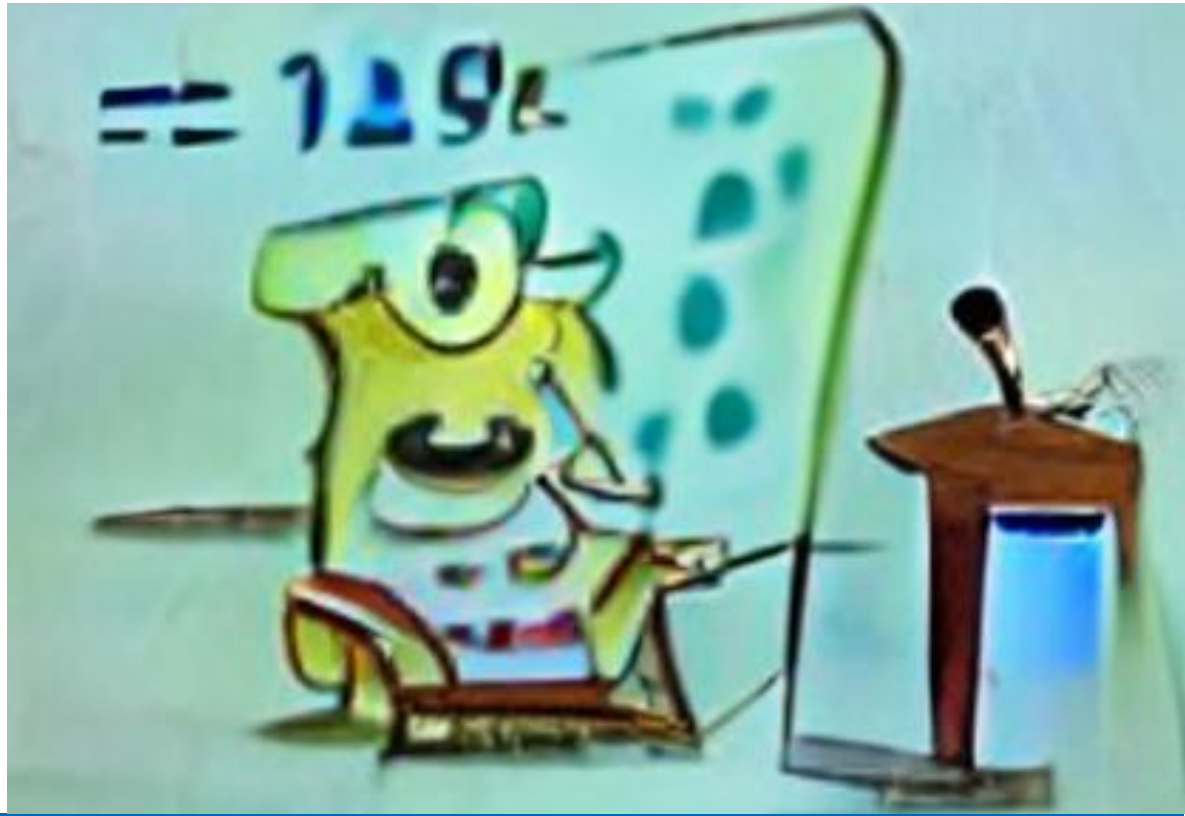
Was brauchen Sie?

Was wünschen Sie sich?

Warum sind Sie hier?

Data Science

Was ist das?



“Spongebob giving a statistics lecture”

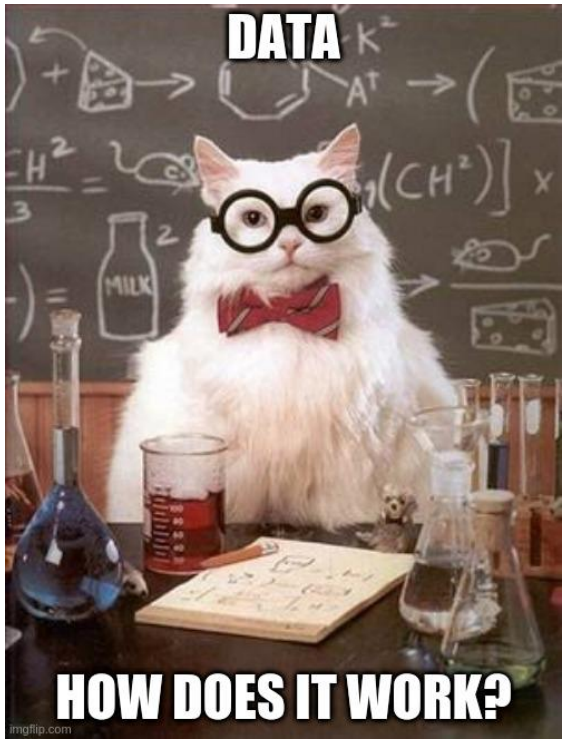
Was ist Data Science

Definition “Data”

Gerhard Goos, VL über Informatik Bd. 1:

Die Darstellung einer Mitteilung durch die zeitliche Veränderung einer physikalischen Größe heißt ein **Signal**.

Wenn wir bei der Darstellung und Weitergabe einer Mitteilung vom verwendetem Medium und den Einzelheiten der Signale und Signalparameter abstrahieren, heißt die Mitteilung eine **Nachricht**.



Die Kenntnisse, die man benötigt, um einer Nachricht Bedeutung zuzuordnen, nennen wir einen **Kontext** oder ein Bezugssystem.

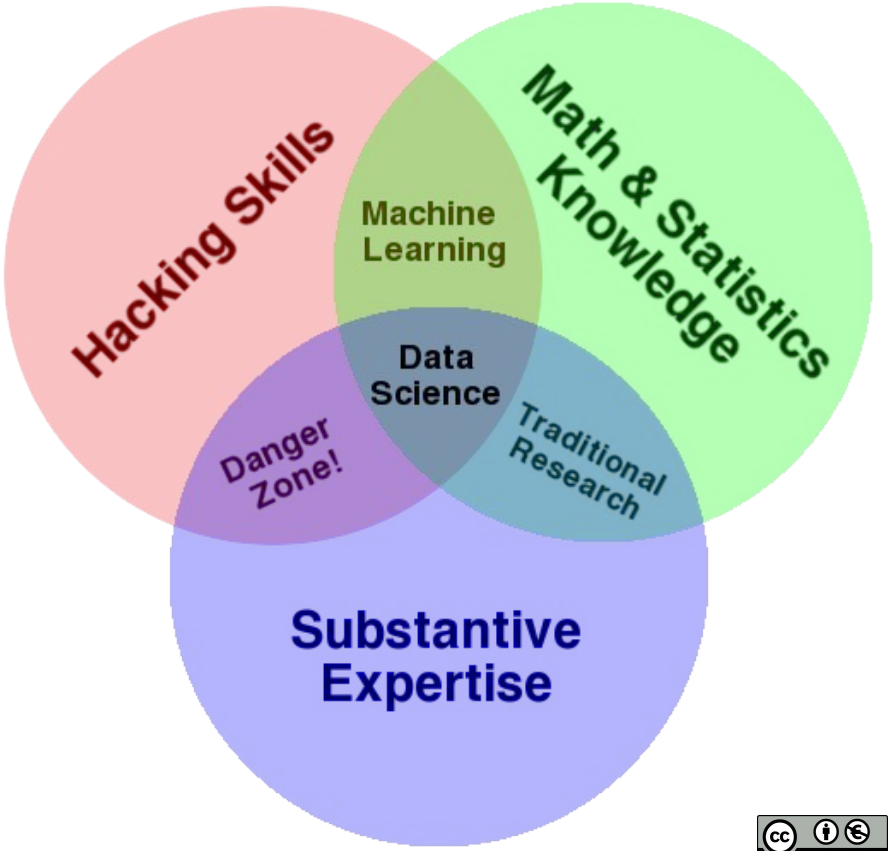
Die zugeordnete Bedeutung heißt eine **Information**.

Man nennt das Paar <Nachricht, zugeordnete Information> ein **Datum**. Der Plural ist **Daten** (englisch **data**).

Was ist Data Science

Ein bunter Mix

“Venn-Diagramm” von Drew Conway, 2013



Gartner sieht “Data Science” im Jahr 2019 fast auf der Spitze des “Hype Cycles”, dem “Peak of Inflated Expectations”.

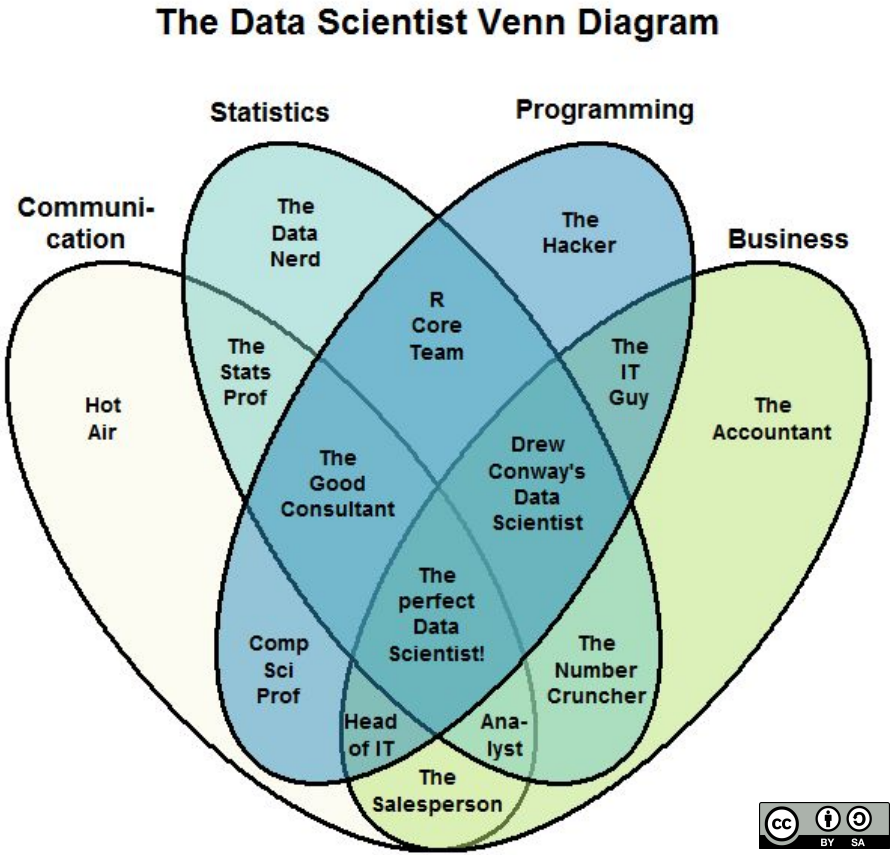
Danach folgt das Tal der Enttäuschung.

2024: “generative AI” auf dem Peak.

Was ist Data Science

Ein bunter Mix

"Venn-Diagramm" von Stephan Kolassa, 2015





Was ist Data Science

Was macht ein Data Scientist

“Nearly all [...] working data scientists make their daily bread and butter through **data collection** and data **cleaning**; building **dashboards** and **reports**; data **visualization**; statistical **inference**; **communicating** results to key stakeholders; and **convincing** decision makers of their results.”

Hugo Bowne-Anderson, Harvard Business Review, 2018

Was ist Data Science

Was macht ein Data Scientist



Was ist Data Science

Was macht ein Data Scientist

Zum **Daten schrubben** braucht man:

- Programmierkenntnisse
- Reguläre Ausdrücke
- Zeit- und Datumsformate
- GIS-Datenformate, Ländercodes
- Unicode oder schlimmeres
- Erfahrung mit den gängigsten Schweinereien, die vom CSV-Standard abweichen
- Geduld
- Übung
- Fachkenntnisse



Was ist Data Science

Was macht ein Data Scientist

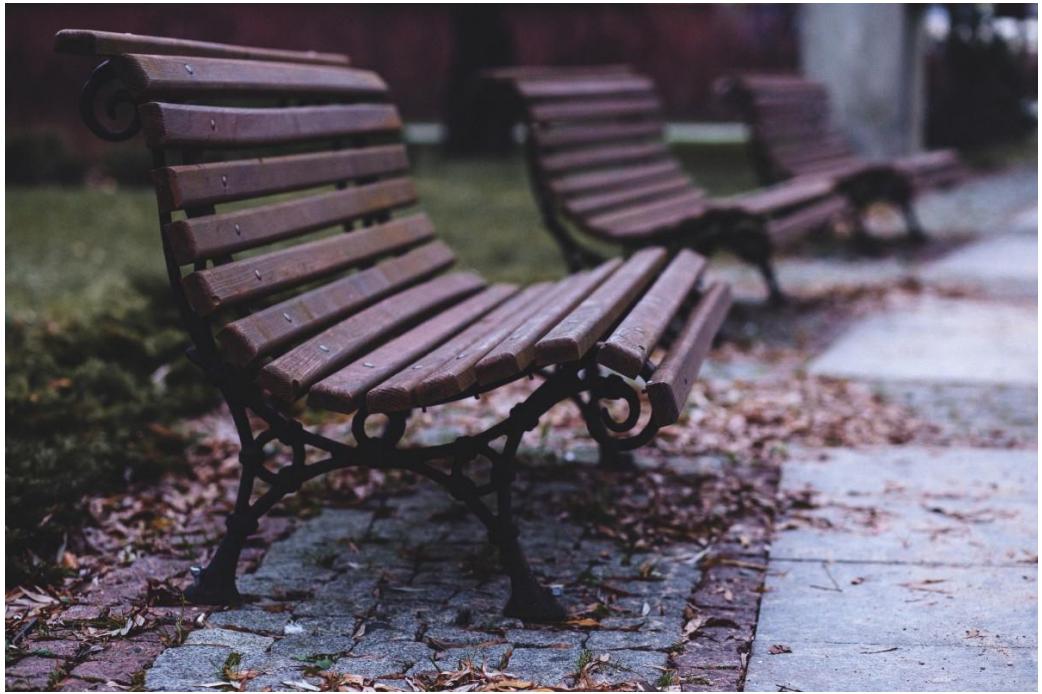


Was ist Data Science

Was macht ein Data Scientist

Um Data Science im Produktivsystem einzusetzen, benutzt man **Datenbanken**.

Wichtig ist dabei **SQL** und das Datenmodell einer relationalen DB.



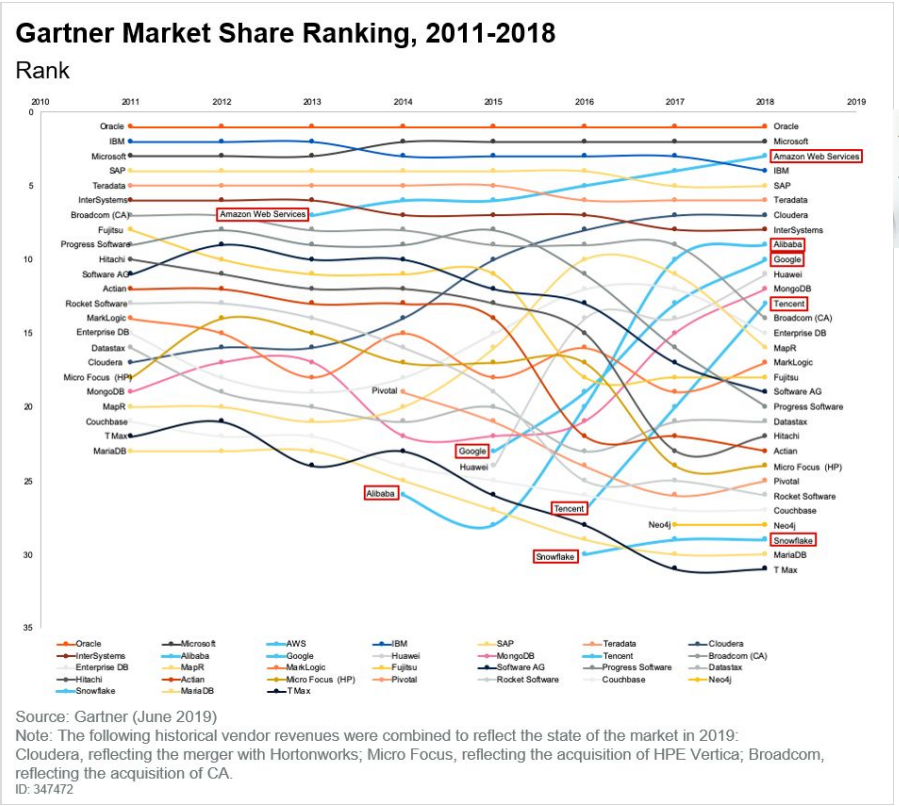
Was ist Data Science

Was macht ein Data Scientist

Um Data Science im Produktivsystem einzusetzen, benutzt man **Datenbanken**.

Wichtig ist dabei **SQL** und das Datenmodell einer relationalen DB.

Wir beschäftigen uns in der Vorlesung nicht mit einer konkreten Datenbank oder Datenbanken allgemein.





Was ist Data Science

Heinrich Heine
Universität Düsseldorf

Big Data?

Daten sind big, wenn zwei-drei V's erfüllt sind:

- **Volume**:
  es ist sehr viel (Terabytes oder Petabytes). Ein Petabyte (PB) kostet bei Amazon Web Services (AWS) ca. 10000 $
- **Variety**:
  es ist vielfältig, nicht nur eine Sorte Daten z.B. ganze Webseiten mit Text, Bild, Film, Code, Zugriffsstatistiken
- **Velocity**:
  ständig entstehen neue Daten, die dann auch mit den "alten" zusammengebracht werden sollen

Was ist Data Science



Was ist Data Science

Heinrich Heine
Universität Düsseldorf

Wer wird gesucht

Du willst Big Data in Smart Data verwandeln? Dann kannst Du Dich hier einbringen:

Du schaffst aus großen strukturierten und unstrukturierten Datenbeständen unterschiedlicher Datenquellen eine Datenbasis, analysierst und interpretierst diese.

Mithilfe von Data Mining, Data Science und Machine Learning-Methoden **erkennst Du Muster und erstellst daraus Prognosen** für die Zukunft.

Die **Betreuung von nationalen und internationalen Kund:innen in Projekten an der Schnittstelle zwischen Fachbereich und IT** fällt ebenfalls in Deinen Aufgabenbereich.

Du arbeitest an der Entwicklung neuer Analysemethoden, um die Datenbasis optimal zu prüfen und zu interpretieren.

Du konzipierst, erstellst und modellierst Datenbankanwendungen.

Dein Profil

Um bei uns als (Junior) Data Scientist (w/m/d) an Bord zu kommen, hast Du Dein Bachelor- oder Masterstudium mit sehr guten Noten abgeschlossen - vorzugsweise in Wirtschaftsinformatik, Informatik, Statistik, Wirtschaftsingenieurwesen, Ingenieurwesen, Wirtschaftsmathematik, Mathematik oder Physik.

Deine Expertise konntest Du bereits praktisch im Beratungsumfeld oder anderweitig in der IT unter Beweis stellen.

Du besitzt erste Kenntnisse in funktionalen / objektorientierten Programmiersprachen, wie C/C++, Python, R, Java oder JavaScript sowie Kenntnisse in Cloud-Technologien, Business Intelligence-Tools wie Tableau, PowerBI, SAS, oder Umfeld von SAP oder SQL-Datenbanken.

Du punktest mit einem **soliden Methodenwissen in Statistik, Machine Learning und IT-Infrastrukturen**, das es Dir ermöglicht, neuen Entwicklungen zu folgen und innovative Lösungen zu entwickeln.

Was ist Data Science

Heinrich Heine
Universität Düsseldorf

Wer wird gesucht

Spannende Aufgaben erwarten dich

Du erarbeitest und setzt innovative Lösungen im Bereich Risikomanagement um, Dir macht es Spaß Prozesse zu optimieren und kontinuierlich zu verbessern, Du formulierst Handlungsempfehlungen und übernimmst gerne auch die entsprechende Umsetzung.

Du arbeitest mit **Big-Data und Cloud Technologien** wie z. B. Google Cloud Platform (GCP), Amazon Webservices (AWS) und Microsoft Azure

Du unterstützt unser Team mit Projekten im Bereich Artificial Intelligence mit Fokus auf:

Machine Learning (z. B. Regression, Clustering, Classification)

Deep Learning (z. B. Computer Vision)

Trustworthy AI: Model Bias, Robust AI, Explainable AI

Natural Language Processing/Generation (NLP/G)

Darin bist du Spezialist:in

Erfolgreich abgeschlossenes Hochschulstudium in Informatik, Statistik, Finanz-/Wirtschaftsmathematik, Ingenieurwesen oder Naturwissenschaften

Leidenschaft mit Daten zu arbeiten, Ausgeprägte analytische sowie konzeptionelle Fähigkeiten vor allem im **Umgang mit Daten und statistischer Modellierung**

Beherrschung von **Python** (z. B. **scikit-learn**, Tensorflow, Keras, Pytorch) oder R (gerne auch Java, C++)

Erste Erfahrungen mit **Machine Learning Algorithmen**, Erste Erfahrungen mit Cloud Technologien sind von Vorteil, Hands-on Kenntnisse mit Analysewerkzeugen wie Trifacta, DataIKU, Orange3, Tensorboard oder Qlik/Tableau

Du bringst eine "Winning Attitude" mit, indem du wissbegierig bist und kreativ sowie kunden- und teamorientiert agierst

Was ist Data Science

Heinrich Heine
Universität Düsseldorf

Wer wird gesucht

Position Description

Manage a team of data scientists.

Conceive, plan and lead data science projects.

Utilize advanced analytical methods and develop algorithms/models to extract insights from diverse data sources that drive business across the whole value chain.

Interact with key-stakeholders (technical and non-technical) to understand their needs and translate those needs into precise analytical solutions to inform strategy and decision making.

Clearly and concisely **communicate analytical solutions** and results to (non-)experts.

Proactively identify new opportunities where data science could bring value in terms of technical improvement and/or business impact.

Your profile

Master degree in a quantitative field (e.g. physics, mathematics, computer science, bioinformatics); PhD is a plus.

Minimum **5 years with hands-on experience** with data science and advanced analytics projects; previous leadership experience.

Expert knowledge on supervised and unsupervised machine learning techniques, statistics and time series analysis. Fluent in programming with **Python** and using common machine learning libraries (e.g. **sklearn**, keras/tensorflow, statsmodels, PyMC3 etc.); programming in Spark or/and **SQL** would be a plus.

Experience with big data ecosystems and **common ETL** processes; experience with the Azure tool stack would be a plus. Knowledge of professional software development practices and using tools for source control and project management like Git, JIRA, Azure Dev Ops etc.

Was ist Data Science

Wer wird gesucht

Ihre Aufgaben

Als Consultant für Datenmanagement und Data Science unterstützen Sie unsere Kunden bei der Erschließung und Nutzung behördlicher Daten innerhalb und außerhalb der öffentlichen Verwaltung

Sie analysieren domänenbezogene Daten der Verwaltung wie Verkehr, Bau oder Sozialwesen und entwickeln innovative Lösungen für den Aufbau einer leistungsfähigen Datenarchitektur

Dabei erarbeiten Sie **Datenmodelle, Standards und Architekturen für ein organisationsübergreifendes Datenmanagement**

Ihr Profil

Abgeschlossenes Studium in Informatik, Wirtschaftsinformatik, Mathematik, Data Science, Public Management oder Business Administration oder vergleichbare Kenntnisse durch Berufspraxis

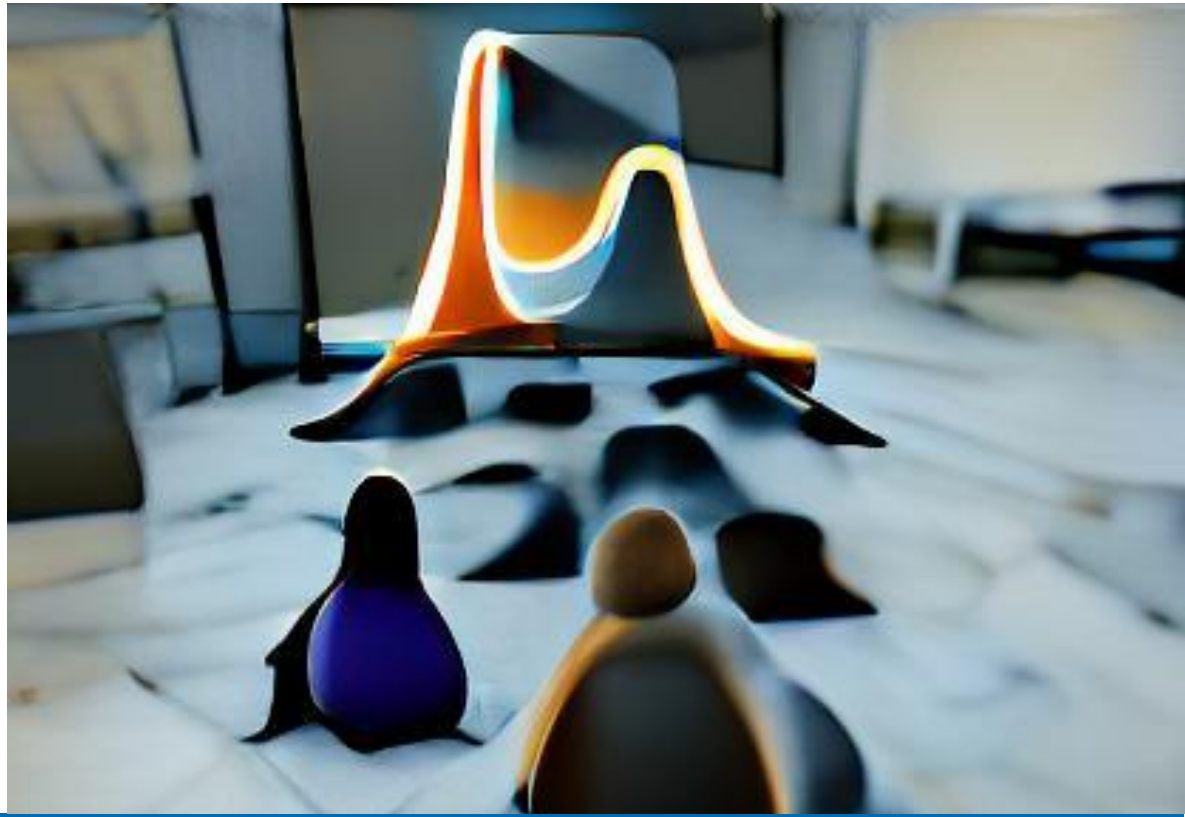
Tiefgreifende Erfahrungen mit Standards und Technologien des Datenmanagements

Analytische und lösungsorientierte Arbeitsweise sowie gute Kommunikations- und Präsentationsfähigkeit


ZEIT FÜR EINE PAUSE?
imgflip.com

Überblick über die Vorlesung

Was machen wir?



“Multivariate normal distribution with exponential friends”

Überblick über die Vorlesung

Heinrich Heine
Universität Düsseldorf

Lernziele (Kompetenzen)

Sie sollen nach dem erfolgreichen Abschluss dieses Moduls in der Lage sein,

1. einen Datensatz explorativ zu analysieren,
2. Daten zur Weiterverarbeitung zu transformieren,
3. Teildatensätze zur Weiterverarbeitung zu wählen,
4. geeignete Datensätze zusammenzuführen,
5. Erkenntnisse in Daten zu beschreiben und zu visualisieren,
6. statistische Modelle anhand von Daten aufzustellen,
7. die Güte von Modellen zu bewerten,
8. und zur Klassifikation und Vorhersage weiterer Daten zu nutzen.

Dazu sind Sie damit vertraut, wie sich diese Aufgaben mit Python lösen lassen.

Überblick über die Vorlesung

Heinrich Heine
Universität Düsseldorf

Weitergehende Lernziele

- Auf Stellen als “Junior Data Scientist” bewerben können
- Vorbereitung auf den Master “Artificial Intelligence & Data Science”
- Data Science Techniken anwenden können in anderen Bereichen, z.B.
  - Produktentwicklung (data-driven design)
  - Systemoptimierung (logfiles analysieren)
  - Performancevergleiche (data-driven decision making)
  - Qualitätskontrolle
  - Einbinden von Machine-Learning-Komponenten in Systeme
- Sie bekommen einen Datensatz in die Hand, und wissen sofort, wie Sie daraus Fragestellungen formulieren & beantworten können.
- Sie können Fachartikel lesen, um Ergebnisse daraus zu nutzen.

Überblick über die Vorlesung

Heinrich Heine
Universität Düsseldorf

Nicht unsere Ziele

1. Data Science **auf verteilten Systemen** (Big Data etc.);
2. **Deep Learning**,
   denn dazu gibt es die Vorlesungen “Einführung in Deep Learning” (EiDL) und “Deep Learning” (im Master),
   die auf Data Science aufbauen können.
3. **Data Science mit R**, RStudio,
   oder irgendwelchen anderen Tools als Python+Module
4. Data Science auf “**model.fit()**” reduzieren
5. **Programmierkurs**
   (Python-Vorkenntnisse werden aber auch nicht vorausgesetzt)

Überblick über die Vorlesung

Warum Python?

- “Most used programming languages among developers worldwide, as of 2024: JavaScript, HTML/CSS, Python” - statista
  Platz 1 im TIOBE Index, März 2025 - tiobe
- Funktionierendes Ökosystem Scientific Python:
  - Numpy
  - SciPy, Scikit-Learn
  - Matplotlib, Seaborn
  - Pandas
  - Jupyter
- Wir nehmen Python ≥ 3.11 (z.B. 3.12) (wegen NEP 29 und SPEC 0)



Überblick über die Vorlesung

Heinrich Heine
Universität Düsseldorf

Welche Inhalte lernen wir, um die Lernziele zu erreichen?

- Background aus der Statistik:
  - **Wahrscheinlichkeitsverteilungen**,
    diskret und stetig, ein- und mehrdimensional
  - **Momente von Zufallsvariablen** (Erwartungswert, Varianz, etc.)
  - **Statistische Modelle**, Parameterschätzer und Signifikanz
- Programmierübung mit Python:
  - mit “**Spielzeugdaten**” und den **Scientific Python** Paketen
- Algorithmen und Datenstrukturen
  - damit wir verstehen, was passiert, wenn man “model.fit()” macht:
  - Parameterschätzer programmieren
  - **Klassifikations- und Clusteringalgorithmen** programmieren

Überblick über die Vorlesung

Heinrich Heine
Universität Düsseldorf

Einführung in die Data Science

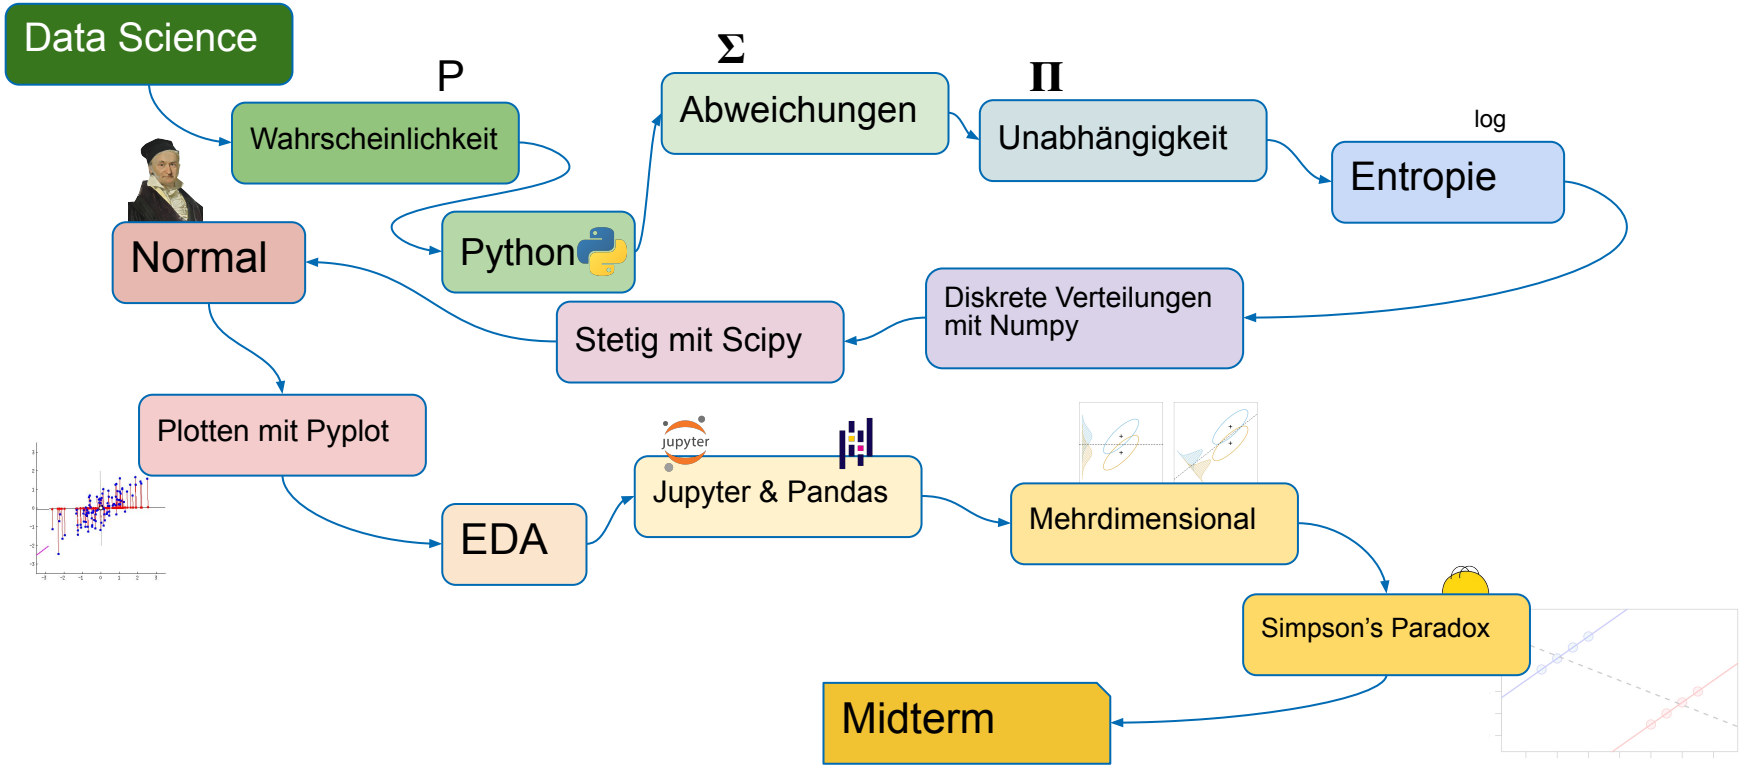
Einführung in die Wahrscheinlichkeitstheorie & Python
Diskrete Zufallsvariablen, Erwartungswert, Varianz
Wichtigste diskrete Verteilungen, Urnenmodelle
Stetige Verteilungen, Dichtefunktionen
Gaußsche Normalverteilung
Scipy Stats, wichtigste stetige Verteilungen

Deskriptive Statistik, Matplotlib
Visualisierung, Quantile, Histogramme
Bedingte Wahrscheinlichkeiten, Bayes
Entropie und Likelihood
Kovarianz und Korrelation
Pandas, Daten putzen, SQL

Statistische Modelle
Konfidenzbereiche, Schätzen, Maximum Likelihood
Verteilungen fitten mit Python
Hypothesentests, Signifikanz
Multivariate Statistik, Dimensionsreduktion mit Hauptkomponentenanalyse

Maschinelles Lernen mit scikit-learn
Regression
Cluster modellieren und finden
Latente Variablen in gemischten Gaußschen Modellen
Klassifikationsverfahren
Modellierung eines ML-Problems

Ablaufplan (erste Hälfte)



Ablaufplan (zweite Hälfte)

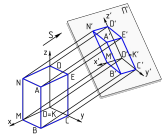


Midterm

Daten putzen



Clustering



Dimensionsreduktion



Datenschutz

Schätzer

Maximum Likelihood

Signifikanz

Regularisierung

Regression
mit Scikit-Learn

???

Latente Variablen

Expectation Maximization

Klausuren

Was muss getan werden?

Um zu bestehen und eine gute Note zu erzielen



“Chewbacca sitting in the classroom drinking a cafe latte”

Was muss getan werden?

Übungsaufgaben

Regelmäßige Teilnahme an den Übungsgruppen ist empfohlen, aber nicht zwingend (und wird nicht geprüft).

Regelmäßige Bearbeitung der Übungsaufgaben ist der wesentliche Inhalt der Lehrveranstaltung.

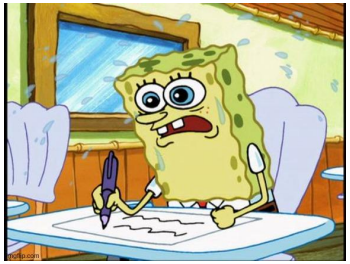
Es gibt hin und wieder Multiple-Choice-Aufgaben, reine Mathematik-Textaufgaben und leichte Programmieraufgaben.

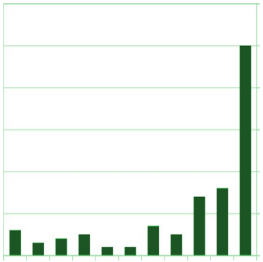
Die Aufgaben sollen zu zweit abgegeben werden. Notfalls zu dritt.

Schriftliche Klausur

Erster Termin:

27.07.2026 von 11:30 bis 14:30





Zweiter Termin:

16.09.2026 von 8:30 bis 11:30

Was muss getan werden?

Übungsblätter

Der Abgabetermin für alle Übungsblätter ist immer Dienstags 10:00, per Upload eines PDF für die Theorieaufgaben und einer .py-Datei ggf. mit Anhängen in ILIAS.

Die Übungsblätter sollen zu zweit bearbeitet werden (dürfen allein und zu dritt).

Das erste Übungsblatt haben Sie am Dienstag, 14.4. erhalten, Abgabe ist am Dienstag, den 21.4. bis 10:00.

Was muss getan werden?

Heinrich Heine
Universität Düsseldorf

Gemeinsam arbeiten

Bearbeiten Sie die Aufgaben mit anderen zusammen, auch wenn Sie alles alleine schaffen würden - Sie lernen mehr und sind schneller fertig.

Organisatorische Fragen können im rocket.chat gestellt werden:

#datascience2025

Format der Abgabe

Abgaben sind handschriftlich (gescannt/abfotografiert in einer *kleinen* PDF-Datei, keine Bilddateien) und getippt (z.B. mit LaTeX, etwa Overleaf) erlaubt.

Nur eine Person soll die Abgabe in ILIAS hochladen. Wenn Sie zu zweit zwei verschiedene Versionen hochladen, entscheidet der Zufall, welche davon bewertet wird.

Was darf getan werden?

Heinrich Heine
Universität Düsseldorf

ChatGPT?

**“...that AI will be the death of learning & so on;
to this, I say NO!**

**My student brings me their essay,
which has been written by AI
& I plug it into my grading AI
& we are free!**



Slavoj Zizek, Wikipedia, CC-BY-SA by User:Amrei-Marie

**While the 'learning' happens, our superego satisfied,
we are free now to learn whatever we want.” -- Slavoj Žižek**

Was darf getan werden?

Heinrich Heine
Universität Düsseldorf

ChatGPT & Copilot usw., nur mit Kennzeichnung

aber nicht in der Klausur (und auch nicht in der Midterm).

Und: Erstmal selbst probieren,
Sonst lernt nur ChatGPT dazu.

Was muss getan werden?

Heinrich Heine
Universität Düsseldorf

Zulassung

Um zur Klausur zugelassen zu werden, müssen Sie von den Übungsblättern auf 10 Blättern jeweils mindestens 50% der Punkte erzielt haben.

Anders formuliert: Sie haben 2 Joker.

Bei begründeten Fällen gibt es natürlich Ausnahmen! Darüber sprechen wir **bitte** erst 2 Wochen vor der Klausur, wenn es wirklich notwendig sein sollte.

Was muss getan werden?

Heinrich Heine
Universität Düsseldorf

AltZulassung

Wenn Sie in den Vorjahren bereits die Klausurzulassung erworben haben, gilt diese weiterhin.

Achtung:

Wenn Sie zuvor die Klausurzulassung erworben haben aber nicht die formalen Voraussetzungen für das Modul erfüllen (die 2024 noch nicht galten), dürfen Sie in 2026 NICHT die Klausur mitschreiben.

Bei den formalen Voraussetzungen können keine Ausnahmen gemacht werden.


ZEIT FÜR EINE PAUSE?
imgflip.com

Was brauchen Sie?

Um zu bestehen und eine gute Note zu erzielen



“Solution to the Voynich manuscript”

Was bringen Sie mit?

Auszug aus dem HIS-LSF

Es sind (Stand 14.4.26)
462 Teilnehmer*innen im LSF angemeldet, davon
149 Wiederholer*innen, also
313 Neulinge

Es sind
31 im Bachelor in PO 2016 und
365 in PO 2021.

Insgesamt 396 Bachelor-Informatik-Teilnehmer und
66 die nicht Bachelor Informatik (als Hauptfach?) studieren

Was brauchen Sie?

Heinrich Heine
Universität Düsseldorf

Wir schauen auf Particify

ars.particify.de

Raum 6022 4061

partici.fi/60224061

ars.particify.de/p/60224061/series/Eingangsfragen/1

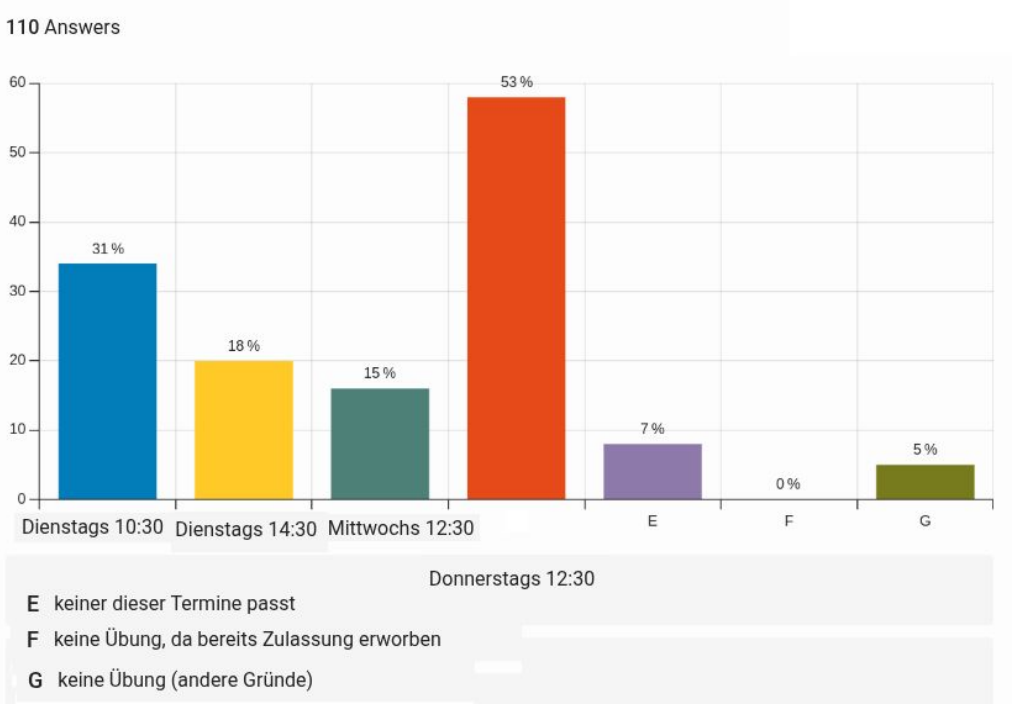
Welche Themen sind für Sie im Bereich "Data Science" interessant?



Das haben Sie gesagt: [Alte Daten]

Heinrich Heine
Universität Düsseldorf

An welcher Übung werden Sie voraussichtlich teilnehmen?



Das haben Sie gesagt: [Alte Daten]

Heinrich Heine
Universität Düsseldorf

Ausgewählte Antworten zu
“Welche Erwartungen und Wünsche haben Sie noch? Gibt es noch etwas, was Sie fragen oder mitteilen möchten?”

Woher soll ich Python können?!

Bitte veröffentlichen sie ein Ankideck!!

Möchte nur viel Mathe machen

Verständliche Beispiele

Eventuell mehr Übungsgruppen da es schnell zu voll wird

So viele Materialien wie möglich online zugänglich zu machen

Was sind Anzeichen für nicht umsetzbare Data Science Projekte?

Ist es sinnvoll die Folien oder das Skript zur Klausurvorbereitung aktiv zu nutzen neben den Übungen?

Danke für Ihre Aufmerksamkeit.