

Data Science, VL 4

Dr. Konrad Völkel, Sommersemester 2026

28.04.2026

Was bisher geschah: Stochastik

- Ein Wahrscheinlichkeitsmaß auf einer Menge Ω ist Abbildung $\mathrm{P} : \mathcal{E}(\Omega) \to [0,1]$ mit $\mathrm{P}(\Omega) = 1$ und Summenregel für disjunkte Vereinigungen. Wir nennen $A \in \mathcal{E}(\Omega)$ die Ereignisse, für eine endliche Menge $\mathcal{E}(\Omega) := \mathcal{P}(\Omega)$, die Menge aller Teilmengen. Das Paar (Ω, P) heißt W-Raum.

Was bisher geschah: Stochastik

- Ein Wahrscheinlichkeitsmaß auf einer Menge Ω ist Abbildung $\mathrm{P} : \mathcal{E}(\Omega) \to [0,1]$ mit $\mathrm{P}(\Omega) = 1$ und Summenregel für disjunkte Vereinigungen. Wir nennen $\mathrm{A} \in \mathcal{E}(\Omega)$ die Ereignisse, für eine endliche Menge $\mathcal{E}(\Omega) := \mathcal{P}(\Omega)$, die Menge aller Teilmengen. Das Paar (Ω, P) heißt W-Raum.
- Auf einer endlichen Menge Ω ist P durch eine pmf $\mathrm{p} \colon \Omega \to [0,1]$ gegeben, $\mathrm{P}(\mathrm{A}) = \sum_{\mathrm{x} \in \mathrm{A}} \mathrm{p}(\mathrm{x})$.

Was bisher geschah: Stochastik

- Ein Wahrscheinlichkeitsmaß auf einer Menge Ω ist Abbildung $\mathrm{P} : \mathcal{E}(\Omega) \to [0,1]$ mit $\mathrm{P}(\Omega) = 1$ und Summenregel für disjunkte Vereinigungen. Wir nennen $\mathrm{A} \in \mathcal{E}(\Omega)$ die Ereignisse, für eine endliche Menge $\mathcal{E}(\Omega) := \mathcal{P}(\Omega)$, die Menge aller Teilmengen. Das Paar (Ω, P) heißt W-Raum.
- Auf einer endlichen Menge Ω ist P durch eine pmf $\mathrm{p}\colon \Omega \to [0,1]$ gegeben, $\mathrm{P}(\mathrm{A}) = \sum_{\mathrm{x}\in\mathrm{A}} \mathrm{p}(\mathrm{x})$.
- Zufallsvariablen sind messbare Abbildungen $\mathrm{X}\colon \Omega' \to \Omega$, die induzierte Verteilung P_X heißt auch Verteilung von X.

Was bisher geschah: Stochastik

- Ein Wahrscheinlichkeitsmaß auf einer Menge Ω ist Abbildung $\mathrm{P} : \mathcal{E}(\Omega) \to [0,1]$ mit $\mathrm{P}(\Omega) = 1$ und Summenregel für disjunkte Vereinigungen. Wir nennen $\mathrm{A} \in \mathcal{E}(\Omega)$ die Ereignisse, für eine endliche Menge $\mathcal{E}(\Omega) := \mathcal{P}(\Omega)$, die Menge aller Teilmengen. Das Paar (Ω, P) heißt W-Raum.
- Auf einer endlichen Menge Ω ist P durch eine pmf $\mathrm{p}\colon \Omega \to [0,1]$ gegeben, $\mathrm{P}(\mathrm{A}) = \sum_{\mathrm{x}\in\mathrm{A}} \mathrm{p}(\mathrm{x})$.
- Zufallsvariablen sind messbare Abbildungen $\mathrm{X}\colon \Omega' \to \Omega$, die induzierte Verteilung P_X heißt auch Verteilung von X.
- Sind Ω, Ω' endlich, so sind alle Abbildungen $\mathrm{X}\colon \Omega' \to \Omega$ messbar.

Daten als Verteilung

Heinrich Heine
Universität Düsseldorf

Gegeben Daten D in einer Tabelle:

	x
0	blue
1	red
2	blue
3	green

Daten als Verteilung

Gegeben Daten D in einer Tabelle:

	x
0	blue
1	red
2	blue
3	green

können wir einen W-Raum $\Omega = \{\text{blue}, \text{red}, \text{green}\}$ modellieren mit

$$\mathrm{P}(\{\mathrm{x}\}) := \text{relative Frequenz von x} = \frac{\text{Anzahl x in D}}{|\mathrm{D}|}$$

Die Verteilung der Daten (und $|\mathrm{D}| = 4$ im Beispiel).

Daten als Verteilung

Gegeben Daten D in einer Tabelle:

	x
0	blue
1	red
2	blue
3	green

ist der Wahrscheinlichkeitsvektor für die Reihenfolge $\Omega = \{\text{blue}, \text{red}, \text{green}\}$

$$\mathrm{p} = \left(\frac{2}{4}, \frac{1}{4}, \frac{1}{4}\right).$$

Populationsverteilung

- Wo kommen die Daten her?

Populationsverteilung

- Wo kommen die Daten her?
- Beispiel: Stichprobe einer Tüte Süssigkeiten.
  Achtung: größere Stichproben können anders verteilt sein.

Populationsverteilung

- Wo kommen die Daten her?
- Beispiel: Stichprobe einer Tüte Süssigkeiten.
  Achtung: größere Stichproben können anders verteilt sein.
- Häufige Aufgabe: Gegeben Stichprobe D einer größeren Menge D′, schätze Verteilung von D′ anhand der Verteilung der Daten D.

Populationsverteilung

Heinrich Heine
Universität Düsseldorf

- Wo kommen die Daten her?
- Beispiel: Stichprobe einer Tüte Süssigkeiten.
  Achtung: größere Stichproben können anders verteilt sein.
- Häufige Aufgabe: Gegeben Stichprobe D einer größeren Menge D', schätze Verteilung von D' anhand der Verteilung der Daten D.
- Dabei heißt D' die Population.

Populationsverteilung

- Wo kommen die Daten her?
- Beispiel: Stichprobe einer Tüte Süssigkeiten.
  Achtung: größere Stichproben können anders verteilt sein.
- Häufige Aufgabe: Gegeben Stichprobe D einer größeren Menge D′, schätze Verteilung von D′ anhand der Verteilung der Daten D.
- Dabei heißt D′ die Population.
- Häufig zusätzlicher Input:
  Zusatzinformationen über die Verteilung von D′ (eine Art von Prior).

Modellverteilung

- Wenn z.B. die Modellannahme ist, dass die Farben gleichverteilt sind bis auf eine Farbe, die doppelt so oft vorkommt, dann sind wir geneigt, nicht die Verteilung der Daten als Modell zu wählen, sondern z.B.

$$\mathrm{p} = \left(\frac{2}{4}, \frac{1}{4}, \frac{1}{4}\right),$$

  auch wenn die konkreten relativen Häufigkeiten leicht davon abweichen.

Modellverteilung

- Wenn z.B. die Modellannahme ist, dass die Farben gleichverteilt sind bis auf eine Farbe, die doppelt so oft vorkommt, dann sind wir geneigt, nicht die Verteilung der Daten als Modell zu wählen, sondern z.B.

$$\mathrm{p} = \left(\frac{2}{4}, \frac{1}{4}, \frac{1}{4}\right),$$

  auch wenn die konkreten relativen Häufigkeiten leicht davon abweichen.
- Auch mit dem Modell lässt sich eine “Stichprobe” ziehen: synthetische Daten, mit Hilfe eines Zufallszahlgenerators.

Modellverteilung

- Wenn z.B. die Modellannahme ist, dass die Farben gleichverteilt sind bis auf eine Farbe, die doppelt so oft vorkommt, dann sind wir geneigt, nicht die Verteilung der Daten als Modell zu wählen, sondern z.B.

$$\mathrm{p} = \left(\frac{2}{4}, \frac{1}{4}, \frac{1}{4}\right),$$

  auch wenn die konkreten relativen Häufigkeiten leicht davon abweichen.
- Auch mit dem Modell lässt sich eine “Stichprobe” ziehen: synthetische Daten, mit Hilfe eines Zufallszahlgenerators.
- Übungsaufgabe: wie genau geht das im Beispiel?

Modellgüte

Wie gut ist das Modell?
Kann vergleichen:
sehen die Daten D so aus, als wären sie aus dem Modell gesampelt worden?

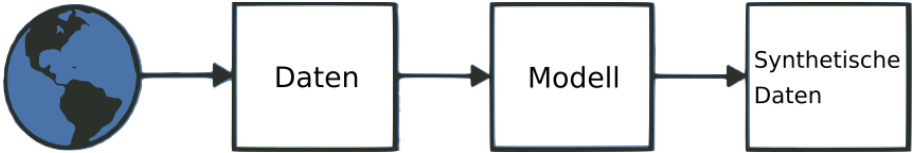
Modellgüte

Heinrich Heine
Universität Düsseldorf

Wie gut ist das Modell?
Kann vergleichen:
sehen die Daten D so aus, als wären sie aus dem Modell gesampelt worden?
“How likely is that?” → Likelihood.

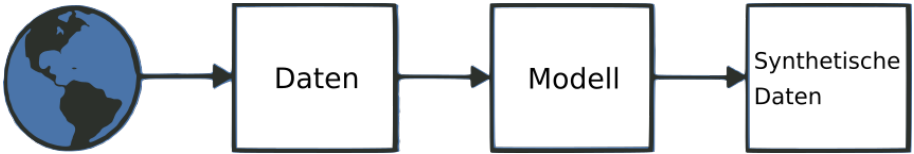
Was bisher geschah: Statistik

- Wir wählen einen Ausschnitt der Welt, sammeln Daten, putzen, transformieren (d.h. wählen die Features aus, die uns interessieren) und bilden Modelle für die Daten: Wahrscheinlichkeitsverteilungen.



Was bisher geschah: Statistik

- Wir wählen einen Ausschnitt der Welt, sammeln Daten, putzen, transformieren (d.h. wählen die Features aus, die uns interessieren) und bilden Modelle für die Daten: Wahrscheinlichkeitsverteilungen.
- Maximum Likelihood-Prinzip: Wir wählen das Modell, zu welchem die beobachteten Daten am ehesten so aussehen, als hätten wir sie aus dem Modell synthetisch erzeugt (gesampelt).



Heinrich Heine
Universität Düsseldorf

Pause?

Vergleich von Verteilungen

- Wie messen wir den Unterschied der Verteilungen aus den Daten und der Verteilungen aus unseren Modellen?

Vergleich von Verteilungen

- Wie messen wir den Unterschied der Verteilungen aus den Daten und der Verteilungen aus unseren Modellen?
- Präzise Antwort: mit der relativen Entropie - das kommt später.

Vergleich von Verteilungen

- Wie messen wir den Unterschied der Verteilungen aus den Daten und der Verteilungen aus unseren Modellen?
- Präzise Antwort: mit der relativen Entropie - das kommt später.
- Möglichkeit: Abstand der Daten zu synthetischen Daten im Datenraum messen.

Vergleich von Verteilungen

Heinrich Heine
Universität Düsseldorf

- Wie messen wir den Unterschied der Verteilungen aus den Daten und der Verteilungen aus unseren Modellen?
- Präzise Antwort: mit der relativen Entropie - das kommt später.
- Möglichkeit: Abstand der Daten zu synthetischen Daten im Datenraum messen.
- Damit wir wissen, wie der Datenraum aussieht: Ab jetzt X eine reelle Zufallsvariable bzw. Daten x sind reelle Zahlen.

Vergleich von Daten

Heinrich Heine Universität Düsseldorf

Gegeben (x, y) mit Stichprobengröße $n = 4$ in zwei Spalten
(Idee: x sind die Daten, y unser Modell, unsere “Vorhersage”)

	x	y
0	178	178
1	160	155
2	155	150
3	174	180

können wir nach dem Abstand von x und y fragen:

$$d(x, y) = \|x - y\|_1 = \sum_{i=0}^{n-1} |x_i - y_i|$$

Vergleich von Daten

- Gegeben Daten (x, y) mit Stichprobengröße $n = 4$ können wir nach dem Abstand von x und y fragen:

$$d(x, y) = \|x - y\|_1 = \sum_{i=0}^{3} |x_i - y_i|$$

  Achtung: Das wächst mit zunehmendem n

Vergleich von Daten

- Gegeben Daten (x, y) mit Stichprobengröße $n = 4$ können wir nach dem Abstand von x und y fragen:

$$d(x, y) = \|x - y\|_1 = \sum_{i=0}^{3} |x_i - y_i|$$

- Ebenso möglich wäre der mittlere Fehler:

$$\frac{1}{n} \sum_{i=0}^{n-1} (x_i - y_i)$$

Vergleich von Daten

- Gegeben Daten (x, y) mit Stichprobengröße n ist der Abstand bzgl. 1-Norm:

$$d_1(x, y) = \|x - y\|_1 = \sum_{i=0}^{n-1} |x_i - y_i|$$

Der mittlere absolute Fehler $\mathrm{mae}(x, y) = \dfrac{d_1(x, y)}{n}$

Vergleich von Daten

- Gegeben Daten (x, y) mit Stichprobengröße n ist der Abstand bzgl. 1-Norm:

$$d_1(x, y) = \|x - y\|_1 = \sum_{i=0}^{n-1} |x_i - y_i|$$

  Der mittlere absolute Fehler $\text{mae}(x, y) = \dfrac{d_1(x, y)}{n}$

- Der Abstand bzgl. 2-Norm ist (quadriert)

$$d_2(x, y)^2 = \|x - y\|_2^2 = \sum_{i=0}^{n-1} (x_i - y_i)^2$$

  Der mittlere quadratische Fehler $\text{mse}(x, y) = \dfrac{d_2(x, y)^2}{n}$

Beispielvergleich von Daten

Heinrich Heine Universität Düsseldorf

Gegeben (x, y) mit Stichprobengröße $n = 4$ in zwei Spalten
(Idee: x sind die Daten, y unser Modell, unsere "Vorhersage")

	x	y	x - y
0	178	178	0
1	160	155	5
2	155	150	5
3	174	180	-6

$$d_1(x, y) = 0 + 5 + 5 + 6 = 16,\ d_2(x, y)^2 = 0^2 + 5^2 + 5^2 + 6^2 = 86$$

$$\text{mae}(x, y) = \frac{16}{4} = 4,\ \text{mse}(x, y) = \frac{86}{4} = 21.5$$

Der mittlere Fehler ist $\frac{0 + 5 + 5 - 6}{4} = 1$, eine trügerisch geringe Zahl.

Beispielvergleich von Daten: einfacher Fall

Heinrich Heine Universität Düsseldorf

Wir wählen nun ein besonders einfaches Modell:
ein konstanter Wert (hier 165) als Vorhersage.

	x	y	x - y
0	178	165	13
1	160	165	-5
2	155	165	-10
3	174	165	9

$$d_1(x, y) = 13 + 5 + 10 + 9 = 37,\ d_2(x, y)^2 = 13^2 + 5^2 + 10^2 + 9^2 = 375$$

$$\text{mae}(x, y) = \frac{37}{4} = 9.25,\ \text{mse}(x, y) = \frac{375}{4} = 93.75$$

Der mittlere Fehler ist $\frac{13 - 5 - 10 + 9}{4} = 7$, eine trügerisch geringe Zahl.

Beispielvergleich von Daten: einfacher Fall

Wir wählen nun ein besonders einfaches Modell:
ein konstanter Wert (hier 165) als Vorhersage.

	x	y	x - y
0	178	165	13
1	160	165	-5
2	155	165	-10
3	174	165	9

Für welche Konstante wird der Fehler minimal?

$$d_1(x, y) = 13 + 5 + 10 + 9 = 37,\ d_2(x, y)^2 = 13^2 + 5^2 + 10^2 + 9^2 = 375$$

$$\text{mae}(x, y) = \frac{37}{4} = 9.25,\ \text{mse}(x, y) = \frac{375}{4} = 93.75$$

Der mittlere Fehler ist $\frac{13 - 5 - 10 + 9}{4} = 7$, eine trügerisch geringe Zahl.

Vergleich von Daten mit einer Konstanten

- Gegeben Daten x mit Stichprobengröße n und einer Konstanten y können wir nach dem Fehler fragen, den wir machen, wenn wir x durch y modellieren.

Vergleich von Daten mit einer Konstanten

- Gegeben Daten x mit Stichprobengröße n und einer Konstanten y können wir nach dem Fehler fragen, den wir machen, wenn wir x durch y modellieren.
- Ein y, welches den mittleren absoluten Fehler $\mathrm{mae}(x, y)$ minimiert, nennt man Median von x, $\mathrm{median}(x) \in \mathrm{argmin}_{c \in \mathbb{R}} \mathrm{mae}(x, c)$. Manche fordern $c \in x$, dass also der Median ein Datenpunkt sein muss.

Vergleich von Daten mit einer Konstanten

- Gegeben Daten x mit Stichprobengröße n und einer Konstanten y können wir nach dem Fehler fragen, den wir machen, wenn wir x durch y modellieren.
- Ein y, welches den mittleren absoluten Fehler $\mathrm{mae}(x, y)$ minimiert, nennt man Median von x, $\mathrm{median}(x) \in \mathrm{argmin}_{c \in \mathbb{R}} \mathrm{mae}(x, c)$. Manche fordern $c \in x$, dass also der Median ein Datenpunkt sein muss.
- Ein y, welches den mittleren quadratischen Fehler $\mathrm{mse}(x, y)$ minimiert, nennt man Mittelwert von x, $\mathrm{mean}(x) = \mathrm{argmin}_{c \in \mathbb{R}} \mathrm{mse}(x, c)$

Vergleich von Daten mit einer Konstanten

- Gegeben Daten x mit Stichprobengröße n und einer Konstanten y können wir nach dem Fehler fragen, den wir machen, wenn wir x durch y modellieren.
- Ein y, welches den mittleren absoluten Fehler $\mathrm{mae}(x, y)$ minimiert, nennt man Median von x, $\mathrm{median}(x) \in \mathrm{argmin}_{c \in \mathbb{R}} \mathrm{mae}(x, c)$. Manche fordern $c \in x$, dass also der Median ein Datenpunkt sein muss.
- Ein y, welches den mittleren quadratischen Fehler $\mathrm{mse}(x, y)$ minimiert, nennt man Mittelwert von x, $\mathrm{mean}(x) = \mathrm{argmin}_{c \in \mathbb{R}} \mathrm{mse}(x, c)$
- Es ist $\mathrm{mean}(x) = \frac{1}{n} \sum_{i=0}^{n-1} x_i$, das arithmetische Mittel.

Vergleich von Daten mit einer Konstanten

- Gegeben Daten x mit Stichprobengröße n und einer Konstanten y können wir nach dem Fehler fragen, den wir machen, wenn wir x durch y modellieren.
- Ein y, welches den mittleren absoluten Fehler $\mathrm{mae}(x, y)$ minimiert, nennt man Median von x, $\mathrm{median}(x) \in \mathrm{argmin}_{c\in\mathbb{R}}\mathrm{mae}(x, c)$. Manche fordern $c \in x$, dass also der Median ein Datenpunkt sein muss.
- Ein y, welches den mittleren quadratischen Fehler $\mathrm{mse}(x, y)$ minimiert, nennt man Mittelwert von x, $\mathrm{mean}(x) = \mathrm{argmin}_{c\in\mathbb{R}}\mathrm{mse}(x, c)$
- Es ist $\mathrm{mean}(x) = \frac{1}{n}\sum_{i=0}^{n-1} x_i$, das arithmetische Mittel.
- Für ungerades n schreiben wir $n = 2m + 1$. Wenn $i(0), \ldots, i(2m)$ Indizes sind sodass $x_{i(j)} \leq x_{i(j+1)}$, dann ist das mittlere $x_{i(m)}$ ein Median von x.

Beispielvergleich von Daten mit konstantem Modell

Heinrich Heine Universität Düsseldorf

Wir wählen nun konstante Modelle: Median 167 und Mittelwert 166.75.

	x	x - median(x)	x - mean(x)
0	178	11	11.25
1	160	-7	-6.75
2	155	-12	-11.75
3	174	7	7.25

$$\text{mae}(\text{x}, \text{median}(\text{x})) = \frac{11 + 7 + 12 + 7}{4} = 9.25, \;\; \text{mse}(\text{x}, \text{mean}(\text{x})) = 90.6875 \approx 9.523^2$$

Es gibt keine konstanten Modelle mit kleineren mae bzw. mse.

Abweichung vom besten konstanten Modell

- Die Größe $\mathrm{mse}(\mathrm{x}, \mathrm{mean}(\mathrm{x}))$ ist ein Maß für die Streuung der Daten.

Abweichung vom besten konstanten Modell

- Die Größe $\mathrm{mse}(\mathrm{x}, \mathrm{mean}(\mathrm{x}))$ ist ein Maß für die Streuung der Daten.
- Da der mittlere quadratische Fehler auf einer anderen Skala liegt als die Daten selbst, ziehen wir die Wurzel:

$$\sigma(\mathrm{x}) := \mathrm{rmse}(\mathrm{x}, \mathrm{mean}(\mathrm{x})) := \sqrt{\mathrm{mse}(\mathrm{x}, \mathrm{mean}(\mathrm{x}))}$$

heißt root mean squared error oder auch Stichproben-Standardabweichung.

Abweichung vom besten konstanten Modell

- Die Größe $\mathrm{mse}(\mathrm{x}, \mathrm{mean}(\mathrm{x}))$ ist ein Maß für die Streuung der Daten.
- Da der mittlere quadratische Fehler auf einer anderen Skala liegt als die Daten selbst, ziehen wir die Wurzel:

$$\sigma(\mathrm{x}) := \mathrm{rmse}(\mathrm{x}, \mathrm{mean}(\mathrm{x})) := \sqrt{\mathrm{mse}(\mathrm{x}, \mathrm{mean}(\mathrm{x}))}$$

  heißt root mean squared error oder auch Stichproben-Standardabweichung.
- Nützliche Formel (wobei x^2 komponentenweise zu verstehen ist):

$$\sigma(\mathrm{x})^2 = \frac{1}{\mathrm{n}} \sum_{\mathrm{i}=0}^{\mathrm{n}-1} (\mathrm{x_i} - \mathrm{mean}(\mathrm{x}))^2 = \mathrm{mean}(\mathrm{x}^2) - \mathrm{mean}(\mathrm{x})^2$$

Zusammenfassung: Abweichungen und Mittel

- Ziel: Unterschied zwischen Daten und Modell quantifizieren.
- Abstandsmaße:
  - Mittlerer absoluter Fehler (MAE): mittlerer Betrag der Abweichungen
  - Mittlerer quadratischer Fehler (MSE): mittleres Quadrat der Abweichungen
- Beste konstante Modelle:
  - Median minimiert den MAE
  - Mittelwert minimiert den MSE
- Streumaß:
  - Standardabweichung (RMSE): Wurzel des MSE beim Mittelwert-Modell



Heinrich Heine
Universität Düsseldorf

Pause?

Mittelwerterwartung

- Das konstante Modell ist eine Dirac-Verteilung. Für eine interessantere Verteilung können wir Stichproben ziehen (sampeln) und deren Mittelwerte und Standardabweichungen berechnen. Der Vergleich mit Mittelwert und Standardabweichung der Daten gibt Anhaltspunkte für gute Modelle.

Mittelwerterwartung

- Das konstante Modell ist eine Dirac-Verteilung. Für eine interessantere Verteilung können wir Stichproben ziehen (sampeln) und deren Mittelwerte und Standardabweichungen berechnen. Der Vergleich mit Mittelwert und Standardabweichung der Daten gibt Anhaltspunkte für gute Modelle.
- Je größer die synthetischen Daten, desto aussagekräftiger.

Mittelwerterwartung

- Das konstante Modell ist eine Dirac-Verteilung. Für eine interessantere Verteilung können wir Stichproben ziehen (sampeln) und deren Mittelwerte und Standardabweichungen berechnen. Der Vergleich mit Mittelwert und Standardabweichung der Daten gibt Anhaltspunkte für gute Modelle.
- Je größer die synthetischen Daten, desto aussagekräftiger.
- Es geht noch besser: wir berechnen den Grenzwert des "synthetischen Mittelwerts" ohne je eine Stichprobe simulieren zu müssen. Wie?

Mittelwerterwartung

- Wenn $p = \left(\frac{a_1}{N}, ..., \frac{a_k}{N}\right)$ ein Wahrscheinlichkeitsvektor ist (also k mögliche Merkmalsausprägungen $y_1, \ldots, y_k \in \mathbb{R}$), so hätte ein "idealisiertes Sample" $\tilde{D}$ z.B. die Häufigkeiten $(a_1, \ldots, a_k)$.

Mittelwerterwartung

- Wenn $p = \left(\frac{a_1}{N}, ..., \frac{a_k}{N}\right)$ ein Wahrscheinlichkeitsvektor ist (also k mögliche Merkmalsausprägungen $y_1, \ldots, y_k \in \mathbb{R}$), so hätte ein "idealisiertes Sample" $\tilde{D}$ z.B. die Häufigkeiten $(a_1, \ldots, a_k)$.
- Der Mittelwert wäre dann $\text{mean}(\tilde{D}) = \frac{1}{N} \sum_{j=1}^{k} a_j y_j$.

Mittelwerterwartung

- Wenn $p = \left(\frac{a_1}{N}, ..., \frac{a_k}{N}\right)$ ein Wahrscheinlichkeitsvektor ist (also k mögliche Merkmalsausprägungen $y_1, \ldots, y_k \in \mathbb{R}$), so hätte ein "idealisiertes Sample" $\tilde{D}$ z.B. die Häufigkeiten $(a_1, \ldots, a_k)$.
- Der Mittelwert wäre dann $\text{mean}(\tilde{D}) = \frac{1}{N} \sum_{j=1}^{k} a_j y_j$.
- Allgemein definieren wir für eine reelle Zufallsvariable $X\colon \Omega \to \mathbb{R}$ mit nur endlich vielen oder höchstens abzählbar unendlich vielen Werten

$$\mathbb{E}(X) := \sum_{\omega \in \Omega} P(\{\omega\}) X(\omega) = \sum_{x \in \mathbb{R}} p_X(x) x$$

(p_X eine pmf für die Verteilung von X). Das ist der Erwartungswert von X.

Erwartungswert einer Gleichverteilung

- Sei $\Omega = \{0, \dots, n-1\}$ mit einer Gleichverteilung gegeben und $X\colon \Omega \to \mathbb{R}$ die Abbildung $\omega \mapsto \omega + 1$. Dann hat die Verteilung von X den Erwartungswert

$$\mathbb{E}(X) = \sum_{\omega=0}^{n-1} \frac{\omega+1}{n} = \sum_{i=1}^{n} \frac{i}{n} = \frac{n(n+1)}{2n} = \frac{n+1}{2}$$

Erwartungswert einer Gleichverteilung

- Sei $\Omega = \{0, \dots, n-1\}$ mit einer Gleichverteilung gegeben und $X\colon \Omega \to \mathbb{R}$ die Abbildung $\omega \mapsto \omega + 1$. Dann hat die Verteilung von X den Erwartungswert

$$\mathbb{E}(X) = \sum_{\omega=0}^{n-1} \frac{\omega+1}{n} = \sum_{i=1}^{n} \frac{i}{n} = \frac{n(n+1)}{2n} = \frac{n+1}{2}$$

- Wenn stattdessen $Y\colon \Omega \to \mathbb{R}$ mit $\omega \mapsto \omega$ eine Gleichverteilung auf $\{0, \dots, n-1\}$ beschreibt, so ist $\mathbb{E}(Y) = \frac{n+1}{2} - 1$.

Streuungserwartung

- Das konstante Modell ist eine Dirac-Verteilung, die Streuung ist 0. Für eine interessantere Verteilung können wir Stichproben ziehen (sampeln) und deren Standardabweichungen berechnen.

Streuungserwartung

- Das konstante Modell ist eine Dirac-Verteilung, die Streuung ist 0. Für eine interessantere Verteilung können wir Stichproben ziehen (sampeln) und deren Standardabweichungen berechnen.
- Wir berechnen den Grenzwert der “synthetischen Standardabweichung” ohne je eine Stichprobe simulieren zu müssen. Wie?

Streuungserwartung

- Das konstante Modell ist eine Dirac-Verteilung, die Streuung ist 0. Für eine interessantere Verteilung können wir Stichproben ziehen (sampeln) und deren Standardabweichungen berechnen.
- Wir berechnen den Grenzwert der “synthetischen Standardabweichung” ohne je eine Stichprobe simulieren zu müssen. Wie?
- $\mathbb{V}(X) := \mathbb{E}\left((X - \mathbb{E}X)^2\right) = \mathbb{E}(X^2) - (\mathbb{E}X)^2$ heißt Varianz von X und $\sigma(X) := \sqrt{\mathbb{V}X}$ die Standardabweichung von X.

Streuungserwartung

- Das konstante Modell ist eine Dirac-Verteilung, die Streuung ist 0. Für eine interessantere Verteilung können wir Stichproben ziehen (sampeln) und deren Standardabweichungen berechnen.
- Wir berechnen den Grenzwert der “synthetischen Standardabweichung” ohne je eine Stichprobe simulieren zu müssen. Wie?
- $\mathbb{V}(X) := \mathbb{E}\left((X - \mathbb{E}X)^2\right) = \mathbb{E}(X^2) - (\mathbb{E}X)^2$ heißt Varianz von X und $\sigma(X) := \sqrt{\mathbb{V}X}$ die Standardabweichung von X.
- Tschebyscheff-Ungleichung: für $\lambda > 0$ ist $\mathrm{P}\left(|X - \mathbb{E}(X)| \geq \lambda\sigma(X)\right) \leq \frac{1}{\lambda^2}$, die Wahrscheinlichkeit einer absoluten Abweichung um mehr als λ Standardabweichungen liegt also unter $\frac{1}{\lambda^2}$.

Zusammenfassung: Momente einer Zufallsvariablen

Heinrich Heine Universität Düsseldorf

- Erwartungswert:
  - Mittelwert einer Zufallsvariablen: $\mathbb{E}(X) = \sum_x p_X(x)\, x$
  - Der typische Wert, den man im Mittel bei vielen Stichproben erwartet
- Varianz und Standardabweichung:
  - Streuung um den Erwartungswert: $\mathbb{V}(X) = \mathbb{E}(X^2) - \mathbb{E}(X)^2$
  - $\sigma(X) := \sqrt{\mathbb{V}(X)}$ ist die Standardabweichung
- Interpretation:
  - $\mathbb{E}X$ und $\sigma(X)$ geben zentrale Lage und Streuung der Verteilung an
  - Tschebyscheff-Ungleichung:
    Abweichungen um mehr als λ Standardabweichungen sind selten

Erwartungswert und Varianz sind fundamentale Kennzahlen von Modellen.



Heinrich Heine
Universität Düsseldorf

Vielen Dank für Ihre Aufmerksamkeit!