

Data Science, VL 5

Dr. Konrad Völkel, Sommersemester 2026

30.04.2025

Was bisher geschah: Statistik

- Für einen Vektor v reeller Zahlen (eine Spalte in einer Tabelle Daten) lassen sich median und mean definieren wie üblich. Dabei minimiert ein Median den mittleren absoluten Fehler mae; das arithmetische Mittel (mean) minimiert den mittleren quadratischen Fehler mse zu den Daten.

Was bisher geschah: Statistik

- Für einen Vektor v reeller Zahlen (eine Spalte in einer Tabelle Daten) lassen sich median und mean definieren wie üblich. Dabei minimiert ein Median den mittleren absoluten Fehler mae; das arithmetische Mittel (mean) minimiert den mittleren quadratischen Fehler mse zu den Daten.
- Die Daten v lassen sich zentrieren: $\tilde{v} := v - \mathrm{mean}(v)$.
  Dabei muss $-\mathrm{mean}(v)$ komponentenweise verstanden werden, also
  $\tilde{v}_i := v_i - \mathrm{mean}(v)$.

Was bisher geschah: Statistik

- Für einen Vektor v reeller Zahlen (eine Spalte in einer Tabelle Daten) lassen sich median und mean definieren wie üblich. Dabei minimiert ein Median den mittleren absoluten Fehler mae; das arithmetische Mittel (mean) minimiert den mittleren quadratischen Fehler mse zu den Daten.
- Die Daten v lassen sich zentrieren: $\tilde{v} := v - \mathrm{mean}(v)$.
  Dabei muss $-\mathrm{mean}(v)$ komponentenweise verstanden werden, also $\tilde{v}_i := v_i - \mathrm{mean}(v)$.
- Die Wurzel aus dem mittleren quadratischen Fehler des Mittelwerts heißt Sample-Standardabweichung $\sigma(v) := \mathrm{rmse}(v, \mathrm{mean}(v)) = \frac{1}{\sqrt{n}}\|\tilde{v}\|$.

Was bisher geschah: Statistik

- Für einen Vektor v reeller Zahlen (eine Spalte in einer Tabelle Daten) lassen sich median und mean definieren wie üblich. Dabei minimiert ein Median den mittleren absoluten Fehler mae; das arithmetische Mittel (mean) minimiert den mittleren quadratischen Fehler mse zu den Daten.
- Die Daten v lassen sich zentrieren: $\tilde{v} := v - \mathrm{mean}(v)$.
  Dabei muss $-\mathrm{mean}(v)$ komponentenweise verstanden werden, also $\tilde{v}_i := v_i - \mathrm{mean}(v)$.
- Die Wurzel aus dem mittleren quadratischen Fehler des Mittelwerts heißt Sample-Standardabweichung $\sigma(v) := \mathrm{rmse}(v, \mathrm{mean}(v)) = \frac{1}{\sqrt{n}}\|\tilde{v}\|$.
- Die Varianz von v ist $\sigma(v)^2 = \frac{1}{n}\tilde{v} \cdot \tilde{v} = \frac{1}{n}\tilde{v}^\top \tilde{v}$.

Was bisher geschah: Stochastik

- Reelle Zufallsvariablen sind (messbare) Abbildungen $X\colon \Omega \to \mathbb{R}$, die induzierte Verteilung P_X heißt auch Verteilung von X und lässt sich für endliche Ω mit einer pmf beschreiben, $p_X(x) = P(X = x) = \sum_{\omega\in\Omega:X(\omega)=x} P_\Omega(\{\omega\})$.

Was bisher geschah: Stochastik

- Reelle Zufallsvariablen sind (messbare) Abbildungen $X\colon \Omega \to \mathbb{R}$, die induzierte Verteilung P_X heißt auch Verteilung von X und lässt sich für endliche Ω mit einer pmf beschreiben, $p_X(x) = P(X = x) = \sum_{\omega\in\Omega:X(\omega)=x} P_\Omega(\{\omega\})$.
- $\mathbb{E}(X) := \sum_{x\in\mathbb{R}} xp(x)$ heißt Erwartungswert von X.

Was bisher geschah: Stochastik

Heinrich Heine Universität Düsseldorf

- Reelle Zufallsvariablen sind (messbare) Abbildungen $X\colon \Omega \to \mathbb{R}$, die induzierte Verteilung P_X heißt auch Verteilung von X und lässt sich für endliche Ω mit einer pmf beschreiben, $p_X(x) = P(X = x) = \sum_{\omega\in\Omega:X(\omega)=x} P_\Omega(\{\omega\})$.
- $\mathbb{E}(X) := \sum_{x\in\mathbb{R}} xp(x)$ heißt Erwartungswert von X.
- $\mathbb{V}(X) := \mathbb{E}\left((X - \mathbb{E}X)^2\right) = \mathbb{E}(X^2) - (\mathbb{E}X)^2$ heißt Varianz von X und $\sigma(X) := \sqrt{\mathbb{V}X}$ die Standardabweichung von X.

Ausblick: Höhere Momente

- Für allgemeines n ist $\mu_n(X) := \mathbb{E}(X^n)$ das n-te Moment,

Ausblick: Höhere Momente

- Für allgemeines n ist $\mu_n(X) := \mathbb{E}(X^n)$ das n-te Moment,
- $\tilde{X} := X - \mathbb{E}(X)$ die zentrierte Zufallsvariable,

Ausblick: Höhere Momente

- Für allgemeines n ist $\mu_n(X) := \mathbb{E}(X^n)$ das n-te Moment,
- $\tilde{X} := X - \mathbb{E}(X)$ die zentrierte Zufallsvariable,
- $\tilde{\mu}_n(X) := \mu_n(\tilde{X})$ das n-te zentrale Moment.

Ausblick: Höhere Momente

- Für allgemeines n ist $\mu_n(X) := \mathbb{E}(X^n)$ das n-te Moment,
- $\tilde{X} := X - \mathbb{E}(X)$ die zentrierte Zufallsvariable,
- $\tilde{\mu}_n(X) := \mu_n(\tilde{X})$ das n-te zentrale Moment.
- Es ist $\mu_1(X) = \mathbb{E}X$, $\tilde{\mu}_1(X) = 0$, $\tilde{\mu}_2(X) = \mathbb{V}X$.

Numpy

Heinrich Heine
Universität Düsseldorf

Wir werden im Folgenden das Paket Numpy verwenden, denn

- Numpy bietet ein Interface zu schnellen Bibliotheken für lineare Algebra und Statistik, die in C, Fortran oder Assembler geschrieben sind.

Numpy

Heinrich Heine
Universität Düsseldorf

Wir werden im Folgenden das Paket Numpy verwenden, denn

- Numpy bietet ein Interface zu schnellen Bibliotheken für lineare Algebra und Statistik, die in C, Fortran oder Assembler geschrieben sind.
- Numpy ermöglicht SIMD-Verarbeitung: single instruction, multiple data.

Numpy

Heinrich Heine
Universität Düsseldorf

Wir werden im Folgenden das Paket Numpy verwenden, denn

- Numpy bietet ein Interface zu schnellen Bibliotheken für lineare Algebra und Statistik, die in C, Fortran oder Assembler geschrieben sind.
- Numpy ermöglicht SIMD-Verarbeitung: single instruction, multiple data. Anstelle von expliziten for-Schleifen über Listen wird eine Operation auf einen ganzen Vektor angewendet. Wenn die Operation keine Verzweigungen (Branching, also if-Abfragen) enthält, kann ein moderner Prozessor das schneller.
- PyTorch (für Deep Learning) arbeitet sehr ähnlich mit Vektoren (tensor vs. ndarray).

Numpy

Heinrich Heine
Universität Düsseldorf

Wir werden im Folgenden das Paket Numpy verwenden, denn

- Numpy bietet ein Interface zu schnellen Bibliotheken für lineare Algebra und Statistik, die in C, Fortran oder Assembler geschrieben sind.
- Numpy ermöglicht SIMD-Verarbeitung: single instruction, multiple data. Anstelle von expliziten for-Schleifen über Listen wird eine Operation auf einen ganzen Vektor angewendet. Wenn die Operation keine Verzweigungen (Branching, also if-Abfragen) enthält, kann ein moderner Prozessor das schneller.
- PyTorch (für Deep Learning) arbeitet sehr ähnlich mit Vektoren (tensor vs. ndarray).

Wir müssen unseren Code also verzweigungsfrei gestalten, vektorisieren.

Heinrich Heine
Universität Düsseldorf

Pause?

Heinrich Heine
Universität Düsseldorf

Programmierung

Im Notebook: Stochastik programmieren

Unabhängigkeit

Heinrich Heine
Universität Düsseldorf

Definition

Sei Ω ein Wahrscheinlichkeitsraum.
Ereignisse $A, B \subseteq \Omega$ heißen voneinander unabhängig, wenn

$$P(A \cap B) = P(A) \cdot P(B).$$

Unabhängigkeit

Heinrich Heine
Universität Düsseldorf

Definition

Sei Ω ein Wahrscheinlichkeitsraum.
Ereignisse $A, B \subseteq \Omega$ heißen voneinander unabhängig, wenn

$$P(A \cap B) = P(A) \cdot P(B).$$

Allgemeiner heißt eine Familie $(A_i)_{i \in I}$, $A_i \subseteq \Omega$ von Ereignissen unabhängig, wenn für jede endliche Teilindexmenge $J \subseteq I$ gilt:

$$P\left(\bigcap_{j \in J} A_j\right) = \prod_{j \in J} P(A_j).$$

Beispiel zur Unabhängigkeit

Zwei faire sechsseitige Würfel werden unabhängig voneinander geworfen.

- Ereignis A: Der erste Würfel zeigt eine gerade Zahl.
- Ereignis B: Der zweite Würfel zeigt eine 6.

Beispiel zur Unabhängigkeit

Zwei faire sechsseitige Würfel werden unabhängig voneinander geworfen.

- Ereignis A: Der erste Würfel zeigt eine gerade Zahl.
- Ereignis B: Der zweite Würfel zeigt eine 6.

- $\mathrm{P}(\mathrm{A}) = \frac{3}{6} = \frac{1}{2}$ (gerade Zahlen: 2, 4, 6)
- $\mathrm{P}(\mathrm{B}) = \frac{1}{6}$
- $\mathrm{P}(\mathrm{A} \cap \mathrm{B}) = \mathrm{P}(\mathrm{A}) \cdot \mathrm{P}(\mathrm{B}) = \frac{1}{2} \cdot \frac{1}{6} = \frac{1}{12}$

Beispiel zur Unabhängigkeit

Zwei faire sechsseitige Würfel werden unabhängig voneinander geworfen.

- Ereignis A: Der erste Würfel zeigt eine gerade Zahl.
- Ereignis B: Der zweite Würfel zeigt eine 6.

- $\mathrm{P}(\mathrm{A}) = \frac{3}{6} = \frac{1}{2}$ (gerade Zahlen: 2, 4, 6)
- $\mathrm{P}(\mathrm{B}) = \frac{1}{6}$
- $\mathrm{P}(\mathrm{A} \cap \mathrm{B}) = \mathrm{P}(\mathrm{A}) \cdot \mathrm{P}(\mathrm{B}) = \frac{1}{2} \cdot \frac{1}{6} = \frac{1}{12}$

Da A und B sich auf unterschiedliche Würfel beziehen, sind sie unabhängig.

Beispiel zur Abhängigkeit

Eine Tüte enthält je ein rotes, grünes und blaues Bonbon.
Zwei Bonbons werden nacheinander ohne Zurücklegen gezogen.

Beispiel zur Abhängigkeit

Eine Tüte enthält je ein rotes, grünes und blaues Bonbon.
Zwei Bonbons werden nacheinander ohne Zurücklegen gezogen.

- Ereignis A: Das erste gezogene Bonbon ist rot.
- Ereignis B: Das zweite gezogene Bonbon ist grün.

Beispiel zur Abhängigkeit

Eine Tüte enthält je ein rotes, grünes und blaues Bonbon.
Zwei Bonbons werden nacheinander ohne Zurücklegen gezogen.

- Ereignis A: Das erste gezogene Bonbon ist rot.
- Ereignis B: Das zweite gezogene Bonbon ist grün.

Insgesamt gibt es $3 \cdot 2 = 6$ mögliche geordnete Ziehungen.

Beispiel zur Abhängigkeit

Eine Tüte enthält je ein rotes, grünes und blaues Bonbon.
Zwei Bonbons werden nacheinander ohne Zurücklegen gezogen.

- Ereignis A: Das erste gezogene Bonbon ist rot.
- Ereignis B: Das zweite gezogene Bonbon ist grün.

Insgesamt gibt es $3 \cdot 2 = 6$ mögliche geordnete Ziehungen.

- Zustände für A: (rot, grün), (rot, blau) $\Rightarrow \mathrm{P(A)} = \frac{2}{6} = \frac{1}{3}$

Beispiel zur Abhängigkeit

Eine Tüte enthält je ein rotes, grünes und blaues Bonbon.
Zwei Bonbons werden nacheinander ohne Zurücklegen gezogen.

- Ereignis A: Das erste gezogene Bonbon ist rot.
- Ereignis B: Das zweite gezogene Bonbon ist grün.

Insgesamt gibt es $3 \cdot 2 = 6$ mögliche geordnete Ziehungen.

- Zustände für A: (rot, grün), (rot, blau) $\Rightarrow \mathrm{P(A)} = \frac{2}{6} = \frac{1}{3}$
- Zustände für B: (rot, grün), (blau, grün) $\Rightarrow \mathrm{P(B)} = \frac{2}{6} = \frac{1}{3}$

Beispiel zur Abhängigkeit

Eine Tüte enthält je ein rotes, grünes und blaues Bonbon.
Zwei Bonbons werden nacheinander ohne Zurücklegen gezogen.

- Ereignis A: Das erste gezogene Bonbon ist rot.
- Ereignis B: Das zweite gezogene Bonbon ist grün.

Insgesamt gibt es $3 \cdot 2 = 6$ mögliche geordnete Ziehungen.

- Zustände für A: (rot, grün), (rot, blau) $\Rightarrow \mathrm{P(A)} = \frac{2}{6} = \frac{1}{3}$
- Zustände für B: (rot, grün), (blau, grün) $\Rightarrow \mathrm{P(B)} = \frac{2}{6} = \frac{1}{3}$
- Zustände für $\mathrm{A} \cap \mathrm{B}$: (rot, grün) $\Rightarrow \mathrm{P(A} \cap \mathrm{B)} = \frac{1}{6}$

Beispiel zur Abhängigkeit

Heinrich Heine Universität Düsseldorf

Eine Tüte enthält je ein rotes, grünes und blaues Bonbon.
Zwei Bonbons werden nacheinander ohne Zurücklegen gezogen.

- Ereignis A: Das erste gezogene Bonbon ist rot.
- Ereignis B: Das zweite gezogene Bonbon ist grün.

Insgesamt gibt es $3 \cdot 2 = 6$ mögliche geordnete Ziehungen.

- Zustände für A: (rot, grün), (rot, blau) $\Rightarrow \mathrm{P(A)} = \frac{2}{6} = \frac{1}{3}$
- Zustände für B: (rot, grün), (blau, grün) $\Rightarrow \mathrm{P(B)} = \frac{2}{6} = \frac{1}{3}$
- Zustände für $\mathrm{A} \cap \mathrm{B}$: (rot, grün) $\Rightarrow \mathrm{P(A \cap B)} = \frac{1}{6}$

$$\mathrm{P(A)} \cdot \mathrm{P(B)} = \frac{1}{3} \cdot \frac{1}{3} = \frac{1}{9} \neq \frac{1}{6} = \mathrm{P(A \cap B)}$$

$\Rightarrow$ A und B sind also nicht unabhängig, sie sind abhängig.

Unabhängige Zufallsvariablen

Heinrich Heine
Universität Düsseldorf

Definition

Sei Ω ein Wahrscheinlichkeitsraum, dann heißen zwei Zufallsvariablen
$X\colon \Omega'_X \to \Omega_X,\ Y\colon \Omega'_Y \to \Omega_Y$ unabhängig, wenn für alle $A \subseteq \Omega_X$ und $B \subseteq \Omega_Y$ gilt:

$$P(X \in A,\ Y \in B) = P(X \in A) \cdot P(Y \in B).$$

Unabhängige Zufallsvariablen

Heinrich Heine Universität Düsseldorf

Definition

Sei Ω ein Wahrscheinlichkeitsraum, dann heißen zwei Zufallsvariablen $X\colon \Omega'_X \to \Omega_X,\ Y\colon \Omega'_Y \to \Omega_Y$ unabhängig, wenn für alle $A \subseteq \Omega_X$ und $B \subseteq \Omega_Y$ gilt:

$$P(X \in A,\ Y \in B) = P(X \in A) \cdot P(Y \in B).$$

Dabei bedeutet $P(X \in A,\ Y \in B) = P((X,Y) \in A \times B)$ für die gemeinsame Verteilung von $(X,Y)\colon \Omega'_X \times \Omega'_Y \to \Omega_X \times \Omega_Y$.

Unabhängige Zufallsvariablen

Heinrich Heine Universität Düsseldorf

Definition

Sei Ω ein Wahrscheinlichkeitsraum, dann heißen zwei Zufallsvariablen
$X\colon \Omega'_X \to \Omega_X,\ Y\colon \Omega'_Y \to \Omega_Y$ unabhängig, wenn für alle $A \subseteq \Omega_X$ und $B \subseteq \Omega_Y$ gilt:

$$P(X \in A,\ Y \in B) = P(X \in A) \cdot P(Y \in B).$$

Dabei bedeutet $P(X \in A,\ Y \in B) = P((X,Y) \in A \times B)$
für die gemeinsame Verteilung von $(X,Y)\colon \Omega'_X \times \Omega'_Y \to \Omega_X \times \Omega_Y$.
Wenn X eine pmf p und Y eine pmf q hat,
dann sind X und Y unabhängig genau dann, wenn

$$P(X = x, Y = y) = p(x)q(y).$$

Korrelation

Achtung: Abhängigkeit $\neq$ Korrelation!

Korrelation

Achtung: Abhängigkeit $\neq$ Korrelation!
Korrelation $\Rightarrow$ Abhängigkeit

Korrelation

Achtung: Abhängigkeit $\neq$ Korrelation!
Korrelation $\Rightarrow$ Abhängigkeit
Korrelation misst man mit dem Korrelationskoeffizienten, der Kovarianz.
Abhängigkeit lässt sich mit der relativen Entropie messen.
Das besprechen wir beides noch, auf dem Weg zur multivariaten Statistik.



Heinrich Heine
Universität Düsseldorf

Pause?

Motivation: Das Gesetz der großen Zahlen

- Setup: Wir wiederholen ein Zufallsexperiment (Zufallsvariable $X\colon \Omega \to \mathbb{R}$)

Wir üben die bisher gelernten Konzepte, indem wir eine Beweisskizze anschauen.

Motivation: Das Gesetz der großen Zahlen

- Setup: Wir wiederholen ein Zufallsexperiment (Zufallsvariable $X\colon \Omega \to \mathbb{R}$)
- Modell: Eine Folge von Zufallsvariablen $X_1,\ X_2,\ \ldots$ mit $X_i \sim X$

Wir üben die bisher gelernten Konzepte, indem wir eine Beweisskizze anschauen.

Motivation: Das Gesetz der großen Zahlen

- Setup: Wir wiederholen ein Zufallsexperiment (Zufallsvariable $X\colon \Omega \to \mathbb{R}$)

- Modell: Eine Folge von Zufallsvariablen $X_1,\ X_2,\ \ldots$ mit $X_i \sim X$
- $X_i \sim X$:= "Jedes X_i ist verteilt wie X".

Wir üben die bisher gelernten Konzepte, indem wir eine Beweisskizze anschauen.

Motivation: Das Gesetz der großen Zahlen

- Setup: Wir wiederholen ein Zufallsexperiment (Zufallsvariable $X\colon \Omega \to \mathbb{R}$)

- Modell: Eine Folge von Zufallsvariablen $X_1,\ X_2,\ \ldots$ mit $X_i \sim X$
- $X_i \sim X$:= "Jedes X_i ist verteilt wie X".
- Außerdem: X_i beeinflusst X_{i+1} nicht usw. "Unabhängigkeit"

Wir üben die bisher gelernten Konzepte, indem wir eine Beweisskizze anschauen.

Motivation: Das Gesetz der großen Zahlen

- Setup: Wir wiederholen ein Zufallsexperiment (Zufallsvariable $X\colon \Omega \to \mathbb{R}$)

- Modell: Eine Folge von Zufallsvariablen $X_1,\ X_2,\ \ldots$ mit $X_i \sim X$
- $X_i \sim X$:= "Jedes X_i ist verteilt wie X".
- Außerdem: X_i beeinflusst X_{i+1} nicht usw. "Unabhängigkeit"

- "Satz": Dann konvergiert der Mittelwert von $X_1, \ldots, X_n$ gegen $\mathbb{E}X$.

Wir üben die bisher gelernten Konzepte, indem wir eine Beweisskizze anschauen.

Motivation: Das Gesetz der großen Zahlen

- Setup: Wir wiederholen ein Zufallsexperiment (Zufallsvariable $X\colon \Omega \to \mathbb{R}$)

- Modell: Eine Folge von Zufallsvariablen $X_1,\ X_2,\ \ldots$ mit $X_i \sim X$
- $X_i \sim X$:= "Jedes X_i ist verteilt wie X".
- Außerdem: X_i beeinflusst X_{i+1} nicht usw. "Unabhängigkeit"

- "Satz": Dann konvergiert der Mittelwert von $X_1, \ldots, X_n$ gegen $\mathbb{E}X$.
- Interpretation: Je größer die Stichprobe, desto besser schätzt `mean` den $\mathbb{E}X$.

Wir üben die bisher gelernten Konzepte, indem wir eine Beweisskizze anschauen.

Lemma (Markov-Ungleichung)

Für $X\colon \Omega \to \mathbb{R}$ mit $X \geq 0$ und $a > 0$ ist

$$P(X \geq a) \leq \frac{\mathbb{E}X}{a}$$

Lemma (Markov-Ungleichung)

Für $X\colon \Omega \to \mathbb{R}$ mit $X \geq 0$ und $a > 0$ ist

$$P(X \geq a) \leq \frac{\mathbb{E}X}{a}$$

Beweis.

$$\mathbb{E}X = \sum_{x=-\infty}^{\infty} x\, p(x)$$

Lemma (Markov-Ungleichung)

Für $X\colon \Omega \to \mathbb{R}$ mit $X \geq 0$ und $a > 0$ ist

$$P(X \geq a) \leq \frac{\mathbb{E}X}{a}$$

Beweis.

$$\mathbb{E}X = \sum_{x=-\infty}^{\infty} x\, p(x) \overset{(X\geq 0)}{=} \sum_{x=0}^{\infty} x\, p(x)$$

Lemma (Markov-Ungleichung)

Für $X\colon \Omega \to \mathbb{R}$ mit $X \geq 0$ und $a > 0$ ist

$$P(X \geq a) \leq \frac{\mathbb{E}X}{a}$$

Beweis.

$$\mathbb{E}X = \sum_{x=-\infty}^{\infty} x\, p(x) \overset{(X\geq 0)}{=} \sum_{x=0}^{\infty} x\, p(x) \geq \sum_{x=a}^{\infty} x\, p(x)$$

Markov

Heinrich Heine Universität Düsseldorf

Lemma (Markov-Ungleichung)

Für $X\colon \Omega \to \mathbb{R}$ mit $X \geq 0$ und $a > 0$ ist

$$P(X \geq a) \leq \frac{\mathbb{E}X}{a}$$

Beweis.

$$\mathbb{E}X = \sum_{x=-\infty}^{\infty} x\, p(x) \overset{(X\geq 0)}{=} \sum_{x=0}^{\infty} x\, p(x) \geq \sum_{x=a}^{\infty} x\, p(x) \geq \sum_{x=a}^{\infty} a\, p(x)$$

Lemma (Markov-Ungleichung)

Für $X\colon \Omega \to \mathbb{R}$ mit $X \geq 0$ und $a > 0$ ist

$$P(X \geq a) \;\leq\; \frac{\mathbb{E}X}{a}$$

Beweis.

$$\mathbb{E}X = \sum_{x=-\infty}^{\infty} x\, p(x) \overset{(X\geq 0)}{=} \sum_{x=0}^{\infty} x\, p(x) \geq \sum_{x=a}^{\infty} x\, p(x) \geq \sum_{x=a}^{\infty} a\, p(x) = aP(X \geq a).$$

□

Tschebyscheff

Heinrich Heine
Universität Düsseldorf

Lemma (Tschebyscheff-Ungleichung)

Für $\lambda > 0$ ist $\mathrm{P}\left(|\mathrm{X} - \mathbb{E}(\mathrm{X})| \geq \lambda\sigma(\mathrm{X})\right) \leq \frac{1}{\lambda^2}$.

Tschebyscheff

Heinrich Heine Universität Düsseldorf

Lemma (Tschebyscheff-Ungleichung)

Für $\lambda > 0$ ist $\mathrm{P}\left(|\mathrm{X} - \mathbb{E}(\mathrm{X})| \geq \lambda\sigma(\mathrm{X})\right) \leq \frac{1}{\lambda^2}$.

Beweis.

Wir wenden Markov-Ungleichung auf $\mathrm{Y} := (\mathrm{X} - \mathbb{E}\mathrm{X})^2 \geq 0$ und $\mathrm{a} := \lambda^2\sigma(\mathrm{X})^2$ an:

$$\mathrm{P}\left((\mathrm{X} - \mathbb{E}\mathrm{X})^2 \geq \lambda^2\sigma(\mathrm{X})^2\right) \leq \frac{\mathbb{E}\mathrm{Y}}{\lambda^2\sigma(\mathrm{X})^2}$$

Tschebyscheff

Heinrich Heine Universität Düsseldorf

Lemma (Tschebyscheff-Ungleichung)

Für $\lambda > 0$ ist $\mathrm{P}\left(|\mathrm{X} - \mathbb{E}(\mathrm{X})| \geq \lambda\sigma(\mathrm{X})\right) \leq \frac{1}{\lambda^2}$.

Beweis.

Wir wenden Markov-Ungleichung auf $\mathrm{Y} := (\mathrm{X} - \mathbb{E}\mathrm{X})^2 \geq 0$ und $\mathrm{a} := \lambda^2\sigma(\mathrm{X})^2$ an:

$$\mathrm{P}\left((\mathrm{X} - \mathbb{E}\mathrm{X})^2 \geq \lambda^2\sigma(\mathrm{X})^2\right) \leq \frac{\mathbb{E}\mathrm{Y}}{\lambda^2\sigma(\mathrm{X})^2}$$

Die Ungleichung $\mathrm{P}\left((\cdot)^2 \leq (\cdot)^2\right)$ auf der linken Seite ist äquivalent zu $\mathrm{P}\left(|\cdot| \leq |\cdot|\right)$.

Lemma (Tschebyscheff-Ungleichung)

Für $\lambda > 0$ ist $\mathrm{P}\left(|\mathrm{X} - \mathbb{E}(\mathrm{X})| \geq \lambda\sigma(\mathrm{X})\right) \leq \frac{1}{\lambda^2}$.

Beweis.

Wir wenden Markov-Ungleichung auf $\mathrm{Y} := (\mathrm{X} - \mathbb{E}\mathrm{X})^2 \geq 0$ und $\mathrm{a} := \lambda^2\sigma(\mathrm{X})^2$ an:

$$\mathrm{P}\left((\mathrm{X} - \mathbb{E}\mathrm{X})^2 \geq \lambda^2\sigma(\mathrm{X})^2\right) \leq \frac{\mathbb{E}\mathrm{Y}}{\lambda^2\sigma(\mathrm{X})^2}$$

Die Ungleichung $\mathrm{P}\left((\cdot)^2 \leq (\cdot)^2\right)$ auf der linken Seite ist äquivalent zu $\mathrm{P}\left(|\cdot| \leq |\cdot|\right)$. Wir beobachten auf der rechten Seite noch $\mathbb{E}\mathrm{Y} = \sigma(\mathrm{X})^2$. □

Gesetz der großen Zahlen

Heinrich Heine
Universität Düsseldorf

Für eine Zufallsvariable $X\colon \Omega \to \mathbb{R}$ mit existierendem Erwartungswert, genügt eine Folge unabhängiger Zufallsvariablen X_i mit $X \sim X_i$ (unabhängig identisch verteilt, iid) einem starken Gesetz der großen Zahlen: Die Mittelwert-Abweichungs-Zufallsvariablen $\overline{X}_n - \mathbb{E}X = \frac{1}{n}\sum_{i=1}^{n}(X_i - \mathbb{E}X_i)$ "konvergieren P-fast sicher gegen 0", d.h.

$$P\left(\lim_{n\to\infty} \overline{X}_n = \mathbb{E}X\right) = 1.$$

Gesetz der großen Zahlen

Heinrich Heine Universität Düsseldorf

Für eine Zufallsvariable $X\colon \Omega \to \mathbb{R}$ mit existierendem Erwartungswert, genügt eine Folge unabhängiger Zufallsvariablen X_i mit $X \sim X_i$ (unabhängig identisch verteilt, iid) einem starken Gesetz der großen Zahlen: Die Mittelwert-Abweichungs-Zufallsvariablen $\overline{X}_n - \mathbb{E}X = \frac{1}{n}\sum_{i=1}^{n}(X_i - \mathbb{E}X_i)$ "konvergieren P-fast sicher gegen 0", d.h.

$$P\left(\lim_{n\to\infty} \overline{X}_n = \mathbb{E}X\right) = 1.$$

Daraus folgt auch die "stochastische Konvergenz": für jedes $\epsilon > 0$ ist

$$\lim_{n\to\infty} P\left(|\overline{X}_n - \mathbb{E}X| \geq \epsilon\right) = 0$$

Beweisskizze Große Zahlen

Beweisskizze schwaches Gesetz der großen Zahlen 1/2.

(Mit $\mu := \mathbb{E}X = \mathbb{E}X_i$ unter der Annahme endlicher Varianz $\mathbb{V}X_i = \mathbb{V}X =: \sigma^2$)

$$\mathbb{V}\left(\overline{X}_n\right) = \mathbb{V}\left(\frac{1}{n}\sum_{i=1}^{n}(X_i - \mathbb{E}X_i)\right)$$

Beweisskizze Große Zahlen

Beweisskizze schwaches Gesetz der großen Zahlen 1/2.

(Mit $\mu := \mathbb{E}X = \mathbb{E}X_i$ unter der Annahme endlicher Varianz $\mathbb{V}X_i = \mathbb{V}X =: \sigma^2$)

$$\mathbb{V}\left(\overline{X}_n\right) = \mathbb{V}\left(\frac{1}{n}\sum_{i=1}^{n}(X_i - \mathbb{E}X_i)\right) = \frac{1}{n^2}\mathbb{V}\left(\left(\sum_{i=1}^{n}X_i\right) - n\mathbb{E}X\right)$$

Beweisskizze Große Zahlen

Beweisskizze schwaches Gesetz der großen Zahlen 1/2.

(Mit $\mu := \mathbb{E}X = \mathbb{E}X_i$ unter der Annahme endlicher Varianz $\mathbb{V}X_i = \mathbb{V}X =: \sigma^2$)

$$\mathbb{V}\left(\overline{X}_n\right) = \mathbb{V}\left(\frac{1}{n}\sum_{i=1}^{n}(X_i - \mathbb{E}X_i)\right) = \frac{1}{n^2}\mathbb{V}\left(\left(\sum_{i=1}^{n}X_i\right) - n\mathbb{E}X\right) = \frac{1}{n^2}\mathbb{V}\left(\sum_{i=1}^{n}X_i\right)$$

Beweisskizze Große Zahlen

Beweisskizze schwaches Gesetz der großen Zahlen 1/2.

(Mit $\mu := \mathbb{E}X = \mathbb{E}X_i$ unter der Annahme endlicher Varianz $\mathbb{V}X_i = \mathbb{V}X =: \sigma^2$)

$$\mathbb{V}\left(\overline{X}_n\right) = \mathbb{V}\left(\frac{1}{n}\sum_{i=1}^{n}(X_i - \mathbb{E}X_i)\right) = \frac{1}{n^2}\mathbb{V}\left(\left(\sum_{i=1}^{n}X_i\right) - n\mathbb{E}X\right) = \frac{1}{n^2}\mathbb{V}\left(\sum_{i=1}^{n}X_i\right)$$

Weil die X_i unabhängig sind, lässt sich auch die Summe herausziehen:

Beweisskizze schwaches Gesetz der großen Zahlen 1/2.

(Mit $\mu := \mathbb{E}X = \mathbb{E}X_i$ unter der Annahme endlicher Varianz $\mathbb{V}X_i = \mathbb{V}X =: \sigma^2$)

$$\mathbb{V}\left(\overline{X}_n\right) = \mathbb{V}\left(\frac{1}{n}\sum_{i=1}^{n}\left(X_i - \mathbb{E}X_i\right)\right) = \frac{1}{n^2}\mathbb{V}\left(\left(\sum_{i=1}^{n} X_i\right) - n\mathbb{E}X\right) = \frac{1}{n^2}\mathbb{V}\left(\sum_{i=1}^{n} X_i\right)$$

Weil die X_i unabhängig sind, lässt sich auch die Summe herausziehen:

$$= \frac{1}{n^2}\sum_{i=1}^{n}\mathbb{V}\left(X_i\right)$$

Beweisskizze Große Zahlen

Beweisskizze schwaches Gesetz der großen Zahlen 1/2.

(Mit $\mu := \mathbb{E}X = \mathbb{E}X_i$ unter der Annahme endlicher Varianz $\mathbb{V}X_i = \mathbb{V}X =: \sigma^2$)

$$\mathbb{V}\left(\overline{X}_n\right) = \mathbb{V}\left(\frac{1}{n}\sum_{i=1}^{n}\left(X_i - \mathbb{E}X_i\right)\right) = \frac{1}{n^2}\mathbb{V}\left(\left(\sum_{i=1}^{n} X_i\right) - n\mathbb{E}X\right) = \frac{1}{n^2}\mathbb{V}\left(\sum_{i=1}^{n} X_i\right)$$

Weil die X_i unabhängig sind, lässt sich auch die Summe herausziehen:

$$= \frac{1}{n^2}\sum_{i=1}^{n}\mathbb{V}\left(X_i\right) = \frac{n}{n^2}\mathbb{V}X$$

Beweisskizze schwaches Gesetz der großen Zahlen 1/2.

(Mit $\mu := \mathbb{E}X = \mathbb{E}X_i$ unter der Annahme endlicher Varianz $\mathbb{V}X_i = \mathbb{V}X =: \sigma^2$)

$$\mathbb{V}\left(\overline{X}_n\right) = \mathbb{V}\left(\frac{1}{n}\sum_{i=1}^{n}(X_i - \mathbb{E}X_i)\right) = \frac{1}{n^2}\mathbb{V}\left(\left(\sum_{i=1}^{n}X_i\right) - n\mathbb{E}X\right) = \frac{1}{n^2}\mathbb{V}\left(\sum_{i=1}^{n}X_i\right)$$

Weil die X_i unabhängig sind, lässt sich auch die Summe herausziehen:

$$= \frac{1}{n^2}\sum_{i=1}^{n}\mathbb{V}(X_i) = \frac{n}{n^2}\mathbb{V}X = \frac{\sigma^2}{n}.$$

Beweisskizze Große Zahlen

Beweisskizze schwaches Gesetz der großen Zahlen 2/2.

(Mit $\mu := \mathbb{E}X = \mathbb{E}X_i$ unter der Annahme endlicher Varianz $\mathbb{V}X_i = \mathbb{V}X =: \sigma^2$)

$$\mathbb{V}\left(\overline{X}_n\right) = \frac{\sigma^2}{n},$$

Beweisskizze Große Zahlen

Beweisskizze schwaches Gesetz der großen Zahlen 2/2.

(Mit $\mu := \mathbb{E}X = \mathbb{E}X_i$ unter der Annahme endlicher Varianz $\mathbb{V}X_i = \mathbb{V}X =: \sigma^2$)

$$\mathbb{V}\left(\overline{X}_n\right) = \frac{\sigma^2}{n}, \qquad \mathbb{E}\overline{X}_n = \mathbb{E}\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right)$$

Beweisskizze Große Zahlen

Beweisskizze schwaches Gesetz der großen Zahlen 2/2.

(Mit $\mu := \mathbb{E}X = \mathbb{E}X_i$ unter der Annahme endlicher Varianz $\mathbb{V}X_i = \mathbb{V}X =: \sigma^2$)

$$\mathbb{V}\left(\overline{X}_n\right) = \frac{\sigma^2}{n}, \qquad \mathbb{E}\overline{X}_n = \mathbb{E}\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right) = \frac{1}{n}\sum_{i=1}^{n}\mathbb{E}X_i$$

Beweisskizze Große Zahlen

Beweisskizze schwaches Gesetz der großen Zahlen 2/2.

(Mit $\mu := \mathbb{E}X = \mathbb{E}X_i$ unter der Annahme endlicher Varianz $\mathbb{V}X_i = \mathbb{V}X =: \sigma^2$)

$$\mathbb{V}\left(\overline{X}_n\right) = \frac{\sigma^2}{n}, \qquad \mathbb{E}\overline{X}_n = \mathbb{E}\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right) = \frac{1}{n}\sum_{i=1}^{n}\mathbb{E}X_i = \frac{n}{n}\mu = \mu.$$

Beweisskizze Große Zahlen

Beweisskizze schwaches Gesetz der großen Zahlen 2/2.

(Mit $\mu := \mathbb{E}X = \mathbb{E}X_i$ unter der Annahme endlicher Varianz $\mathbb{V}X_i = \mathbb{V}X =: \sigma^2$)

$$\mathbb{V}\left(\overline{X}_n\right) = \frac{\sigma^2}{n}, \qquad \mathbb{E}\overline{X}_n = \mathbb{E}\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right) = \frac{1}{n}\sum_{i=1}^{n}\mathbb{E}X_i = \frac{n}{n}\mu = \mu.$$

Wir wenden die Tschebyscheff-Ungleichung auf $\overline{X}_n$ an:

$$P\left(\left|\overline{X}_n - \mu\right| \geq \varepsilon\right) \leq \frac{\sigma^2}{n\varepsilon^2} \xrightarrow{n\to\infty} 0.$$

Beweisskizze Große Zahlen

Beweisskizze schwaches Gesetz der großen Zahlen 2/2.

(Mit $\mu := \mathbb{E}X = \mathbb{E}X_i$ unter der Annahme endlicher Varianz $\mathbb{V}X_i = \mathbb{V}X =: \sigma^2$)

$$\mathbb{V}\left(\overline{X}_n\right) = \frac{\sigma^2}{n}, \qquad \mathbb{E}\overline{X}_n = \mathbb{E}\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right) = \frac{1}{n}\sum_{i=1}^{n}\mathbb{E}X_i = \frac{n}{n}\mu = \mu.$$

Wir wenden die Tschebyscheff-Ungleichung auf $\overline{X}_n$ an:

$$P\left(\left|\overline{X}_n - \mu\right| \geq \varepsilon\right) \leq \frac{\sigma^2}{n\varepsilon^2} \xrightarrow{n\to\infty} 0.$$

Das ist genau die stochastische Konvergenz. □



Heinrich Heine
Universität Düsseldorf

Vielen Dank für Ihre Aufmerksamkeit!