

Data Science, VL 8

Dr. Konrad Völkel, Sommersemester 2026

19.05.2026

Summen von Bernoulli-Variablen

- Betrachten wir eine Folge von Bernoulli-verteilten Zufallsvariablen X_i mit gleichem Parameter p.

Summen von Bernoulli-Variablen

- Betrachten wir eine Folge von Bernoulli-verteilten Zufallsvariablen X_i mit gleichem Parameter p.
- Die Summe $S_n := \sum_{i=1}^{n} X_i$ über die ersten n Variablen ist binomialverteilt: $S_n \sim \mathrm{Bin}(n, p)$.

Summen von Bernoulli-Variablen

- Betrachten wir eine Folge von Bernoulli-verteilten Zufallsvariablen X_i mit gleichem Parameter p.
- Die Summe $S_n := \sum_{i=1}^{n} X_i$ über die ersten n Variablen ist binomialverteilt: $S_n \sim \mathrm{Bin}(n, p)$.
- Die Wahrscheinlichkeitsfunktion (pmf) von S_n lautet bekanntlich:

$$p(k) = P(S_n = k) = \binom{n}{k} p^k (1-p)^{n-k}$$

Summen von Bernoulli-Variablen

- Betrachten wir eine Folge von Bernoulli-verteilten Zufallsvariablen X_i mit gleichem Parameter p.
- Die Summe $S_n := \sum_{i=1}^{n} X_i$ über die ersten n Variablen ist binomialverteilt: $S_n \sim \mathrm{Bin}(n, p)$.
- Die Wahrscheinlichkeitsfunktion (pmf) von S_n lautet bekanntlich:

$$p(k) = P(S_n = k) = \binom{n}{k} p^k (1-p)^{n-k}$$

- Für große n nähert sich die Form des Histogramms stets einer Glockenkurve an.

Summen von Bernoulli-Variablen

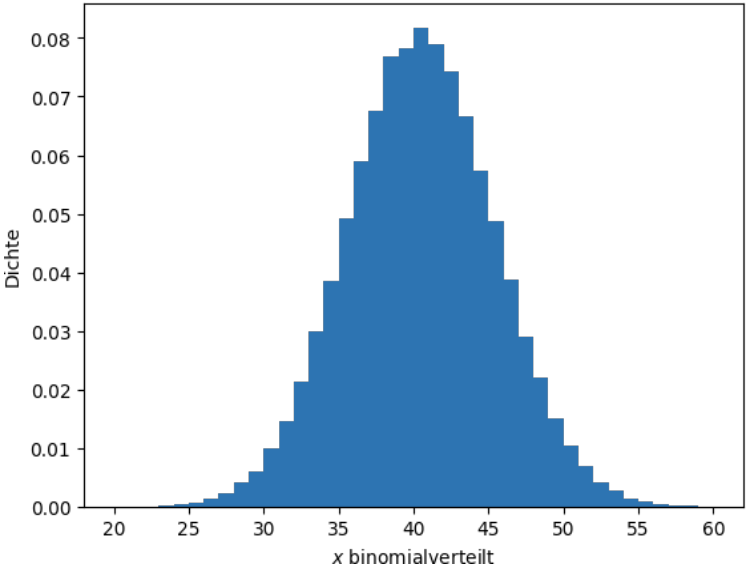
- Betrachten wir eine Folge von Bernoulli-verteilten Zufallsvariablen X_i mit gleichem Parameter p.
- Die Summe $S_n := \sum_{i=1}^{n} X_i$ über die ersten n Variablen ist binomialverteilt: $S_n \sim \mathrm{Bin}(n, p)$.
- Die Wahrscheinlichkeitsfunktion (pmf) von S_n lautet bekanntlich:

$$p(k) = P(S_n = k) = \binom{n}{k} p^k (1-p)^{n-k}$$

- Für große n nähert sich die Form des Histogramms stets einer Glockenkurve an.
- Da Binomialkoeffizienten für große n schwer exakt zu berechnen sind (Fakultäten wachsen extrem schnell), sucht man nach einer stetigen Approximation.

Plot eines binomialverteilten Samples

```python
import numpy as np
from scipy.stats import binom, norm
from matplotlib import pyplot as plt
np.random.seed(123123)
binom_samples = binom.rvs(n=100,
                          p=0.4,
                          size=100000)
plt.hist(binom_samples, bins=40, density=True)
plt.xlabel("x binomialverteilt")
plt.ylabel("Dichte")
plt.show()
```


0.08
0.07
0.06
0.05
0.04
0.03
0.02
0.01
0.00
Dichte
20
25
30
35
40
45
50
55
60
x binomialverteilt

Satz von de Moivre-Laplace

Heinrich Heine
Universität Düsseldorf

Stirling-Formel zur Approximation

$$n! \approx \sqrt{2\pi n}\left(\frac{n}{e}\right)^n$$

Satz von de Moivre-Laplace

Heinrich Heine Universität Düsseldorf

Stirling-Formel zur Approximation

$$n! \approx \sqrt{2\pi n}\left(\frac{n}{e}\right)^n$$

Damit lässt sich für die Binomialverteilung zeigen:

$$P(S_n = k) \sim \frac{1}{\sqrt{np(1-p)}} \frac{1}{\sqrt{2\pi}} e^{-\frac{x_n^2}{2}} \quad \text{für } n \to \infty$$

wobei $x_n = \frac{k-np}{\sqrt{np(1-p)}}$ eingesetzt wird.

Satz von de Moivre-Laplace

Heinrich Heine Universität Düsseldorf

Stirling-Formel zur Approximation

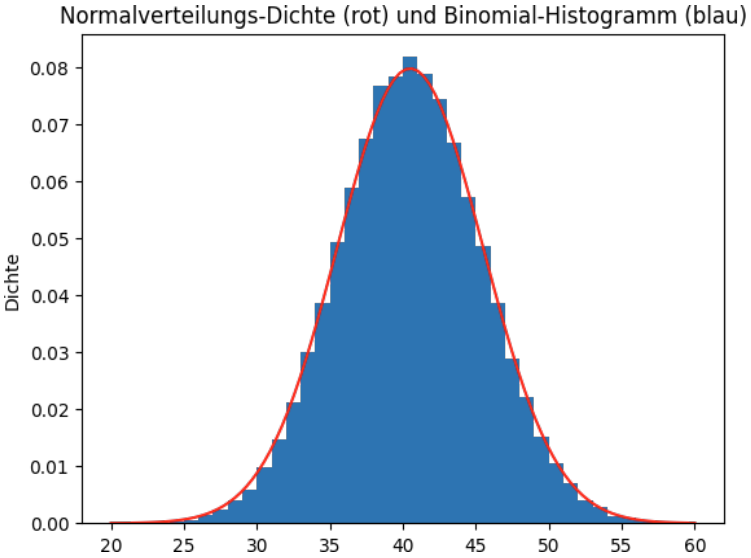
$$n! \approx \sqrt{2\pi n}\left(\frac{n}{e}\right)^n$$

Damit lässt sich für die Binomialverteilung zeigen:

$$P(S_n = k) \sim \frac{1}{\sqrt{np(1-p)}} \frac{1}{\sqrt{2\pi}} e^{-\frac{x_n^2}{2}} \qquad \text{für } n \to \infty$$

wobei $x_n = \frac{k-np}{\sqrt{np(1-p)}}$ eingesetzt wird.

Das Symbol $\sim$ bedeutet asymptotische Gleichheit (der Quotient konvergiert gegen 1). Die Funktion $e^{-x^2/2}$ spielt hier also die zentrale Rolle.


Normalverteilungs-Dichte (rot) und Binomial-Histogramm (blau)
Dichte
0.00
0.01
0.02
0.03
0.04
0.05
0.06
0.07
0.08
20
25
30
35
40
45
50
55
60

Das Gaußsche Integral

Um aus $e^{-x^2/2}$ eine Wahrscheinlichkeitsdichte zu machen, muss das Integral über $\mathbb{R}$ gleich 1 sein. Wir betrachten ein allgemeineres Integral:

Das Gaußsche Integral

Um aus $e^{-x^2/2}$ eine Wahrscheinlichkeitsdichte zu machen, muss das Integral über $\mathbb{R}$ gleich 1 sein. Wir betrachten ein allgemeineres Integral:

Lemma

Sei $v \in \mathbb{R}$ und $v > 0$. Dann gilt

$$\int_{-\infty}^{\infty} e^{-\frac{x^2}{2v}} dx = \sqrt{2\pi v}.$$

Beweis des Gaußschen Integrals (1/2)

Heinrich Heine
Universität Düsseldorf

Proof.

Wir quadrieren das Integral und transformieren es in Polarkoordinaten:

$$\left(\int_{-\infty}^{\infty} \mathrm{e}^{-\frac{x^2}{2v}}\,\mathrm{dx}\right)^2 = \int_{-\infty}^{\infty} \mathrm{e}^{-\frac{x^2}{2v}}\,\mathrm{dx} \int_{-\infty}^{\infty} \mathrm{e}^{-\frac{y^2}{2v}}\,\mathrm{dy}$$

Beweis des Gaußschen Integrals (1/2)

Heinrich Heine Universität Düsseldorf

Proof.

Wir quadrieren das Integral und transformieren es in Polarkoordinaten:

$$\left(\int_{-\infty}^{\infty} \mathrm{e}^{-\frac{\mathrm{x}^2}{2\mathrm{v}}}\,\mathrm{dx}\right)^2 = \int_{-\infty}^{\infty} \mathrm{e}^{-\frac{\mathrm{x}^2}{2\mathrm{v}}}\,\mathrm{dx} \int_{-\infty}^{\infty} \mathrm{e}^{-\frac{\mathrm{y}^2}{2\mathrm{v}}}\,\mathrm{dy}$$
$$= \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} \mathrm{e}^{-\frac{\mathrm{x}^2+\mathrm{y}^2}{2\mathrm{v}}}\,\mathrm{dxdy} = \int_{\mathbb{R}^2} \mathrm{e}^{-\frac{\mathrm{x}^2+\mathrm{y}^2}{2\mathrm{v}}}\,\mathrm{d(x,y)}$$

Beweis des Gaußschen Integrals (1/2)

Heinrich Heine Universität Düsseldorf

Proof.

Wir quadrieren das Integral und transformieren es in Polarkoordinaten:

$$\begin{aligned}\left(\int_{-\infty}^{\infty} \mathrm{e}^{-\frac{\mathrm{x}^2}{2\mathrm{v}}}\,\mathrm{dx}\right)^2 &= \int_{-\infty}^{\infty} \mathrm{e}^{-\frac{\mathrm{x}^2}{2\mathrm{v}}}\,\mathrm{dx} \int_{-\infty}^{\infty} \mathrm{e}^{-\frac{\mathrm{y}^2}{2\mathrm{v}}}\,\mathrm{dy} \\ &= \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} \mathrm{e}^{-\frac{\mathrm{x}^2+\mathrm{y}^2}{2\mathrm{v}}}\,\mathrm{dxdy} = \int_{\mathbb{R}^2} \mathrm{e}^{-\frac{\mathrm{x}^2+\mathrm{y}^2}{2\mathrm{v}}}\,\mathrm{d(x,y)} \\ &= \int_0^{\infty}\int_0^{2\pi} \mathrm{r}\mathrm{e}^{-\frac{\mathrm{r}^2}{2\mathrm{v}}}\,\mathrm{d}\phi\mathrm{dr} = \int_0^{\infty} \mathrm{r}\mathrm{e}^{-\frac{\mathrm{r}^2}{2\mathrm{v}}}[\phi]_0^{2\pi}\,\mathrm{dr}\end{aligned}$$

Beweis des Gaußschen Integrals (1/2)

Heinrich Heine Universität Düsseldorf

Proof.

Wir quadrieren das Integral und transformieren es in Polarkoordinaten:

$$\begin{aligned}\left(\int_{-\infty}^{\infty} \mathrm{e}^{-\frac{\mathrm{x}^2}{2\mathrm{v}}}\,\mathrm{dx}\right)^2 &= \int_{-\infty}^{\infty} \mathrm{e}^{-\frac{\mathrm{x}^2}{2\mathrm{v}}}\,\mathrm{dx} \int_{-\infty}^{\infty} \mathrm{e}^{-\frac{\mathrm{y}^2}{2\mathrm{v}}}\,\mathrm{dy} \\ &= \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} \mathrm{e}^{-\frac{\mathrm{x}^2+\mathrm{y}^2}{2\mathrm{v}}}\,\mathrm{dxdy} = \int_{\mathbb{R}^2} \mathrm{e}^{-\frac{\mathrm{x}^2+\mathrm{y}^2}{2\mathrm{v}}}\,\mathrm{d(x,y)} \\ &= \int_0^{\infty}\int_0^{2\pi} \mathrm{r}\mathrm{e}^{-\frac{\mathrm{r}^2}{2\mathrm{v}}}\,\mathrm{d}\phi\mathrm{dr} = \int_0^{\infty} \mathrm{r}\mathrm{e}^{-\frac{\mathrm{r}^2}{2\mathrm{v}}}[\phi]_0^{2\pi}\,\mathrm{dr} \\ &= 2\pi\int_0^{\infty} \mathrm{r}\mathrm{e}^{-\frac{\mathrm{r}^2}{2\mathrm{v}}}\,\mathrm{dr}\end{aligned}$$

Beweis des Gaußschen Integrals (2/2)

Heinrich Heine
Universität Düsseldorf

Proof.

Wir quadrieren das Integral und transformieren es in Polarkoordinaten:

$$= 2\pi \int_0^{\infty} \mathrm{r} \mathrm{e}^{-\frac{\mathrm{r}^2}{2\mathrm{v}}} \mathrm{dr}$$

$$= 2\pi \mathrm{v} \int_{-\infty}^{0} \mathrm{e}^{\mathrm{u}} \mathrm{du} \quad (\text{Substitution } \mathrm{u} = -\mathrm{r}^2/(2\mathrm{v}))$$

Beweis des Gaußschen Integrals (2/2)

Heinrich Heine Universität Düsseldorf

Proof.

Wir quadrieren das Integral und transformieren es in Polarkoordinaten:

$$
\begin{aligned}
&= 2\pi \int_0^{\infty} \mathrm{r} \mathrm{e}^{-\frac{\mathrm{r}^2}{2\mathrm{v}}} \mathrm{dr} \\
&= 2\pi\mathrm{v} \int_{-\infty}^{0} \mathrm{e}^{\mathrm{u}} \mathrm{du} \quad (\text{Substitution } \mathrm{u} = -\mathrm{r}^2/(2\mathrm{v})) \\
&= 2\pi\mathrm{v}[\mathrm{e}^{\mathrm{u}}]_{-\infty}^{0} = 2\pi\mathrm{v}.
\end{aligned}
$$

Beweis des Gaußschen Integrals (2/2)

Heinrich Heine Universität Düsseldorf

Proof.

Wir quadrieren das Integral und transformieren es in Polarkoordinaten:

$$
\begin{aligned}
&= 2\pi \int_0^{\infty} \mathrm{r} \mathrm{e}^{-\frac{\mathrm{r}^2}{2\mathrm{v}}} \mathrm{dr} \\
&= 2\pi\mathrm{v} \int_{-\infty}^{0} \mathrm{e}^{\mathrm{u}} \mathrm{du} \quad (\text{Substitution } \mathrm{u} = -\mathrm{r}^2/(2\mathrm{v})) \\
&= 2\pi\mathrm{v}[\mathrm{e}^{\mathrm{u}}]_{-\infty}^{0} = 2\pi\mathrm{v}.
\end{aligned}
$$

Wurzelziehen liefert die Behauptung. □

Die eindimensionale Normalverteilung

Heinrich Heine Universität Düsseldorf

Definition

Seien $\mu, \sigma \in \mathbb{R}$ mit $\sigma > 0$. Dann heißt die Verteilung mit der Dichtefunktion

$$\phi(\mathrm{x}) = \frac{1}{\sigma\sqrt{2\pi}} \mathrm{e}^{-\frac{(\mathrm{x}-\mu)^2}{2\sigma^2}}$$

Normalverteilung.
Für eine reelle Zufallsvariable X mit dieser Verteilung schreiben wir $\mathrm{X} \sim \mathcal{N}(\mu, \sigma^2)$.

Die eindimensionale Normalverteilung

Heinrich Heine Universität Düsseldorf

Definition

Seien $\mu, \sigma \in \mathbb{R}$ mit $\sigma > 0$. Dann heißt die Verteilung mit der Dichtefunktion

$$\phi(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Normalverteilung.
Für eine reelle Zufallsvariable X mit dieser Verteilung schreiben wir $X \sim \mathcal{N}(\mu, \sigma^2)$.

Definition

Eine Zufallsvariable mit $X \sim \mathcal{N}(0, 1)$ heißt standardnormalverteilt.

Erwartungswert und Varianz

Heinrich Heine
Universität Düsseldorf

Proposition

Wenn $\mathrm{X} \sim \mathcal{N}(\mu, \sigma^2)$, so ist $\mathbb{E}(\mathrm{X}) = \mu$ und $\mathbb{V}(\mathrm{X}) = \sigma^2$.

Erwartungswert und Varianz

Heinrich Heine Universität Düsseldorf

Beweis-Skizze für den Erwartungswert.

$$\mathbb{E}(X) = \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} x e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx$$

□

Erwartungswert und Varianz

Heinrich Heine Universität Düsseldorf

Beweis-Skizze für den Erwartungswert.

$$\begin{aligned}\mathbb{E}(X) &= \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} x e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx \\ &= \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} (x+\mu) e^{-\frac{x^2}{2\sigma^2}} dx \quad \text{(Substitution } x \mapsto x+\mu\text{)}\end{aligned}$$

□

Erwartungswert und Varianz

Heinrich Heine Universität Düsseldorf

Beweis-Skizze für den Erwartungswert.

$$
\begin{aligned}
\mathbb{E}(X) &= \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} x e^{-\frac{(x-\mu)^2}{2\sigma^2}} \, dx \\
&= \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} (x+\mu) e^{-\frac{x^2}{2\sigma^2}} \, dx \quad \text{(Substitution } x \mapsto x+\mu\text{)} \\
&= \underbrace{\frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} x e^{-\frac{x^2}{2\sigma^2}} \, dx}_{=0 \text{ (aus Symmetrie)}} + \mu \underbrace{\frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{x^2}{2\sigma^2}} \, dx}_{=1 \text{ (Dichte)}}
\end{aligned}
$$

□

Erwartungswert und Varianz

Heinrich Heine Universität Düsseldorf

Beweis-Skizze für den Erwartungswert.

$$
\begin{aligned}
\mathbb{E}(X) &= \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} x e^{-\frac{(x-\mu)^2}{2\sigma^2}} \, dx \\
&= \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} (x+\mu) e^{-\frac{x^2}{2\sigma^2}} \, dx \quad \text{(Substitution } x \mapsto x+\mu\text{)} \\
&= \underbrace{\frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} x e^{-\frac{x^2}{2\sigma^2}} \, dx}_{=0 \text{ (aus Symmetrie)}} + \mu \underbrace{\frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{x^2}{2\sigma^2}} \, dx}_{=1 \text{ (Dichte)}} \\
&= \mu.
\end{aligned}
$$

□

Eigenschaften der Normalverteilung

Proposition

Wenn $X \sim \mathcal{N}(\mu, \sigma^2)$, so ist $\frac{X-\mu}{\sigma} \sim \mathcal{N}(0,1)$.

Eigenschaften der Normalverteilung

Heinrich Heine
Universität Düsseldorf

Proposition

Wenn $X \sim \mathcal{N}(\mu, \sigma^2)$, so ist $\frac{X-\mu}{\sigma} \sim \mathcal{N}(0,1)$.

Es ist offensichtlich, dass $\mathbb{E}\left(\frac{X-\mu}{\sigma}\right) = 0$ und $\mathbb{V}\left(\frac{X-\mu}{\sigma}\right) = 1$.
Die Normalverteiltheit bleibt unter linearen Transformationen erhalten.

Eigenschaften der Normalverteilung

Heinrich Heine Universität Düsseldorf

Proposition

Wenn $\mathrm{X} \sim \mathcal{N}(\mu, \sigma^2)$, so ist $\frac{\mathrm{X}-\mu}{\sigma} \sim \mathcal{N}(0,1)$.

Es ist offensichtlich, dass $\mathbb{E}\left(\frac{\mathrm{X}-\mu}{\sigma}\right) = 0$ und $\mathbb{V}\left(\frac{\mathrm{X}-\mu}{\sigma}\right) = 1$.
Die Normalverteiltheit bleibt unter linearen Transformationen erhalten.

Proposition

Wenn $\mathrm{X} \sim \mathcal{N}(\mu_1, \sigma_1^2)$ und $\mathrm{Y} \sim \mathcal{N}(\mu_2, \sigma_2^2)$ unabhängig sind, so ist

$$\mathrm{X} + \mathrm{Y} \sim \mathcal{N}(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2).$$

Maximale Entropie

Heinrich Heine
Universität Düsseldorf

Theorem

Unter allen stetigen Verteilungen reeller Zufallsvariablen mit Träger ganz $\mathbb{R}$ und festem Erwartungswert μ und Varianz σ^2 ist die Normalverteilung diejenige mit der maximalen Entropie.

Maximale Entropie

Heinrich Heine
Universität Düsseldorf

Theorem

Unter allen stetigen Verteilungen reeller Zufallsvariablen mit Träger ganz $\mathbb{R}$ und festem Erwartungswert μ und Varianz σ^2 ist die Normalverteilung diejenige mit der maximalen Entropie.

Take-Home-Message: Wenn über eine Verteilung (außer Träger, Erwartungswert und Varianz) nichts bekannt ist, dann ist die Normalverteilung die unvoreingenommenste und vernünftigste Annahme.

Ausblick: Maximale Entropie bei anderem Träger

Heinrich Heine Universität Düsseldorf

Je nach Träger (support) und den bekannten Parametern ergeben sich andere Verteilungen als unvoreingenommenste Annahme (Maximale Entropie):

- Träger $[a, b]$ (endliches Intervall), keine weiteren Parameter bekannt:
  $\Rightarrow$ Stetige Gleichverteilung $\frac{1}{b-a}$

Ausblick: Maximale Entropie bei anderem Träger

Heinrich Heine Universität Düsseldorf

Je nach Träger (support) und den bekannten Parametern ergeben sich andere Verteilungen als unvoreingenommenste Annahme (Maximale Entropie):

- Träger $[a, b]$ (endliches Intervall), keine weiteren Parameter bekannt:
  $\Rightarrow$ Stetige Gleichverteilung $\frac{1}{b-a}$
- Diskreter Träger $\{1, \ldots, n\}$, keine weiteren Parameter bekannt:
  $\Rightarrow$ Diskrete Gleichverteilung $\frac{1}{n}$

Ausblick: Maximale Entropie bei anderem Träger

Heinrich Heine Universität Düsseldorf

Je nach Träger (support) und den bekannten Parametern ergeben sich andere Verteilungen als unvoreingenommenste Annahme (Maximale Entropie):

- Träger $[a, b]$ (endliches Intervall), keine weiteren Parameter bekannt:
  $\Rightarrow$ Stetige Gleichverteilung $\frac{1}{b-a}$
- Diskreter Träger $\{1, \ldots, n\}$, keine weiteren Parameter bekannt:
  $\Rightarrow$ Diskrete Gleichverteilung $\frac{1}{n}$
- Träger $[0, \infty)$ (nur positive Werte), fester Erwartungswert μ bekannt:
  $\Rightarrow$ Exponentialverteilung $\lambda e^{-\lambda x}$ für $x \geq 0$, wobei $\lambda = \frac{1}{\mu}$.

Ausblick: Maximale Entropie bei anderem Träger

Heinrich Heine Universität Düsseldorf

Je nach Träger (support) und den bekannten Parametern ergeben sich andere Verteilungen als unvoreingenommenste Annahme (Maximale Entropie):

- Träger $[a, b]$ (endliches Intervall), keine weiteren Parameter bekannt:
  $\Rightarrow$ Stetige Gleichverteilung $\frac{1}{b-a}$
- Diskreter Träger $\{1, \ldots, n\}$, keine weiteren Parameter bekannt:
  $\Rightarrow$ Diskrete Gleichverteilung $\frac{1}{n}$
- Träger $[0, \infty)$ (nur positive Werte), fester Erwartungswert μ bekannt:
  $\Rightarrow$ Exponentialverteilung $\lambda e^{-\lambda x}$ für $x \geq 0$, wobei $\lambda = \frac{1}{\mu}$.
- Träger $[a, b]$ (endliches Intervall), feste Varianz σ^2 bekannt:
  $\Rightarrow$ Gestutzte Normalverteilung

Der zentrale Grenzwertsatz (CLT)

Heinrich Heine
Universität Düsseldorf

Theorem (Zentraler Grenzwertsatz)

Wenn $(X_i)_{i\in\mathbb{N}}$ eine Folge von unabhängig und identisch verteilten (iid) Zufallsvariablen mit $\mathbb{E}(X_i) = 0$ und $\mathbb{V}(X_i) = \sigma^2$ ist, dann gilt für die reskalierte Summe $S_N := \frac{1}{\sigma\sqrt{N}} \sum_{i=1}^{N} X_i$ die Konvergenz in Verteilung:

$$S_N \xrightarrow{N\to\infty} \mathcal{N}(0,1)$$

Der zentrale Grenzwertsatz (CLT)

Heinrich Heine Universität Düsseldorf

Theorem (Zentraler Grenzwertsatz)

Wenn $(X_i)_{i\in\mathbb{N}}$ eine Folge von unabhängig und identisch verteilten (iid) Zufallsvariablen mit $\mathbb{E}(X_i) = 0$ und $\mathbb{V}(X_i) = \sigma^2$ ist, dann gilt für die reskalierte Summe $S_N := \frac{1}{\sigma\sqrt{N}} \sum_{i=1}^{N} X_i$ die Konvergenz in Verteilung:

$$S_N \xrightarrow{N\to\infty} \mathcal{N}(0,1)$$

- Bedeutung in der Praxis: Die Summe vieler kleiner, unabhängiger Fehlereinflüsse ist am Ende oft annähernd normalverteilt.
- Beispiele: Messfehler bei GPS-Systemen, Abweichungen in der industriellen Fertigung.

Konvergenzgeschwindigkeit (Berry-Esseen)

Wie schnell konvergiert die Verteilung gegen die Normalverteilung?

Konvergenzgeschwindigkeit (Berry-Esseen)

Heinrich Heine Universität Düsseldorf

Wie schnell konvergiert die Verteilung gegen die Normalverteilung?

Theorem

Es existiert eine Konstante $C > 0,4409$ mit der Eigenschaft: Wenn X_i iid sind mit $\mathbb{E}(X_i) = 0$, $\mathbb{V}(X_i) = \sigma^2$ und $\mathbb{E}|X_i^3| = \rho < \infty$, so gilt für die kumulative Verteilungsfunktion F_N von $\frac{1}{\sigma\sqrt{N}} \sum_{i=1}^{N} X_i$ und die cdf Φ von $\mathcal{N}(0,1)$:

$$\sup_{x \in \mathbb{R}} |F_N(x) - \Phi(x)| \leq \frac{C\rho}{\sigma^3\sqrt{N}}.$$

Konvergenzgeschwindigkeit (Berry-Esseen)

Heinrich Heine Universität Düsseldorf

Wie schnell konvergiert die Verteilung gegen die Normalverteilung?

Theorem

Es existiert eine Konstante $C > 0,4409$ mit der Eigenschaft: Wenn X_i iid sind mit $\mathbb{E}(X_i) = 0$, $\mathbb{V}(X_i) = \sigma^2$ und $\mathbb{E}|X_i^3| = \rho < \infty$, so gilt für die kumulative Verteilungsfunktion F_N von $\frac{1}{\sigma\sqrt{N}} \sum_{i=1}^{N} X_i$ und die cdf Φ von $\mathcal{N}(0,1)$:

$$\sup_{x \in \mathbb{R}} |F_N(x) - \Phi(x)| \leq \frac{C\rho}{\sigma^3\sqrt{N}}.$$

Damit lässt sich für bekannte Parameter abschätzen, wie groß N sein muss, um eine gewünschte Genauigkeit für die Normalapproximation zu erzielen.

Praxisbeispiel: Der „N $\geq$ 30“-Mythos

Mythos: „Bei Stichproben ab N = 30 darf man eine Normalverteilung annehmen.“

Praxisbeispiel: Der „$N \geq 30$“-Mythos

Mythos: „Bei Stichproben ab $N = 30$ darf man eine Normalverteilung annehmen.“

Warum das (gerade bei medizinischen Studien mit binären Daten) falsch ist:

- Bei binären Merkmalen (z. B. Nebenwirkung ja/nein) liegt eine Bernoulli-Verteilung vor.

Praxisbeispiel: Der „$N \geq 30$“-Mythos

Mythos: „Bei Stichproben ab $N = 30$ darf man eine Normalverteilung annehmen.“

Warum das (gerade bei medizinischen Studien mit binären Daten) falsch ist:

- Bei binären Merkmalen (z. B. Nebenwirkung ja/nein) liegt eine Bernoulli-Verteilung vor.
- Wenn das Ereignis selten ist (z. B. $p = 0.01$), ist diese Verteilung extrem schief.

Praxisbeispiel: Der „$N \geq 30$“-Mythos

Mythos: „Bei Stichproben ab $N = 30$ darf man eine Normalverteilung annehmen.“

Warum das (gerade bei medizinischen Studien mit binären Daten) falsch ist:

- Bei binären Merkmalen (z. B. Nebenwirkung ja/nein) liegt eine Bernoulli-Verteilung vor.
- Wenn das Ereignis selten ist (z. B. $p = 0.01$), ist diese Verteilung extrem schief.
- Berry-Esseen zeigt: Der Approximationsfehler hängt maßgeblich vom dritten Moment (der Schiefe) ab! Ist $\mathbb{E}|X_i^3|$ im Verhältnis zu σ^3 groß, reicht $n = 30$ bei Weitem nicht aus, um den Fehler klein zu halten.

Praxisbeispiel: Faustregel

Heinrich Heine
Universität Düsseldorf

Die korrekte Faustregel für binäre Daten

Eine Normalapproximation ist erst gerechtfertigt, wenn die erwartete absolute Häufigkeit für beide Ausprägungen groß genug ist (Laplace-Bedingung):

$$N \cdot p \geq 10 \quad \text{und} \quad N \cdot (1 - p) \geq 10$$

Bei einer seltenen Krankheit mit $p = 0.01$ braucht man also mindestens $N = 1000$ Probanden!



Heinrich Heine
Universität Düsseldorf

Vielen Dank für Ihre Aufmerksamkeit!