

Data Science, VL 9

Dr. Konrad Völkel, Sommersemester 2026

21.05.2026



Vokabelstunde (Skalenniveaus)

Statistik - maschinelles Lernen

Zwei 'Kulturen': Statistik als Teilgebiet der Mathematik, maschinelles Lernen als Teilgebiet der künstlichen Intelligenz.

Statistik - maschinelles Lernen

Zwei 'Kulturen': Statistik als Teilgebiet der Mathematik, maschinelles Lernen als Teilgebiet der künstlichen Intelligenz.

Statistik	maschinelles Lernen
Parameter	Gewichte
Fitten	Lernen
Testdatensatz-Performance	Generalisierung
Regression, Klassifikation	Supervised Learning
Dichteschätzung, Klassenbildung (clustering)	Unsupervised Learning

Tabelle: Begriffe aus den verschiedenen Kulturen

Explorative Datenanalyse vs Data Mining

Heinrich Heine
Universität Düsseldorf

Die explorative Datenanalyse ist das Berechnen summarischer Statistik und Visualsierung (also deskriptiver Statistik), um eine bessere Einschätzung über die Informationen in einem Datensatz zu erlangen. Sie ist ein menschengesteuerter iterativer Prozess und erfordert domänenspezifisches Wissen.

Explorative Datenanalyse vs Data Mining

Heinrich Heine Universität Düsseldorf

Die explorative Datenanalyse ist das Berechnen summarischer Statistik und Visualsierung (also deskriptiver Statistik), um eine bessere Einschätzung über die Informationen in einem Datensatz zu erlangen. Sie ist ein menschengesteuerter iterativer Prozess und erfordert domänenspezifisches Wissen.

Beim Data Mining geht es darum, diesen Arbeitsschritt in einem Data Science Projekt zu automatisieren, also die automatische Entdeckung von Mustern und Zusammenhängen, oft in einem vorher festgelegten Schema.

Deskriptive vs inferentielle Statistik

Die beschreibende (deskriptive) Statistik besteht aus den Datenanalysen, die vor der schließenden (inferentiellen) Statistik gemacht werden. Das besteht vor Allem in der Beschreibung der Daten durch verschiedene Maßzahlen.

Deskriptive vs inferentielle Statistik

Die beschreibende (deskriptive) Statistik besteht aus den Datenanalysen, die vor der schließenden (inferentiellen) Statistik gemacht werden. Das besteht vor Allem in der Beschreibung der Daten durch verschiedene Maßzahlen.

Die inferentielle Statistik umfasst das Schätzen von unbekannten Größen und die Testtheorie. Verfahren des maschinellen Lernens wie Clustering und Regression lassen sich als Schätzungen interpretieren und sind ebenso inferentielle Statistik.

Recap: Stichprobe

Daten sind uns als Vektor, Matrix (Tabelle) von Zahlen oder Strings oder anderen Datentypen gegeben. Die Länge der Daten, also Anzahl Einträge des Vektors bzw. Anzahl Zeilen der Tabelle, also Achse 0 in Numpy, heißt auch Umfang der Stichprobe (= des Samples). Die Einträge/Zeilen heißen Ergebnisse oder auch Instanzen.

Recap: Stichprobe

Heinrich Heine
Universität Düsseldorf

Daten sind uns als Vektor, Matrix (Tabelle) von Zahlen oder Strings oder anderen Datentypen gegeben. Die Länge der Daten, also Anzahl Einträge des Vektors bzw. Anzahl Zeilen der Tabelle, also Achse 0 in Numpy, heißt auch Umfang der Stichprobe (= des Samples). Die Einträge/Zeilen heißen Ergebnisse oder auch Instanzen.

Abzugrenzen von der Stichprobe ist die Population, die Grundgesamtheit aller möglichen Ergebnisse (Ausprägungen, outcomes) mit einer spezifischen Verteilung (die i.A. unbekannt ist).

Recap: Stichprobe

Heinrich Heine
Universität Düsseldorf

Daten sind uns als Vektor, Matrix (Tabelle) von Zahlen oder Strings oder anderen Datentypen gegeben. Die Länge der Daten, also Anzahl Einträge des Vektors bzw. Anzahl Zeilen der Tabelle, also Achse 0 in Numpy, heißt auch Umfang der Stichprobe (= des Samples). Die Einträge/Zeilen heißen Ergebnisse oder auch Instanzen.

Abzugrenzen von der Stichprobe ist die Population, die Grundgesamtheit aller möglichen Ergebnisse (Ausprägungen, outcomes) mit einer spezifischen Verteilung (die i.A. unbekannt ist).

Die Spalten der Tabelle sind Stichproben von einzelnen Variablen, auch Attribute, Merkmale, Features genannt.

Skalen

Heinrich Heine
Universität Düsseldorf

Je nach Art eines Merkmals und möglicher Ausprägungen unterscheiden wir Skalenniveaus:

- Nominalskala: kategorial, diskret (keine feste Reihenfolge)

Beispiele: Geschlecht, Postleitzahl, Religionszugehörigkeit
Achtung: Mittelwert und Median ergeben keinen Sinn, aber Häufigkeit!

Skalen

Je nach Art eines Merkmals und möglicher Ausprägungen unterscheiden wir Skalenniveaus:

- Nominalskala: kategorial, diskret (keine feste Reihenfolge)
- Ordinalskala: Werte können geordnet ($<$) werden (aber ohne Abstandsmaß)

Beispiele: Rangplätze im Sport, Dienstrang, Mohs-Härte der Mineralogie
Achtung: Mittelwerte ergeben keinen Sinn!

Skalen

Je nach Art eines Merkmals und möglicher Ausprägungen unterscheiden wir Skalenniveaus:

- Nominalskala: kategorial, diskret (keine feste Reihenfolge)
- Ordinalskala: Werte können geordnet ($<$) werden (aber ohne Abstandsmaß)
- Intervallskala (Kardinalskala): Werte können geordnet werden, es gibt ein Abstandsmaß und einen festgelegten Nullpunkt

Beispiele: Temperatur in Celsius, Datum, Likert-Skalen, Pegelstand des Rheins

Skalen

Je nach Art eines Merkmals und möglicher Ausprägungen unterscheiden wir Skalenniveaus:

- Nominalskala: kategorial, diskret (keine feste Reihenfolge)
- Ordinalskala: Werte können geordnet ($<$) werden (aber ohne Abstandsmaß)
- Intervallskala (Kardinalskala): Werte können geordnet werden, es gibt ein Abstandsmaß und einen festgelegten Nullpunkt
- Verhältnisskala: Kardinalskala mit absolutem Nullpunkt und einem Verhältnisbegriff:
  zu drei Werten a, b, c ist es sinnvoll, $a : b$ mit $a : c$ zu vergleichen.

Beispiele: Temperatur in Kelvin, Geschwindigkeit in km/h, Anzahl Personen eines Haushalts

Maßzahlen zentraler Tendenz

Heinrich Heine
Universität Düsseldorf

Je nach Skalenniveau sind verschiedene Maßzahlen verfügbar:

- Nominalskala: der Modus := häufigste Ausprägung

Beispiel: häufigste Religionszugehörigkeit

Maßzahlen zentraler Tendenz

Heinrich Heine Universität Düsseldorf

Je nach Skalenniveau sind verschiedene Maßzahlen verfügbar:

- Nominalskala: der Modus := häufigste Ausprägung
- Ordinalskala: der Median := Ausprägung, die die Stichprobe halbiert

Beispiel: Mohs-Härte der Mineralogie: die Hälfte aller Minerale sind weichergleich als der Median, die andere Hälfte ist härtergleich dem Median.

Maßzahlen zentraler Tendenz

Heinrich Heine Universität Düsseldorf

Je nach Skalenniveau sind verschiedene Maßzahlen verfügbar:

- Nominalskala: der Modus := häufigste Ausprägung
- Ordinalskala: der Median := Ausprägung, die die Stichprobe halbiert
- Intervallskala (Kardinalskala): der Mittelwert := arithmetisches Mittel `mean`

Beispiele: mittlere Temperatur in Celsius, mittlerer Pegelstand des Rheins.

Maßzahlen zentraler Tendenz

Heinrich Heine Universität Düsseldorf

Je nach Skalenniveau sind verschiedene Maßzahlen verfügbar:

- Nominalskala: der Modus := häufigste Ausprägung
- Ordinalskala: der Median := Ausprägung, die die Stichprobe halbiert
- Intervallskala (Kardinalskala): der Mittelwert := arithmetisches Mittel `mean`
- Intervallskala (Kardinalskala): die Bereichsmitte (midrange) := arithmetisches Mittel aus größtem und kleinsten Wert

Beispiele: arithmetisches Mittel aus Tageshöchst- und Tiefsttemperatur.

Maßzahlen zentraler Tendenz

Heinrich Heine Universität Düsseldorf

Je nach Skalenniveau sind verschiedene Maßzahlen verfügbar:

- Nominalskala: der Modus := häufigste Ausprägung
- Ordinalskala: der Median := Ausprägung, die die Stichprobe halbiert
- Intervallskala (Kardinalskala): der Mittelwert := arithmetisches Mittel `mean`
- Intervallskala (Kardinalskala): die Bereichsmitte (midrange) := arithmetisches Mittel aus größtem und kleinsten Wert
- Verhältnisskala: das geometrische Mittel (seltener nützlich)

Beispiele: das geometrische Mittel von zwei Temperaturen in Kelvin ist wieder eine Temperatur in Kelvin in der Mitte (anders bei negativen Temperaturen in Celsius!)

Dispersion precedes location

Viele Maße zentraler Tendenz minimieren ein entsprechendes Abweichungsmaß für das Skalenniveau, welches sich aus der Fehlermessung mit einer bestimmten Norm ergibt.

- Nominalskala: der Modus minimiert das Variationsverhältnis := Anteil der Stichprobe, die nicht der Modus ist (L_0-'Norm')

Dispersion precedes location

Viele Maße zentraler Tendenz minimieren ein entsprechendes Abweichungsmaß für das Skalenniveau, welches sich aus der Fehlermessung mit einer bestimmten Norm ergibt.

- Nominalskala: der Modus minimiert das Variationsverhältnis := Anteil der Stichprobe, die nicht der Modus ist (L_0-'Norm')
- Ordinalskala: der Median minimiert die mittlere absolute Abweichung (L_1-Norm)

Dispersion precedes location

Viele Maße zentraler Tendenz minimieren ein entsprechendes Abweichungsmaß für das Skalenniveau, welches sich aus der Fehlermessung mit einer bestimmten Norm ergibt.

- Nominalskala: der Modus minimiert das Variationsverhältnis := Anteil der Stichprobe, die nicht der Modus ist (L_0-'Norm')
- Ordinalskala: der Median minimiert die mittlere absolute Abweichung (L_1-Norm)
- Intervallskala: der Mittelwert minimiert die mittlere quadratische Abweichung (L_2-Norm)

Dispersion precedes location

Viele Maße zentraler Tendenz minimieren ein entsprechendes Abweichungsmaß für das Skalenniveau, welches sich aus der Fehlermessung mit einer bestimmten Norm ergibt.

- Nominalskala: der Modus minimiert das Variationsverhältnis := Anteil der Stichprobe, die nicht der Modus ist (L_0-'Norm')
- Ordinalskala: der Median minimiert die mittlere absolute Abweichung (L_1-Norm)
- Intervallskala: der Mittelwert minimiert die mittlere quadratische Abweichung (L_2-Norm)
- Intervallskala: die Bereichsmitte minimiert die maximale absolute Abweichung (L_∞-Norm)

Streuungsmaße

Die Abweichung der Daten von einem Maß zentraler Tendenz, gemessen mit einem Abweichungsmaß für das Skalenniveau, ergibt ein Streuungsmaß.
Je nach Skalenniveau sind verschiedene Streuungsmaße verfügbar:

- Nominalskala: Variationsverhältnis = Anteil nicht-Modus-Werte.

Streuungsmaße

Die Abweichung der Daten von einem Maß zentraler Tendenz, gemessen mit einem Abweichungsmaß für das Skalenniveau, ergibt ein Streuungsmaß.
Je nach Skalenniveau sind verschiedene Streuungsmaße verfügbar:

- Nominalskala: Variationsverhältnis = Anteil nicht-Modus-Werte.
- Intervallskala: Spannweite := Abstand zwischen max. und min. Wert.

Streuungsmaße

Die Abweichung der Daten von einem Maß zentraler Tendenz, gemessen mit einem Abweichungsmaß für das Skalenniveau, ergibt ein Streuungsmaß.
Je nach Skalenniveau sind verschiedene Streuungsmaße verfügbar:

- Nominalskala: Variationsverhältnis = Anteil nicht-Modus-Werte.
- Intervallskala: Spannweite := Abstand zwischen max. und min. Wert.
- Intervallskala: Interquartilsabstand := Abstand zwischen erstem und dritten Quartil. Dabei werden die Daten angeordnet in 4 Teile geteilt, das zweite Quartil ist der Median.

Streuungsmaße

Die Abweichung der Daten von einem Maß zentraler Tendenz, gemessen mit einem Abweichungsmaß für das Skalenniveau, ergibt ein Streuungsmaß.
Je nach Skalenniveau sind verschiedene Streuungsmaße verfügbar:

- Nominalskala: Variationsverhältnis = Anteil nicht-Modus-Werte.
- Intervallskala: Spannweite := Abstand zwischen max. und min. Wert.
- Intervallskala: Interquartilsabstand := Abstand zwischen erstem und dritten Quartil. Dabei werden die Daten angeordnet in 4 Teile geteilt, das zweite Quartil ist der Median.
- Intervallskala: Stichprobenstandardabweichung = Wurzel der mittleren quadratischen Abweichung vom Mittelwert.

Streuungsmaße

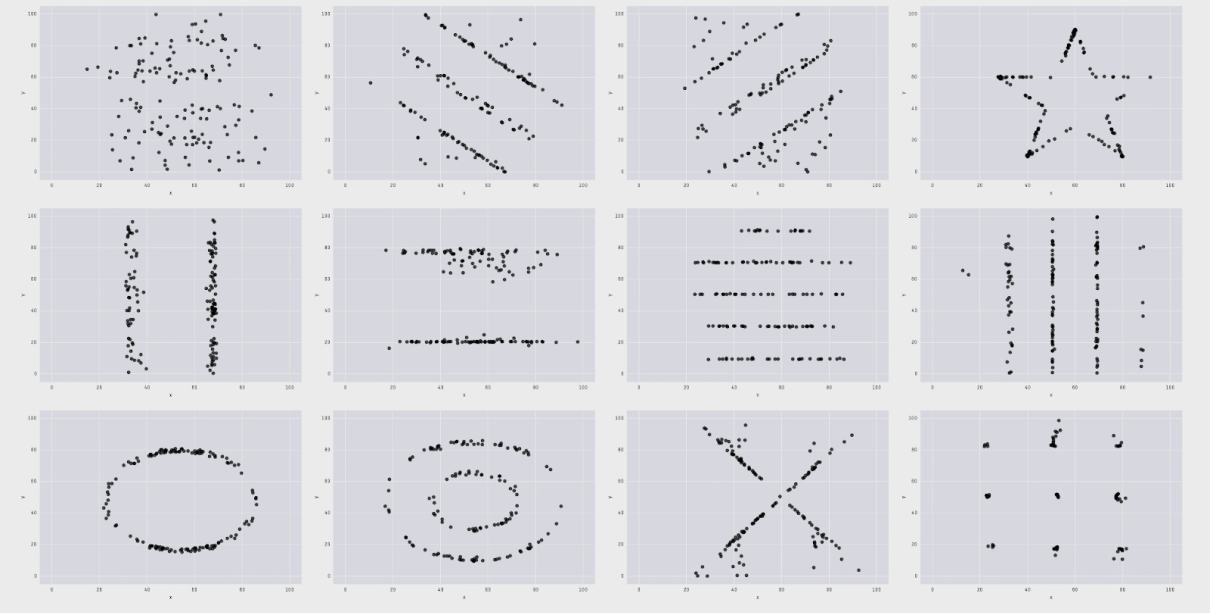
Heinrich Heine Universität Düsseldorf

Die Abweichung der Daten von einem Maß zentraler Tendenz, gemessen mit einem Abweichungsmaß für das Skalenniveau, ergibt ein Streuungsmaß.
Je nach Skalenniveau sind verschiedene Streuungsmaße verfügbar:

- Nominalskala: Variationsverhältnis = Anteil nicht-Modus-Werte.
- Intervallskala: Spannweite := Abstand zwischen max. und min. Wert.
- Intervallskala: Interquartilsabstand := Abstand zwischen erstem und dritten Quartil. Dabei werden die Daten angeordnet in 4 Teile geteilt, das zweite Quartil ist der Median.
- Intervallskala: Stichprobenstandardabweichung = Wurzel der mittleren quadratischen Abweichung vom Mittelwert.
- Verhältnisskala: Variationskoeffizient := $\frac{\sigma}{\mu}$, der Quotient aus Standardabweichung und Mittelwert. Der Kehrwert $\frac{\mu}{\sigma}$ heißt auch signal-to-noise-ratio.

Heinrich Heine
Universität Düsseldorf

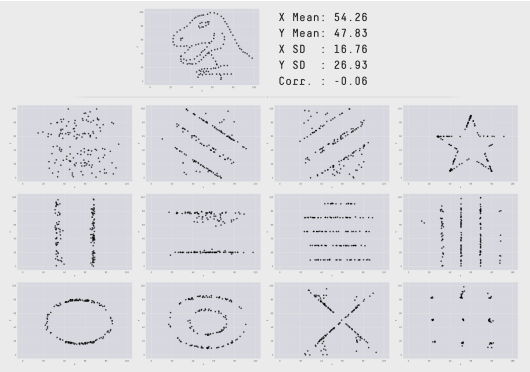
Visualisierung



Datasaurus

Heinrich Heine
Universität Düsseldorf

Alberto Cairo: the Datasaurus



Never trust summary statistics alone; always visualize your data

Scatterplot

Heinrich Heine
Universität Düsseldorf

Eine Menge von Vektoren (Punkten) in $\mathbb{R}^2$ lässt sich darstellen, indem ein rechteckiger Ausschnitt des $\mathbb{R}^2$ auf die Plotfläche abgebildet wird und an jedem Punkt ein Symbol, etwa ein gefüllter Kreis, gezeichnet wird.

`scatter(x, y, marker='o')` in `matplotlib.pyplot`

Also z.B. wenn `data.shape == (N, 2)`, dann
`scatter(data[:, 0], data[:, 1])`
um beide Spalten gegeneinander zu plotten.

Farbe im Scatterplot

Heinrich Heine
Universität Düsseldorf

Liegt zusätzlich zu x- und y-Werten noch eine dritte Variable vor, die sich in eine Farbskala umrechnen lässt, können wir diese nutzen.
Ist z.B. `data.shape == (N, 3)` und das dritte Feature ist eine kategoriale Variable mit 3 möglichen Ausprägungen, so wird

```
scatter(data[:, 0], data[:, 1], c=data[:, 2])
```

die Punkte entsprechend einer Default-Colormap (cmap) mit 3 Farben unterschiedlich einfärben.

Linienplots

Heinrich Heine
Universität Düsseldorf

Unsere Plots von Funktionsgraphen waren Linienplots. Man kann auch einen Kreis als Linienplot darstellen, indem man entlang eines Kreises Punkte sampelt, etwa für einen `np.linspace` zwischen 0 und 2π den Winkel:

```
angles = np.linspace(0, 6.28, 360)
plot(np.cos(angles), np.sin(angles), linewidth=2)
```

Bar charts (Balkendiagramme)

Für nominal skalierte Merkmale: pro Ausprägung ein Rechteck (der Balken) fester Breite, dessen Höhe proportional zur Häufigkeit der Ausprägung in der Stichprobe ist.

Bar charts (Balkendiagramme)

Heinrich Heine
Universität Düsseldorf

Für nominal skalierte Merkmale: pro Ausprägung ein Rechteck (der Balken) fester Breite, dessen Höhe proportional zur Häufigkeit der Ausprägung in der Stichprobe ist.

Bei ordinal skalierten Features ist es sinnvoll, die Rechtecke entlang der x-Achse anzuordnen.

Bar charts (Balkendiagramme)

Für nominal skalierte Merkmale: pro Ausprägung ein Rechteck (der Balken) fester Breite, dessen Höhe proportional zur Häufigkeit der Ausprägung in der Stichprobe ist.

Bei ordinal skalierten Features ist es sinnvoll, die Rechtecke entlang der x-Achse anzuordnen.

Tortendiagramme sind seltsam dargestellte Barcharts und in der Regel schlechter intuitiv zu erfassen als der entsprechende Barchart oder stacked Barchart (gestapelt).

Histogramme

Für Features mit unendlich vielen möglichen Ausprägungen, typischerweise auf Intervallskalen, ist ein Barchart nicht direkt sinnvoll.

Wir unterteilen die Skala in endlich viele Intervalle und bilden eine neue Variable: die Häufigkeit von Instanzen mit Ausprägung innerhalb des Intervalls. Diese neue Variable ist diskret, ihr Barchart heisst Histogramm von der ursprünglichen Variable. Die Unterteilung in Intervalle heißt Binning, die Größe eines Intervalls binsize (Eimergröße).

Empfehlung: Mike Yi: A complete guide to histograms

Weitere Visualisierungen

- Boxplot (Box-and-Whiskers) zur Darstellung von Quantilen

Weitere Visualisierungen

- Boxplot (Box-and-Whiskers) zur Darstellung von Quantilen
- Violinenplot zur Darstellung einer Dichte im Boxplot

Weitere Visualisierungen

- Boxplot (Box-and-Whiskers) zur Darstellung von Quantilen
- Violinenplot zur Darstellung einer Dichte im Boxplot
- Kartendarstellungen (etwa zweidimensionales Histogramm mit Farbe)

Die Grammatik der Grafiken

Geschichte

- 1983: Bertin: Semiology of Graphics
- 2000: Wilkinson, Anand, Grossman: The Grammar of Graphics
- 2005: Wickham: `ggplot2` R Paket
- 2010: Wickham: A Layered Grammar of Graphics

Grammatik

- Daten – Welche sollen visualisiert werden?
- Ästhetik – Achsen, Dimensionen
- Skalen – Werte skalieren? Nominal/Ordinal?
- Geometrie – Punkte, Linien, Polygone
- Statistik – z.B. Mittelwerte
- Facetten – Subplots
- Koordinatensysteme – kartesisch oder polar oder logarithmisch

Schichten (Layer)

Heinrich Heine
Universität Düsseldorf

Eine Schicht besteht aus

- Daten und ästhetische Zuordnungen (aes)
- Statistischen Transformationen (stat)
- Geometrischen Objekten (geom)
- Positionsbestimmungen

Statistische Transformationen

Die wichtigsten statistischen Transformationen, die in ggplot2 implementiert sind, haben wir teilweise schon kennen gelernt:

- bin: Teile stetigen Bereich in Bins (Klassen) und zähle Punkte in jeder Klasse.
- boxplot: Berechne Statistik für Boxplot
- contour: Berechne Konturlinien
- density: Berechne eindimensionale Dichteschätzung
- identity: Identitätsabbildung, f(x) = x
- jitter: Verändere jeden Wert mit einem kleinen Zufallswert
- smooth: Geglätteter Mittelwert von y, gegeben x
- summary: Summierte Werte von y für jedes x
- unique: Entferne Duplikate

Skalen

Eine Skala im Sinne der Grammatik der Grafiken kontrolliert die Zuordnung von Daten zu den ästhetischen Attributen.

Skalen

Eine Skala im Sinne der Grammatik der Grafiken kontrolliert die Zuordnung von Daten zu den ästhetischen Attributen.

Beispiel: eine reelle Variable zwischen 0 und 1 lässt sich als Farbänderung von Blau zu Rot darstellen. Die Skala ist die Zuordnung aller Werte von $[0, 1]$ auf Farbwerte. Die Umkehrfunktion dieser Zuordnung lässt sich zur Darstellung einer Legende nutzen.

Skalen

Eine Skala im Sinne der Grammatik der Grafiken kontrolliert die Zuordnung von Daten zu den ästhetischen Attributen.

Beispiel: eine reelle Variable zwischen 0 und 1 lässt sich als Farbänderung von Blau zu Rot darstellen. Die Skala ist die Zuordnung aller Werte von $[0, 1]$ auf Farbwerte. Die Umkehrfunktion dieser Zuordnung lässt sich zur Darstellung einer Legende nutzen.

Beispiel: eine kategoriale Variable (etwa die Spezies im Iris-Datensatz) wird mit verschiedenen Symbolen dargestellt (etwa in einem Scatterplot). Die Zuordnung Ausprägung zu Symbol ist die Skala.

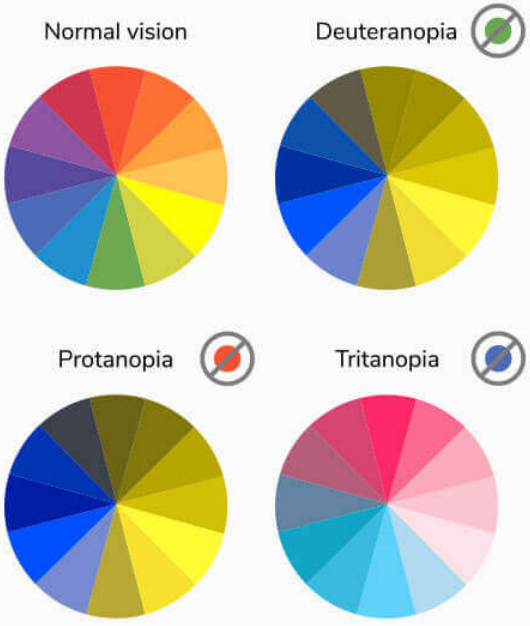
Farben

Bei der Wahl von Farben zur Visualisierung sollte man stets bedenken, dass schlechte Lichtverhältnisse bereits zu verminderter Farbwahrnehmung führen und daher Farbe möglichst nicht allein verwendet werden sollte - mindestens die Helligkeit sollte bereits ausreichen (früher: Druck in Graustufen). Auch ergänzt mit Linienstil (-dicke, gestrichelt, gepunktet) oder Symbolen (Kreise, Kreuze) wirkt Farbe.

Farben

Bei der Wahl von Farben zur Visualisierung sollte man stets bedenken, dass schlechte Lichtverhältnisse bereits zu verminderter Farbwahrnehmung führen und daher Farbe möglichst nicht allein verwendet werden sollte - mindestens die Helligkeit sollte bereits ausreichen (früher: Druck in Graustufen). Auch ergänzt mit Linienstil (-dicke, gestrichelt, gepunktet) oder Symbolen (Kreise, Kreuze) wirkt Farbe.

Etwa jeder 12. Mann und jede 200. Frau können Farben nicht so unterscheiden wie die Mehrheit. Das ist so häufig, dass man Farbskalen verwenden sollte, die diese Menschen auch unterscheiden können.



hhu
Heinrich Heine
Universität Düsseldorf

Zusammenfassung

- Sie können Daten in verschiedene Skalenniveaus einteilen,

Zusammenfassung

- Sie können Daten in verschiedene Skalenniveaus einteilen,
- anhand dessen deskriptive Statistiken (Häufigkeiten, Summen, Lagemaße zentraler Tendenz, Dispersionsmaße) berechnen,

Zusammenfassung

- Sie können Daten in verschiedene Skalenniveaus einteilen,
- anhand dessen deskriptive Statistiken (Häufigkeiten, Summen, Lagemaße zentraler Tendenz, Dispersionsmaße) berechnen,
- geeignete Visualisierungen auswählen (statistische Transformationen, Geometrien),

Zusammenfassung

- Sie können Daten in verschiedene Skalenniveaus einteilen,
- anhand dessen deskriptive Statistiken (Häufigkeiten, Summen, Lagemaße zentraler Tendenz, Dispersionsmaße) berechnen,
- geeignete Visualisierungen auswählen (statistische Transformationen, Geometrien),
- mit Wahrscheinlichkeitsverteilungen modellieren und die Modelle visualisieren.

Explorative Datenanalyse

In der EDA geht es darum, sich iterativ Daten zu erschließen und die Erkenntnisse zu kommunizieren. Dabei werden wiederholt diese Schritte durchgeführt:

- Forschungsfragen formulieren (welche Skalen, Verteilungen, Zusammenhänge?)

Das werden wir noch üben!

Explorative Datenanalyse

In der EDA geht es darum, sich iterativ Daten zu erschließen und die Erkenntnisse zu kommunizieren. Dabei werden wiederholt diese Schritte durchgeführt:

- Forschungsfragen formulieren (welche Skalen, Verteilungen, Zusammenhänge?)
- Daten visualisieren (deskriptive Statistik)

Das werden wir noch üben!

Explorative Datenanalyse

In der EDA geht es darum, sich iterativ Daten zu erschließen und die Erkenntnisse zu kommunizieren. Dabei werden wiederholt diese Schritte durchgeführt:

- Forschungsfragen formulieren (welche Skalen, Verteilungen, Zusammenhänge?)
- Daten visualisieren (deskriptive Statistik)
- Daten putzen (ggf. Ausreißer entfernen, Fehlstellen imputieren/interpolieren)

Das werden wir noch üben!

Explorative Datenanalyse

In der EDA geht es darum, sich iterativ Daten zu erschließen und die Erkenntnisse zu kommunizieren. Dabei werden wiederholt diese Schritte durchgeführt:

- Forschungsfragen formulieren (welche Skalen, Verteilungen, Zusammenhänge?)
- Daten visualisieren (deskriptive Statistik)
- Daten putzen (ggf. Ausreißer entfernen, Fehlstellen imputieren/interpolieren)
- Daten transformieren (Teile auswählen, neue Features generieren)

Das werden wir noch üben!

Explorative Datenanalyse

In der EDA geht es darum, sich iterativ Daten zu erschließen und die Erkenntnisse zu kommunizieren. Dabei werden wiederholt diese Schritte durchgeführt:

- Forschungsfragen formulieren (welche Skalen, Verteilungen, Zusammenhänge?)
- Daten visualisieren (deskriptive Statistik)
- Daten putzen (ggf. Ausreißer entfernen, Fehlstellen imputieren/interpolieren)
- Daten transformieren (Teile auswählen, neue Features generieren)
- Daten modellieren (statistische Modelle wählen, fitten)

Das werden wir noch üben!



Heinrich Heine
Universität Düsseldorf

Vielen Dank für Ihre Aufmerksamkeit!