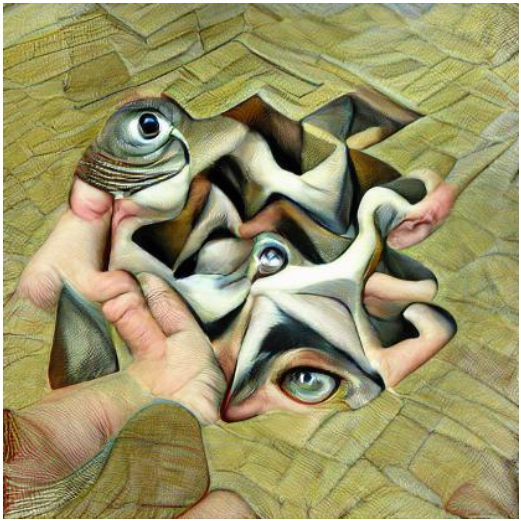


Data Science, VL 10

Dr. Konrad Völkel, Sommersemester 2026

26.05.2026



„Many dimensions at once, MC Escher“

Gemeinsame Verteilungen

Heinrich Heine
Universität Düsseldorf

Zu zwei Zufallsvariablen $X\colon \Omega_1 \to \mathbb{R}$, $Y\colon \Omega_2 \to \mathbb{R}$ können wir das Produkt bilden:

$$X \times Y\colon \Omega_1 \times \Omega_2 \to \mathbb{R}^2, \quad (a, b) \mapsto (X(a), Y(b))$$

Gemeinsame Verteilungen

Zu zwei Zufallsvariablen $\mathrm{X}\colon \Omega_1 \to \mathbb{R}$, $\mathrm{Y}\colon \Omega_2 \to \mathbb{R}$ können wir das Produkt bilden:

$$\mathrm{X} \times \mathrm{Y}\colon \Omega_1 \times \Omega_2 \to \mathbb{R}^2, \quad (\mathrm{a}, \mathrm{b}) \mapsto (\mathrm{X}(\mathrm{a}), \mathrm{Y}(\mathrm{b}))$$

Sind die Definitionsbereiche identisch ($\Omega_1 = \Omega_2 = \Omega$), können wir das Produkt bilden:

$$\mathrm{X} \times \mathrm{Y}\colon \Omega^2 \to \mathbb{R}^2, \quad (\mathrm{a}, \mathrm{b}) \mapsto (\mathrm{X}(\mathrm{a}), \mathrm{Y}(\mathrm{b}))$$

und die Diagonalabbildung $\Delta\colon \Omega \to \Omega^2, \mathrm{a} \mapsto (\mathrm{a}, \mathrm{a})$ davorschalten, um die Zufallsvariable $(\mathrm{X}, \mathrm{Y})\colon \Omega \to \mathbb{R}^2$ zu erhalten.

Marginalverteilungen

- Zu einer mehrdimensionalen Zufallsvariable $X\colon \Omega \to \mathbb{R}^n$ mit $X = (X_1, \ldots, X_n)$ können wir die einzelnen $X_i\colon \Omega \to \mathbb{R}$ betrachten.

Marginalverteilungen

- Zu einer mehrdimensionalen Zufallsvariable $X\colon \Omega \to \mathbb{R}^n$ mit $X = (X_1, \ldots, X_n)$ können wir die einzelnen $X_i\colon \Omega \to \mathbb{R}$ betrachten.
- Diese X_i heißen Randverteilungen oder Marginalverteilungen.

Marginalverteilungen

- Zu einer mehrdimensionalen Zufallsvariable $X\colon \Omega \to \mathbb{R}^n$ mit $X = (X_1, \ldots, X_n)$ können wir die einzelnen $X_i\colon \Omega \to \mathbb{R}$ betrachten.
- Diese X_i heißen Randverteilungen oder Marginalverteilungen.
- Allgemeiner ist auch ein Teilvektor wie (X_1, X_3, X_9) eine Marginalverteilung.

Marginalverteilungen

- Zu einer mehrdimensionalen Zufallsvariable $X\colon \Omega \to \mathbb{R}^n$ mit $X = (X_1, \dots, X_n)$ können wir die einzelnen $X_i\colon \Omega \to \mathbb{R}$ betrachten.
- Diese X_i heißen Randverteilungen oder Marginalverteilungen.
- Allgemeiner ist auch ein Teilvektor wie (X_1, X_3, X_9) eine Marginalverteilung.
- Wir können die Verteilung von X_i berechnen:

$$P(X_i \in A) = P(X \in \pi_i^{-1}(A))$$

wobei $\pi_i\colon \mathbb{R}^n \to \mathbb{R}$ die Projektion auf die i-te Koordinate ist (denn $X_i = \pi_i \circ X$).

Marginalverteilungen berechnen

Zu einer diskreten Zufallsvariable $(X, Y)\colon \Omega \to \mathbb{R}^2$ berechnet sich die Verteilung von Y durch Ausintegrieren (Summieren) von X:

$$P(Y \in A) = \sum_{x \in X(\Omega)} P\big((X, Y) \in \{x\} \times A\big)$$

(bzw. mit einem entsprechenden Integral im stetigen Fall)

Marginalverteilungen berechnen

Zu einer diskreten Zufallsvariable $(X, Y)\colon \Omega \to \mathbb{R}^2$ berechnet sich die Verteilung von Y durch Ausintegrieren (Summieren) von X:

$$P(Y \in A) = \sum_{x \in X(\Omega)} P\big((X, Y) \in \{x\} \times A\big)$$

(bzw. mit einem entsprechenden Integral im stetigen Fall)

Dabei haben wir $\pi_1^{-1}(A) = X(\Omega) \times A$ in disjunkte Teilmengen zerlegt.

Bedingte und gemeinsame Verteilung

Aus der Definition der bedingten Wahrscheinlichkeit $\mathrm{P}(\mathrm{A} \mid \mathrm{B}) := \frac{\mathrm{P}(\mathrm{A} \cap \mathrm{B})}{\mathrm{P}(\mathrm{B})}$ folgt die Summenregel:

$$\mathrm{P}((\mathrm{X}, \mathrm{Y}) = (\mathrm{x}, \mathrm{y})) = \mathrm{P}(\mathrm{X} = \mathrm{x}, \mathrm{Y} = \mathrm{y}) = \mathrm{P}(\mathrm{Y} = \mathrm{y} \mid \mathrm{X} = \mathrm{x})\mathrm{P}(\mathrm{X} = \mathrm{x})$$

Bedingte und gemeinsame Verteilung

Aus der Definition der bedingten Wahrscheinlichkeit $\mathrm{P}(\mathrm{A} \mid \mathrm{B}) := \frac{\mathrm{P}(\mathrm{A} \cap \mathrm{B})}{\mathrm{P}(\mathrm{B})}$ folgt die Summenregel:

$$\mathrm{P}((\mathrm{X}, \mathrm{Y}) = (\mathrm{x}, \mathrm{y})) = \mathrm{P}(\mathrm{X} = \mathrm{x}, \mathrm{Y} = \mathrm{y}) = \mathrm{P}(\mathrm{Y} = \mathrm{y} \mid \mathrm{X} = \mathrm{x})\mathrm{P}(\mathrm{X} = \mathrm{x})$$

Für diskrete Zufallsvariablen schreiben wir das mit der Wahrscheinlichkeitsfunktion (PMF):

$$\mathrm{p}_{\mathrm{X},\mathrm{Y}}(\mathrm{x}, \mathrm{y}) = \mathrm{p}_{\mathrm{Y}|\mathrm{X}}(\mathrm{y} \mid \mathrm{x})\mathrm{p}_{\mathrm{X}}(\mathrm{x}) \quad \Longleftrightarrow \quad \mathrm{p}_{\mathrm{Y}|\mathrm{X}}(\mathrm{y} \mid \mathrm{x}) := \frac{\mathrm{p}_{\mathrm{X},\mathrm{Y}}(\mathrm{x}, \mathrm{y})}{\mathrm{p}_{\mathrm{X}}(\mathrm{x})}$$

Dies ist für jedes konkrete x die PMF der bedingten Verteilung. (Analog für stetige Zufallsvariablen mit der Dichtefunktion PDF).

Unabhängigkeit

Die Unabhängigkeit zweier Zufallsvariablen X und Y ist äquivalent dazu, dass sich die gemeinsame Dichte faktorisieren lässt:

$$p_{X,Y}(x, y) = p_Y(y)p_X(x)$$

Unabhängigkeit

Die Unabhängigkeit zweier Zufallsvariablen X und Y ist äquivalent dazu, dass sich die gemeinsame Dichte faktorisieren lässt:

$$p_{X,Y}(x, y) = p_Y(y)p_X(x)$$

Dies ist wiederum äquivalent zu:

$$p_{Y|X}(y \mid x) = p_Y(y)$$



„Powerful magician looking at semiconductors“

Der Satz von Bayes

Heinrich Heine
Universität Düsseldorf

Gegeben zwei Ereignisse $A, B \subseteq \Omega$. Aus dem Beweis $P(A \mid B) := \frac{P(A \cap B)}{P(B)}$ folgt:

$$P(A \mid B) = \frac{P(B \mid A)P(A)}{P(B)}$$

Der Satz von Bayes

Heinrich Heine
Universität Düsseldorf

Gegeben zwei Ereignisse $A, B \subseteq \Omega$. Aus dem Beweis $P(A \mid B) := \frac{P(A \cap B)}{P(B)}$ folgt:

$$P(A \mid B) = \frac{P(B \mid A)P(A)}{P(B)}$$

Für Zufallsvariablen $X, Y \colon \Omega \to \mathbb{R}^n$:

$$P(Y = y \mid X = x) = \frac{P(X = x \mid Y = y)P(Y = y)}{P(X = x)}$$

Der Satz von Bayes

Heinrich Heine Universität Düsseldorf

Gegeben zwei Ereignisse $A, B \subseteq \Omega$. Aus dem Beweis $P(A \mid B) := \frac{P(A \cap B)}{P(B)}$ folgt:

$$P(A \mid B) = \frac{P(B \mid A)P(A)}{P(B)}$$

Für Zufallsvariablen $X, Y \colon \Omega \to \mathbb{R}^n$:

$$P(Y = y \mid X = x) = \frac{P(X = x \mid Y = y)P(Y = y)}{P(X = x)}$$

Häufige Anwendung:

- $X = x$ sind die Daten D (die sind bekannt).
- $Y = y$ ist unsere vorläufige Hypothese H (unser Modell).

Bayessches Update

Gegeben eine Hypothese H und Daten D:

$$\underbrace{\mathrm{P}(\mathrm{H} \mid \mathrm{D})}_{\text{Posterior}} = \frac{\overbrace{\mathrm{P}(\mathrm{D} \mid \mathrm{H})}^{\text{Likelihood}} \cdot \overbrace{\mathrm{P}(\mathrm{H})}^{\text{Prior}}}{\underbrace{\mathrm{P}(\mathrm{D})}_{\text{Evidenz}}}$$

Bayessches Update

Heinrich Heine Universität Düsseldorf

Gegeben eine Hypothese H und Daten D:

$$\underbrace{\mathrm{P}(\mathrm{H} \mid \mathrm{D})}_{\text{Posterior}} = \frac{\overbrace{\mathrm{P}(\mathrm{D} \mid \mathrm{H})}^{\text{Likelihood}} \cdot \overbrace{\mathrm{P}(\mathrm{H})}^{\text{Prior}}}{\underbrace{\mathrm{P}(\mathrm{D})}_{\text{Evidenz}}}$$

Die Wahrscheinlichkeit für die Hypothese unter Berücksichtigung der Daten zu berechnen, heißt Bayessches Update.

- Prior: $\mathrm{P}(\mathrm{H})$

Bayessches Update

Heinrich Heine Universität Düsseldorf

Gegeben eine Hypothese H und Daten D:

$$\underbrace{\mathrm{P}(\mathrm{H} \mid \mathrm{D})}_{\text{Posterior}} = \frac{\overbrace{\mathrm{P}(\mathrm{D} \mid \mathrm{H})}^{\text{Likelihood}} \cdot \overbrace{\mathrm{P}(\mathrm{H})}^{\text{Prior}}}{\underbrace{\mathrm{P}(\mathrm{D})}_{\text{Evidenz}}}$$

Die Wahrscheinlichkeit für die Hypothese unter Berücksichtigung der Daten zu berechnen, heißt Bayessches Update.

- Prior: $\mathrm{P}(\mathrm{H})$
- Likelihood: $\mathrm{P}(\mathrm{D} \mid \mathrm{H})$, „how likely is the data, if the hypothesis were true?“

Bayessches Update

Heinrich Heine Universität Düsseldorf

Gegeben eine Hypothese H und Daten D:

$$\underbrace{\mathrm{P}(\mathrm{H} \mid \mathrm{D})}_{\text{Posterior}} = \frac{\overbrace{\mathrm{P}(\mathrm{D} \mid \mathrm{H})}^{\text{Likelihood}} \cdot \overbrace{\mathrm{P}(\mathrm{H})}^{\text{Prior}}}{\underbrace{\mathrm{P}(\mathrm{D})}_{\text{Evidenz}}}$$

Die Wahrscheinlichkeit für die Hypothese unter Berücksichtigung der Daten zu berechnen, heißt Bayessches Update.

- Prior: $\mathrm{P}(\mathrm{H})$
- Likelihood: $\mathrm{P}(\mathrm{D} \mid \mathrm{H})$, „how likely is the data, if the hypothesis were true?“
- Evidenz: $\mathrm{P}(\mathrm{D})$

Bayessches Update

Heinrich Heine Universität Düsseldorf

Gegeben eine Hypothese H und Daten D:

$$\underbrace{\mathrm{P}(\mathrm{H} \mid \mathrm{D})}_{\text{Posterior}} = \frac{\overbrace{\mathrm{P}(\mathrm{D} \mid \mathrm{H})}^{\text{Likelihood}} \cdot \overbrace{\mathrm{P}(\mathrm{H})}^{\text{Prior}}}{\underbrace{\mathrm{P}(\mathrm{D})}_{\text{Evidenz}}}$$

Die Wahrscheinlichkeit für die Hypothese unter Berücksichtigung der Daten zu berechnen, heißt Bayessches Update.

- Prior: $\mathrm{P}(\mathrm{H})$
- Likelihood: $\mathrm{P}(\mathrm{D} \mid \mathrm{H})$, „how likely is the data, if the hypothesis were true?“
- Evidenz: $\mathrm{P}(\mathrm{D})$
- Posterior: $\mathrm{P}(\mathrm{H} \mid \mathrm{D})$

Die Likelihood in der Praxis

Heinrich Heine
Universität Düsseldorf

Denken wir an die 3 Verteilungen: Datenerzeugung $X \rightarrow$ Daten $D \rightarrow$ Modell Y.

Die Likelihood $P(X = D \mid Y = D)$ gibt an, wie wahrscheinlich es ist, die Daten D zu sehen, wenn man Y zur Erzeugung der Daten nimmt.

Die Likelihood in der Praxis

Heinrich Heine
Universität Düsseldorf

Denken wir an die 3 Verteilungen: Datenerzeugung $\mathrm{X} \to$ Daten $\mathrm{D} \to$ Modell Y.

Die Likelihood $\mathrm{P}(\mathrm{X} = \mathrm{D} \mid \mathrm{Y} = \mathrm{D})$ gibt an, wie wahrscheinlich es ist, die Daten D zu sehen, wenn man Y zur Erzeugung der Daten nimmt.

Beispiel: Angenommen, wir rechnen fest mit einer Normalverteilung $\mathcal{N}(\mu, \sigma^2)$ mit Dichte $\mathrm{p}_{\mu,\sigma}$. Hypothese H: $\mu = 0, \sigma = 2$.

Dann ist $\mathrm{P}(\mathrm{X} = \mathrm{D} \mid \mathrm{H})$ die Wahrscheinlichkeit für ein Sample D unter $\mathrm{X} \sim \mathcal{N}(0, 2^2)$. Die Likelihood(-Dichte) ist das Produkt: $\prod_{\mathrm{x} \in \mathrm{D}} \mathrm{p}_{\mu,\sigma}(\mathrm{x})$.

Kovarianz

Heinrich Heine
Universität Düsseldorf

Definition

Gegeben eine bivariate Zufallsvariable $(X, Y)\colon \Omega \to \mathbb{R}^2$. Die Kovarianz ist definiert als:

$$\mathrm{Cov}(X, Y) := \mathbb{E}\big((X - \mathbb{E}X)(Y - \mathbb{E}Y)\big)$$

Kovarianz

Heinrich Heine
Universität Düsseldorf

Definition

Gegeben eine bivariate Zufallsvariable $(X, Y)\colon \Omega \to \mathbb{R}^2$. Die Kovarianz ist definiert als:

$$\mathrm{Cov}(X, Y) := \mathbb{E}\big((X - \mathbb{E}X)(Y - \mathbb{E}Y)\big)$$

Also auch: $\mathbb{V}(X) = \mathrm{Cov}(X, X)$.

Kovarianz

Heinrich Heine
Universität Düsseldorf

Definition

Gegeben eine bivariate Zufallsvariable $(X, Y)\colon \Omega \to \mathbb{R}^2$. Die Kovarianz ist definiert als:

$$\mathrm{Cov}(X, Y) := \mathbb{E}\big((X - \mathbb{E}X)(Y - \mathbb{E}Y)\big)$$

Also auch: $\mathbb{V}(X) = \mathrm{Cov}(X, X)$.

Die Kovarianz hat die gleiche Krankheit wie die Varianz: sie ist skalenabhängig. Zur Heilung normiert man mit den Standardabweichungen.

Korrelationskoeffizient

Heinrich Heine
Universität Düsseldorf

Definition

(Pearsons) Korrelationskoeffizient $\rho(X, Y)$ ist definiert als:

$$\rho(X, Y) := \frac{\mathrm{Cov}(X, Y)}{\sigma(X)\sigma(Y)}$$

Korrelationskoeffizient

Definition

(Pearsons) Korrelationskoeffizient $\rho(X, Y)$ ist definiert als:

$$\rho(X, Y) := \frac{\mathrm{Cov}(X, Y)}{\sigma(X)\sigma(Y)}$$

- Es ist klar: $\rho(X, Y) = 0 \iff \mathrm{Cov}(X, Y) = 0$.

Korrelationskoeffizient

Heinrich Heine Universität Düsseldorf

Definition

(Pearsons) Korrelationskoeffizient $\rho(X, Y)$ ist definiert als:

$$\rho(X, Y) := \frac{\mathrm{Cov}(X, Y)}{\sigma(X)\sigma(Y)}$$

- Es ist klar: $\rho(X, Y) = 0 \iff \mathrm{Cov}(X, Y) = 0$.
- X und Y sind positiv korreliert, wenn $\rho(X, Y) > 0$.

Korrelationskoeffizient

Heinrich Heine Universität Düsseldorf

Definition

(Pearsons) Korrelationskoeffizient $\rho(X, Y)$ ist definiert als:

$$\rho(X, Y) := \frac{\mathrm{Cov}(X, Y)}{\sigma(X)\sigma(Y)}$$

- Es ist klar: $\rho(X, Y) = 0 \iff \mathrm{Cov}(X, Y) = 0$.
- X und Y sind positiv korreliert, wenn $\rho(X, Y) > 0$.
- X und Y sind unkorreliert, wenn $\rho(X, Y) = 0$.

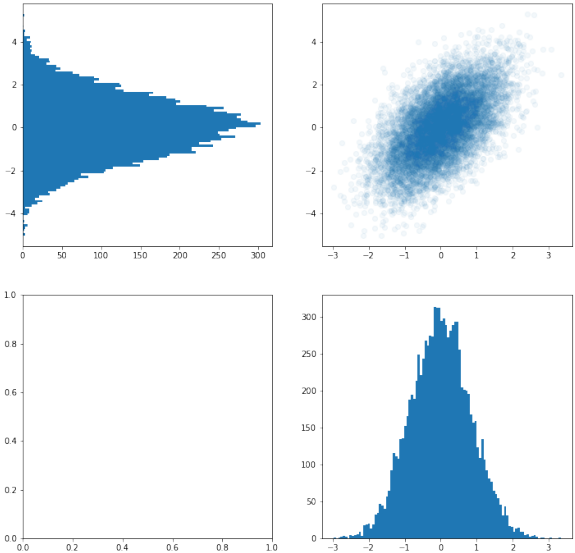
Visualisierung einer bivariaten Verteilung

Heinrich Heine Universität Düsseldorf

```python
import numpy as np
import scipy.stats as st
import matplotlib.pyplot as plt

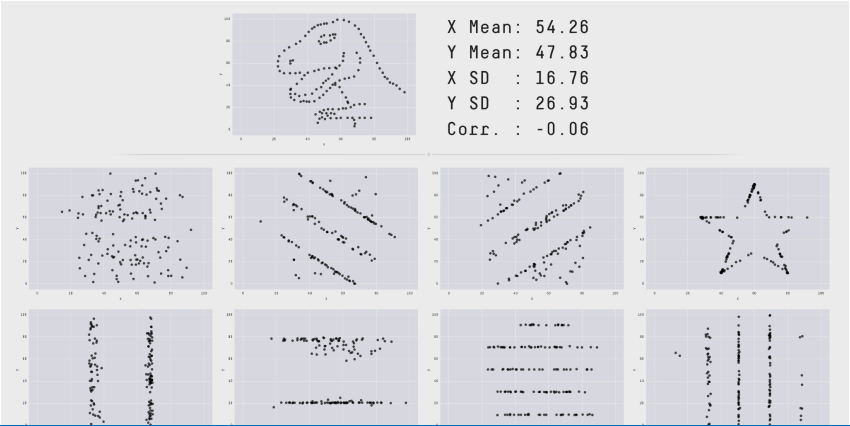
origin = [0,0] #
Sigma = [[1,2],[0,1]] #
Z = st.multivariate_normal(origin, cov=Sigma) #
sample = Z.rvs(10000) #
x, y = sample[:,0], sample[:,1] #

fig, axs = plt.subplots(2, 2, figsize=(12,12)) #
axs[0,1].scatter(x, y, alpha=0.05) #
axs[1,1].hist(x, bins=100) #
axs[0,0].hist(y, bins=100, orientation="horizontal") #
plt.show() #
```


4
2
0
−2
−4
0
50
100
150
200
250
300
4
2
0
−2
−4
−3
−2
−1
0
1
2
3
1.0
0.8
0.6
0.4
0.2
0.0
0.0
0.2
0.4
0.6
0.8
1.0
300
250
200
150
100
50
0
−3
−2
−1
0
1
2
3

Kovarianz: Der Datasaurus

Matejka, Fitzmaurice: Same Stats, Different Graphs (2017)



Eigenschaften der Kovarianz

Die Kovarianz ist symmetrisch und bilinear:

- Symmetrie: $\mathrm{Cov}(X, Y) = \mathrm{Cov}(Y, X)$

Eigenschaften der Kovarianz

Die Kovarianz ist symmetrisch und bilinear:

- Symmetrie: $\mathrm{Cov}(X, Y) = \mathrm{Cov}(Y, X)$
- Bilinearität: Für $a, b \in \mathbb{R}$ ist:

$$\mathrm{Cov}(aX + bY, Z) = a \cdot \mathrm{Cov}(X, Z) + b \cdot \mathrm{Cov}(Y, Z)$$

Eigenschaften der Kovarianz

Die Kovarianz ist symmetrisch und bilinear:

- Symmetrie: $\mathrm{Cov}(X, Y) = \mathrm{Cov}(Y, X)$
- Bilinearität: Für $a, b \in \mathbb{R}$ ist:

$$\mathrm{Cov}(aX + bY, Z) = a \cdot \mathrm{Cov}(X, Z) + b \cdot \mathrm{Cov}(Y, Z)$$

- Positiv definit: $\mathrm{Cov}(X, X) \geq 0$ und $\mathrm{Cov}(X, X) = 0$ nur für konstantes X.



Heinrich Heine
Universität Düsseldorf

Danke für Ihre Aufmerksamkeit.