

Data Science, VL 16

Dr. Konrad Völkel, Sommersemester 2026

18.06.2026

Das Maximum-Likelihood-Prinzip

Likelihood-Funktion

Heinrich Heine
Universität Düsseldorf

Definition

Gegeben ein statistisches Standardmodell $(\mathcal{X}, \mathrm{P}_\theta : \theta \in \Theta)$ mit Dichte f_θ (entweder pmf oder pdf) für P_θ heißt $\rho\colon \mathcal{X} \times \Theta \to \mathbb{R}_{\geq 0}$ mit $\rho(\mathrm{x}, \theta) := \mathrm{L}_\mathrm{x}(\theta) := \mathrm{f}_\theta(\mathrm{x})$ die Likelihood-Funktion und für festes x heißt $\mathrm{L}_\mathrm{x} = \rho(\mathrm{x}, \cdot)\colon \Theta \to \mathbb{R}_{\geq 0}$ die Likelihood-Funktion zum Beobachtungswert x.

Likelihood-Funktion

Heinrich Heine
Universität Düsseldorf

Definition

Gegeben ein statistisches Standardmodell $(\mathcal{X}, \mathrm{P}_\theta : \theta \in \Theta)$ mit Dichte f_θ (entweder pmf oder pdf) für P_θ heißt $\rho\colon \mathcal{X} \times \Theta \to \mathbb{R}_{\geq 0}$ mit $\rho(\mathrm{x}, \theta) := \mathrm{L}_\mathrm{x}(\theta) := \mathrm{f}_\theta(\mathrm{x})$ die Likelihood-Funktion und für festes x heißt $\mathrm{L}_\mathrm{x} = \rho(\mathrm{x}, \cdot)\colon \Theta \to \mathbb{R}_{\geq 0}$ die Likelihood-Funktion zum Beobachtungswert x.

Erinnerung: Wenn wir die Hypothese $\mathrm{H} = (\theta$ ist der wahre Parameter) haben, und $\mathrm{D} = \mathrm{x}$ (für Daten) schreiben, so ist $\mathrm{P}(\mathrm{D}|\mathrm{H}) = \mathrm{L}_\mathrm{x}(\theta) = \mathrm{f}_\theta(\mathrm{x})$ die Likelihood.

MLE

Heinrich Heine
Universität Düsseldorf

Definition

Ein Schätzer $\mathrm{T}\colon \mathcal{X} \to \Theta$ für den Parameter θ heißt Maximum-Likelihood-Schätzer (maximum likelihood estimator, MLE), wenn für alle $\mathrm{x} \in \mathcal{X}$ gilt:

$$\mathrm{L}_{\mathrm{x}}(\mathrm{T}(\mathrm{x})) = \max_{\theta \in \Theta} \mathrm{L}_{\mathrm{x}}(\theta),$$

also wenn $\mathrm{T}(\mathrm{x})$ die Likelihood von x maximiert, für alle x. Man schreibt auch

$$\mathrm{T}(\mathrm{x}) = \operatorname*{argmax}_{\theta \in \Theta} \mathrm{L}_{\mathrm{x}}(\theta).$$

Beispiel

Im N-fachen univariat normalverteilten Modell ist $\mathrm{x} \mapsto (\texttt{mean}(\mathrm{x}), \sigma(\mathrm{x}))$ ein Maximum-Likelihood-Schätzer für den Parameter $(\mu(\mathrm{X}), \sigma(\mathrm{X}))$. Der Schätzer σ^* ist hingegen kein Maximum-Likelihood-Schätzer für $\sigma(\mathrm{X})$. Also können sich Erwartungstreue und Maximum-Likelihood-Prinzip gegenseitig ausschließen.

Bemerkung

Mit Hilfe der relativen Entropie lässt sich beweisen, dass unter schwachen Voraussetzungen eine Folge von Maximum-Likelihood-Schätzern stets konsistent ist.

Bemerkung

Mit Hilfe der relativen Entropie lässt sich beweisen, dass unter schwachen Voraussetzungen eine Folge von Maximum-Likelihood-Schätzern stets konsistent ist. Erinnerung: das heisst dass die Schätzwerte gegen den zu schätzenden Wert konvergieren.

Bemerkung

- Wir sind also für eine Familie von Verteilungen P_θ mit Dichten f_θ daran interessiert, die Likelihood $f_\theta(x)$ einer Beobachtung x in θ zu maximieren.

Bemerkung

- Wir sind also für eine Familie von Verteilungen P_θ mit Dichten f_θ daran interessiert, die Likelihood $f_\theta(x)$ einer Beobachtung x in θ zu maximieren.
- Um Funktionen zu maximieren, betrachten wir gern die Ableitung (dazu sollte f in θ differenzierbar sein).

Bemerkung

- Wir sind also für eine Familie von Verteilungen P_θ mit Dichten f_θ daran interessiert, die Likelihood $\mathrm{f}_\theta(\mathrm{x})$ einer Beobachtung x in θ zu maximieren.
- Um Funktionen zu maximieren, betrachten wir gern die Ableitung (dazu sollte f in θ differenzierbar sein).
- Schon am Beispiel der univariaten Normalverteilungsdichte $\phi_{\mu,\sigma}$ sehen wir, dass die Ableitung $\frac{\mathrm{d}}{\mathrm{d}\mu}\phi_{\mu,\sigma}(\mathrm{x}) = \frac{(\mathrm{x}-\mu)}{\sigma^2}\phi_{\mu,\sigma}(\mathrm{x})$ bei $\mathrm{x} = \mu$ verschwindet, damit ist $\mu = \mathrm{x}$ der MLE für eine Stichprobe der Größe 1.

Bemerkung

- Wir sind also für eine Familie von Verteilungen P_θ mit Dichten f_θ daran interessiert, die Likelihood $\mathrm{f}_\theta(\mathrm{x})$ einer Beobachtung x in θ zu maximieren.
- Um Funktionen zu maximieren, betrachten wir gern die Ableitung (dazu sollte f in θ differenzierbar sein).
- Schon am Beispiel der univariaten Normalverteilungsdichte $\phi_{\mu,\sigma}$ sehen wir, dass die Ableitung $\frac{\mathrm{d}}{\mathrm{d}\mu}\phi_{\mu,\sigma}(\mathrm{x}) = \frac{(\mathrm{x}-\mu)}{\sigma^2}\phi_{\mu,\sigma}(\mathrm{x})$ bei $\mathrm{x} = \mu$ verschwindet, damit ist $\mu = \mathrm{x}$ der MLE für eine Stichprobe der Größe 1.
- Im Allgemeinen ist die Likelihood allerdings schwerer zu berechnen (betrachte ein n-faches Produktmodell).

Trick

Anstatt die Likelihood von x über alle möglichen θ zu maximieren, kann man auch die log-Likelihood $\log \rho(x, \theta)$ maximieren.
log konkav $\Rightarrow$ ein Maximum der log-Likelihood ist auch ein Max. der Likelihood.

Trick

Anstatt die Likelihood von x über alle möglichen θ zu maximieren, kann man auch die log-Likelihood $\log \rho(x, \theta)$ maximieren.
log konkav $\Rightarrow$ ein Maximum der log-Likelihood ist auch ein Max. der Likelihood.
Wenn z.B. ρ die Form $e^A e^B$ hat (etwa bei einem 2-fachen Produktmodell), hat $\log \rho$ die Form $A + B$ und Ableitungen gleich 0 setzen wird deutlich einfacher.

Beispiel Server-Logfiles

- Wir betrachten Server-Logfiles einer Web-Anwendung, insbesondere die Zeitstempel. Daraus können wir die konsekutiven Abstände berechnen, also die Wartezeit zwischen zwei Aufrufen.
  Wir möchten gerne wissen, mit welcher Wartezeit wir im Mittel rechnen können (um zusammen mit der durchschnittlichen Laufzeit eines Aufrufs zu einer Einschätzung zu kommen, welche Last wir erwarten können).

Beispiel Server-Logfiles

- Wir betrachten Server-Logfiles einer Web-Anwendung, insbesondere die Zeitstempel. Daraus können wir die konsekutiven Abstände berechnen, also die Wartezeit zwischen zwei Aufrufen.
  Wir möchten gerne wissen, mit welcher Wartezeit wir im Mittel rechnen können (um zusammen mit der durchschnittlichen Laufzeit eines Aufrufs zu einer Einschätzung zu kommen, welche Last wir erwarten können).
- Die Wartezeiten sind exponentialverteilt mit Parameter $\lambda > 0$, den wir schätzen wollen. Zur Erinnerung: Die Dichte einer Exponentialverteilung ist $f(x) = \lambda e^{-\lambda x}$ und der Erwartungswert ist $\frac{1}{\lambda}$.

Beispiel Server-Logfiles

Wir betrachten Server-Logfiles (Zeitstempel) und konsekutive Abstände (Wartezeiten zwischen zwei Aufrufen). Die Wartezeiten sind exponentialverteilt mit Parameter $\lambda > 0$, den wir schätzen wollen. Die Dichte ist $f(x) = \lambda e^{-\lambda x}$.
Die Likelihood für eine Stichprobe der Größe N ist $L_x(\lambda) = \prod_{i=1}^{N} \lambda e^{-\lambda x_i}$ und die log-Likelihood ist demnach

$$\ell_x(\lambda) := \log L_x(\lambda) = \left(\sum_{i=1}^{N} \log \lambda - \lambda x_i \right) = n \left(\log \lambda - \lambda \, \mathsf{mean}(x) \right).$$

Beispiel Server-Logfiles (pt. 2)

$$\ell_x(\lambda) := \log L_x(\lambda) = \left(\sum_{i=1}^{N} \log \lambda - \lambda x_i \right) = n \left(\log \lambda - \lambda \mathsf{mean}(x) \right).$$

Die Ableitung nach λ ist einfach $\frac{n}{\lambda} - n\mathsf{mean}(x)$, eine Nullstelle liegt bei $\hat{\lambda} = \frac{1}{\mathsf{mean}(x)}$. Die zweite Ableitung von ℓ_x ist $-\frac{n}{\lambda^2}$, was bei $\hat{\lambda}$ den Wert $-n\mathsf{mean}(x)^2 < 0$ annimmt, also ist $\hat{\lambda}$ ein Maximum und wir haben den Maximum-Likelihood-Schätzer bestimmt.

Beispiel Server-Logfiles (pt. 2)

$$\ell_{\mathrm{x}}(\lambda) := \log \mathrm{L}_{\mathrm{x}}(\lambda) = \left(\sum_{\mathrm{i}=1}^{\mathrm{N}} \log \lambda - \lambda \mathrm{x}_{\mathrm{i}} \right) = \mathrm{n} \left(\log \lambda - \lambda \mathtt{mean}(\mathrm{x}) \right).$$

Die Ableitung nach λ ist einfach $\frac{\mathrm{n}}{\lambda} - \mathrm{n}\mathtt{mean}(\mathrm{x})$, eine Nullstelle liegt bei $\hat{\lambda} = \frac{1}{\mathtt{mean}(\mathrm{x})}$. Die zweite Ableitung von ℓ_{x} ist $-\frac{\mathrm{n}}{\lambda^2}$, was bei $\hat{\lambda}$ den Wert $-\mathrm{n}\mathtt{mean}(\mathrm{x})^2 < 0$ annimmt, also ist $\hat{\lambda}$ ein Maximum und wir haben den Maximum-Likelihood-Schätzer bestimmt.

Wir rechnen also mit einer erwarteten Wartezeit $\mathtt{mean}(\mathrm{x})$ zwischen den Server-Aufrufen, wobei x die beobachteten Wartezeiten sind.

Beispiel k-Means

Der k-Means-Algorithmus kann als Schätzer interpretiert werden: das statistische Modell ist $\mathcal{X} = \mathbb{R}^{nN}$, wenn n die Dimension der Daten ist (also bei 4 reellen Variablen, etwa im Iris-Datensatz, $n = 4$) und N die Stichprobengröße (bei Iris ist $N = 150$).
Der Parameterraum ist $\mathbb{R}^{nk}$ und die Verteilung zu einem Parameter $\theta = (c_1, \ldots, c_k) \in \mathbb{R}^{nk}$ (mit $c_i \in \mathbb{R}^n$) ist ein gemischtes Modell aus multivariaten Normalverteilungen mit Erwartungswert c_i und der $n \times n$-Einheitsmatrix als Kovarianzmatrix.

Beispiel k-Means

Die 'perfekte' k-Means-Lösung, also die Zentroide $(c_1, \ldots, c_k)$, die der k-Means-Algorithmus versucht, zu bestimmen, sind diejenigen, für die die Summe der euklidischen Abstände eines jeden Punktes x_i eines Samples $x \in \mathcal{X}$ minimal sind. Das sind genau die Zentroide, für die die Likelihood der Daten unter der entsprechenden gemischten Verteilung maximal wird.