

Data Science, VL 17

Dr. Konrad Völkel, Sommersemester 2026

23.06.2026

Heinrich Heine
Universität Düsseldorf

Herleitung der PCA

PCA

Principal Component Analysis (PCA, Hauptkomponentenanalyse) ist ein unsupervised Verfahren;
meist sind damit Schritte 1-2 oder auch 1-3 gemeint:

1. (fit) Berechnung einer linearen invertierbaren Koordinatentransformation (einer OrthoNormalBasis) aus Daten

PCA

Principal Component Analysis (PCA, Hauptkomponentenanalyse) ist ein unsupervised Verfahren;
meist sind damit Schritte 1-2 oder auch 1-3 gemeint:

1. (fit) Berechnung einer linearen invertierbaren Koordinatentransformation (einer OrthoNormalBasis) aus Daten
2. (transform) Anwenden der Transformation auf Daten

PCA

Principal Component Analysis (PCA, Hauptkomponentenanalyse) ist ein unsupervised Verfahren;
meist sind damit Schritte 1-2 oder auch 1-3 gemeint:

1. (fit) Berechnung einer linearen invertierbaren Koordinatentransformation (einer OrthoNormalBasis) aus Daten
2. (transform) Anwenden der Transformation auf Daten
3. (Dimensionsreduktion) Projektion der Daten auf einen niedrigdimensionalen linearen Unterraum

PCA

Principal Component Analysis (PCA, Hauptkomponentenanalyse) ist ein unsupervised Verfahren;
meist sind damit Schritte 1-2 oder auch 1-3 gemeint:

1. (fit) Berechnung einer linearen invertierbaren Koordinatentransformation (einer OrthoNormalBasis) aus Daten
2. (transform) Anwenden der Transformation auf Daten
3. (Dimensionsreduktion) Projektion der Daten auf einen niedrigdimensionalen linearen Unterraum

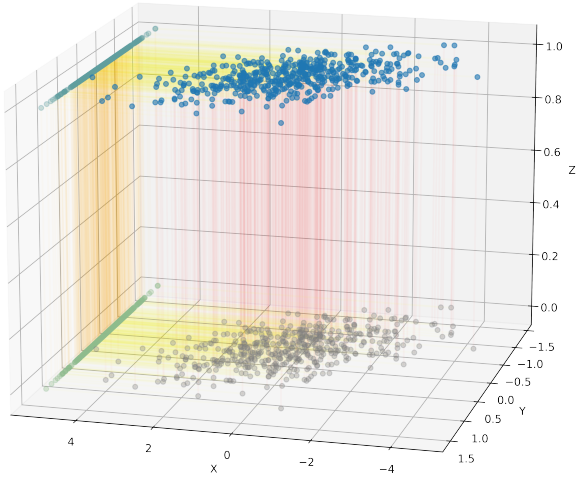
Dabei werden die Daten so transformiert, dass die neuen Koordinatenachsen (sog. Hauptkomponenten/Hauptachsen) geordnet sind danach, wo die Daten die höhere Varianz aufweisen.

Beispiel

(X,Y) ~ N(0,Σ) with ρ=0.37, Constant Z=1

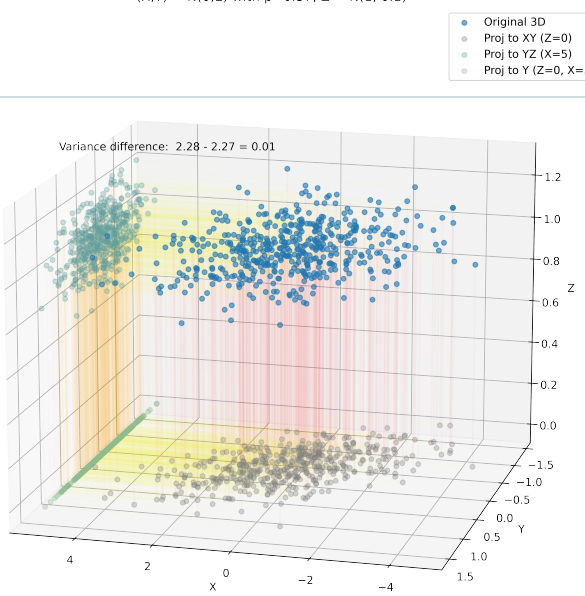
Variance difference: 2.27 - 2.27 = 0.00

(1/2)



Beispiel

(2/2)


(X,Y) ~ N(0,Σ) with ρ=0.37, Z ~ N(1, 0.1)
Original 3D
Proj to XY (Z=0)
Proj to YZ (X=5)
Proj to Y (Z=0, X=5)
Variance difference: 2.28 - 2.27 = 0.01
X
Y
Z

Beispiel

Die vorigen Plots in Worte gefasst

Wenn man Daten im dreidimensionalen Raum hat, bei denen aber die dritte Koordinate z stets 1 ist, so ändert eine Projektion auf die xy-Ebene nichts am Informationsgehalt der Daten.

Beispiel

Die vorigen Plots in Worte gefasst

Wenn man Daten im dreidimensionalen Raum hat, bei denen aber die dritte Koordinate z stets 1 ist, so ändert eine Projektion auf die xy-Ebene nichts am Informationsgehalt der Daten.
Wenn die Daten hingegen in der z-Koordinate geringfügig um die 1 variieren, in den x- und y-Koordinaten aber deutlich stärker variieren, so ändert eine Projektion auf die xy-Ebene nur wenig am Informationsgehalt der Daten.

PCA als Koordinatentransformation

- Eine Koordinatentransformation ist genau die Matrixmultiplikation mit einer invertierbaren Matrix.

PCA als Koordinatentransformation

- Eine Koordinatentransformation ist genau die Matrixmultiplikation mit einer invertierbaren Matrix.
- Die Spalten der Matrix sind die Bilder der Basisvektoren.

PCA als Koordinatentransformation

Heinrich Heine
Universität Düsseldorf

- Eine Koordinatentransformation ist genau die Matrixmultiplikation mit einer invertierbaren Matrix.
- Die Spalten der Matrix sind die Bilder der Basisvektoren.
- Die PCA entspricht einer Orthonormalmatrix, d.h. die Spalten sind normiert und stehen senkrecht aufeinander.

Richtung der größten Varianz

- Ziel der PCA 1)
  Richtung (Vektor, Hauptachse) finden sodass in der Richtung die höchste Varianz vorliegt.

Richtung der größten Varianz

- Ziel der PCA 1)
  Richtung (Vektor, Hauptachse) finden sodass in der Richtung die höchste Varianz vorliegt.
- Ziel der PCA 2)
  Für das Orthogonalkomplement der Hauptachse wiederum PCA.

Richtung der größten Varianz

Heinrich Heine
Universität Düsseldorf

- Ziel der PCA 1)
  Richtung (Vektor, Hauptachse) finden sodass in der Richtung die höchste Varianz vorliegt.
- Ziel der PCA 2)
  Für das Orthogonalkomplement der Hauptachse wiederum PCA.
- Ergebnis:
  Liste mit Hauptachsen (=Matrix), die senkrecht aufeinander stehen (=Orthogonalmatrix).

Richtung der größten Varianz

- Ziel der PCA 1)
  Richtung (Vektor, Hauptachse) finden sodass in der Richtung die höchste Varianz vorliegt.
- Ziel der PCA 2)
  Für das Orthogonalkomplement der Hauptachse wiederum PCA.
- Ergebnis:
  Liste mit Hauptachsen (=Matrix), die senkrecht aufeinander stehen (=Orthogonalmatrix).
- Transformation auf die neue Basis mit dem Inversen dieser Matrix.

Beispiel

Wenn wir ein Sample einer bivariaten Standardnormalverteilung betrachten, können wir einen Kreis um das 95%-Quantil zeichnen. Die Matrix $\begin{pmatrix} 2 & 0 \\ 0 & 1 \end{pmatrix}$ ist eine Streckung auf der x-Achse, die aus dem hübschen Kreis eine langgezogene Ellipse macht. Die Richtung der größten Varianz ist dann genau die x-Achse.

Beispiel

Wenn wir ein Sample einer bivariaten Standardnormalverteilung betrachten, können wir einen Kreis um das 95%-Quantil zeichnen. Die Matrix $\begin{pmatrix} 2 & 0 \\ 0 & 1 \end{pmatrix}$ ist eine Streckung auf der x-Achse, die aus dem hübschen Kreis eine langgezogene Ellipse macht. Die Richtung der größten Varianz ist dann genau die x-Achse.

Wenn eine beliebige invertierbare Matrix $\mathrm{M} = \begin{pmatrix} \mathrm{a} & \mathrm{b} \\ \mathrm{c} & \mathrm{d} \end{pmatrix}$ auf ein Sample einer bivariaten Standardnormalverteilung angewendet wird, dann können wir die Richtungen mit größter Varianz bestimmen als die Richtungen, die von M am stärksten gestreckt werden. Dass wäre ein Vektor v mit $\mathrm{Mv} = \lambda \mathrm{v}$ für das größte solche λ.

Beobachtung

Wenn wir die Kovarianzmatrix einer bivariaten Standardnormalverteilung betrachten, also $\begin{pmatrix} \mathbb{V}(X) & \mathrm{Cov}(X,Y) \\ \mathrm{Cov}(Y,X) & \mathbb{V}(Y) \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$ und dann, wie sich die Kovarianzmatrix eines Samples ändert, wenn wir die Koordinatentransformation $\begin{pmatrix} 2 & 0 \\ 0 & 1 \end{pmatrix}$ durchführen, beobachten wir eine Quadrierung: beim Berechnen der Sample-Kovarianz $\mathrm{Cov}(x,y) = \frac{1}{n}\sum_{i=1}^{n} x_i y_i$ geht die Skalierung mit 2 einfach ein, bei $\mathbb{V}(x) = \mathrm{Cov}(x,x)$ aber quadratisch.

Beobachtung

Wenn wir die Kovarianzmatrix einer bivariaten Standardnormalverteilung betrachten, also $\begin{pmatrix} \mathbb{V}(X) & \mathrm{Cov}(X,Y) \\ \mathrm{Cov}(Y,X) & \mathbb{V}(Y) \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$ und dann, wie sich die Kovarianzmatrix eines Samples ändert, wenn wir die Koordinatentransformation $\begin{pmatrix} 2 & 0 \\ 0 & 1 \end{pmatrix}$ durchführen, beobachten wir eine Quadrierung: beim Berechnen der Sample-Kovarianz $\mathrm{Cov}(x,y) = \frac{1}{n}\sum_{i=1}^{n} x_i y_i$ geht die Skalierung mit 2 einfach ein, bei $\mathbb{V}(x) = \mathrm{Cov}(x,x)$ aber quadratisch.
Wenn wir also die Wurzel aus der neuen Kovarianzmatrix berechnen, erhalten wir die Koordinatentransformation zurück.

Matrixwurzel

Kovarianzmatrizen sind positiv definit und symmetrisch.

Matrixwurzel

Kovarianzmatrizen sind positiv definit und symmetrisch.
Zu jeder positiv definiten symmetrischen Matrix C
existiert eine invertierbare Matrix Σ mit $\Sigma^2 = \mathrm{C}$.

Matrixwurzel

Kovarianzmatrizen sind positiv definit und symmetrisch.
Zu jeder positiv definiten symmetrischen Matrix C
existiert eine invertierbare Matrix Σ mit $\Sigma^2 = C$.

Eine quadratische Matrix C heisst
symmetrisch, wenn $C = C^T$ und
positiv definit, wenn alle Eigenwerte positiv sind.

Äquivalent: C positiv definit wenn für alle $v \neq 0$ gilt dass $v^T Cv > 0$ ist.

Zutaten zusammensetzen

Wir stellen uns jetzt vor, dass die Daten X aus einer Standardnormalverteilung Y durch eine Koordinatentransformation A hervorgehen.

- Können wir aus $X = AY$ etwa A oder Y zurückgewinnen?
  Was sind die Hauptkomponenten?

Zutaten zusammensetzen

Heinrich Heine
Universität Düsseldorf

Wir stellen uns jetzt vor, dass die Daten X aus einer Standardnormalverteilung Y durch eine Koordinatentransformation A hervorgehen.

- Können wir aus $X = AY$ etwa A oder Y zurückgewinnen?
  Was sind die Hauptkomponenten?
- Die empirische Kovarianzmatrix schätzt die Kovarianzmatrix C ein, deren Wurzel A ist, also $A^2 = C$.

Zutaten zusammensetzen

Heinrich Heine Universität Düsseldorf

Wir stellen uns jetzt vor, dass die Daten X aus einer Standardnormalverteilung Y durch eine Koordinatentransformation A hervorgehen.

- Können wir aus $X = AY$ etwa A oder Y zurückgewinnen?
  Was sind die Hauptkomponenten?
- Die empirische Kovarianzmatrix schätzt die Kovarianzmatrix C ein, deren Wurzel A ist, also $A^2 = C$.
- Wir berechnen den größten Eigenwert von A und einen zugehörigen Eigenvektor v.

Zutaten zusammensetzen

Heinrich Heine Universität Düsseldorf

Wir stellen uns jetzt vor, dass die Daten X aus einer Standardnormalverteilung Y durch eine Koordinatentransformation A hervorgehen.

- Können wir aus $X = AY$ etwa A oder Y zurückgewinnen?
  Was sind die Hauptkomponenten?
- Die empirische Kovarianzmatrix schätzt die Kovarianzmatrix C ein, deren Wurzel A ist, also $A^2 = C$.
- Wir berechnen den größten Eigenwert von A und einen zugehörigen Eigenvektor v.
- Das ist die Richtung der größten Varianz in den Daten!

Zutaten zusammensetzen

Heinrich Heine Universität Düsseldorf

Wir stellen uns jetzt vor, dass die Daten X aus einer Standardnormalverteilung Y durch eine Koordinatentransformation A hervorgehen.

- Können wir aus $X = AY$ etwa A oder Y zurückgewinnen?
  Was sind die Hauptkomponenten?
- Die empirische Kovarianzmatrix schätzt die Kovarianzmatrix C ein, deren Wurzel A ist, also $A^2 = C$.
- Wir berechnen den größten Eigenwert von A und einen zugehörigen Eigenvektor v.
- Das ist die Richtung der größten Varianz in den Daten!
- Es ist auch ein Eigenvektor zum größten Eigenwert von A^2.

Letzter Schritt

Wenn die Daten nicht normalverteilt sind (oder nur A unbekannt ist), können wir das gleiche machen:

Letzter Schritt

Wenn die Daten nicht normalverteilt sind (oder nur A unbekannt ist), können wir das gleiche machen:
Einen Eigenvektor zum größten Eigenwert von der empirischen Kovarianzmatrix C bestimmen.

Letzter Schritt

Wenn die Daten nicht normalverteilt sind (oder nur A unbekannt ist), können wir das gleiche machen:
Einen Eigenvektor zum größten Eigenwert von der empirischen Kovarianzmatrix C bestimmen.
Schön: Das ist immer die Richtung der größten Varianz in den Daten.

Anderer Zugang: Optimierung

Die Richtung größter Varianz lässt sich auch finden als die Gerade, welche die Summe der quadrierten Abstände der Daten zur Gerade minimiert.

Anderer Zugang: Optimierung

Die Richtung größter Varianz lässt sich auch finden als die Gerade, welche die Summe der quadrierten Abstände der Daten zur Gerade minimiert.
Das ist äquivalent zum Minimieren des MSE. Erinnerung: das konstante Modell, welches den MSE minimiert, ist `mean`.
Die erste Hauptkomponente ist also das beste lineare Modell aus der MSE-Perspektive.

Anderer Zugang: Optimierung

Die Richtung größter Varianz lässt sich auch finden als die Gerade, welche die Summe der quadrierten Abstände der Daten zur Gerade minimiert.
Das ist äquivalent zum Minimieren des MSE. Erinnerung: das konstante Modell, welches den MSE minimiert, ist `mean`.
Die erste Hauptkomponente ist also das beste lineare Modell aus der MSE-Perspektive.

(im Skript ist eine Animation dazu)

Ab jetzt ins Notebook!



Heinrich Heine
Universität Düsseldorf

Vielen Dank für Ihre Aufmerksamkeit!