

Data Science, VL 19

Dr. Konrad Völkel, Sommersemester 2026

25.06.2026

Regression und Klassifikation

Klassifikation

Heinrich Heine
Universität Düsseldorf

Klassifikation ist ein Oberbegriff für Supervised Learning Methoden, bei denen die Zielvariable / die Label kategorial verteilt (nominal skaliert) sind.

Klassifikation

Heinrich Heine
Universität Düsseldorf

Klassifikation ist ein Oberbegriff für Supervised Learning Methoden, bei denen die Zielvariable / die Label kategorial verteilt (nominal skaliert) sind.

Ziel ist, aus einem Trainingsdatensatz (mit gegebenen Labels) den Zusammenhang zwischen allen anderen Variablen mit den Labels zu 'lernen', um so für neue Daten (ohne Labels) das Label vorherzusagen / zu schätzen.

Klassifikation

Heinrich Heine
Universität Düsseldorf

Klassifikation ist ein Oberbegriff für Supervised Learning Methoden, bei denen die Zielvariable / die Label kategorial verteilt (nominal skaliert) sind.

Ziel ist, aus einem Trainingsdatensatz (mit gegebenen Labels) den Zusammenhang zwischen allen anderen Variablen mit den Labels zu 'lernen', um so für neue Daten (ohne Labels) das Label vorherzusagen / zu schätzen.

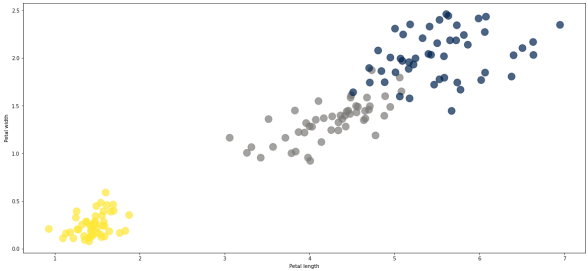
Um zu evaluieren, wie gut das 'lernen' geklappt hat, behalte einen Teil der Daten mit Label (train-test-split), vergleiche Vorhersage mit 'ground truth'.

Beispiel zur Klassifikation

Anhand der Blütenblattlänge (petal length) wollen wir die Iris-Spezies 'Setosa' (0) und 'Versicolor' (1) unterscheiden.

Beispiel zur Klassifikation

Anhand der Blütenblattlänge (petal length) wollen wir die Iris-Spezies 'Setosa' (0) und 'Versicolor' (1) unterscheiden.
Variable: eine reelle Zahl, die Blütenblattlänge (petal length).
Ziel/Label: 0 oder 1 ($\rightarrow$ binäre Klassifikation)



Beispiel zur Klassifikation

Anhand der Blütenblattlänge (petal length) wollen wir die Iris-Spezies 'Setosa' (0) und 'Versicolor' (1) unterscheiden.
Variable: eine reelle Zahl, die Blütenblattlänge (petal length).
Ziel/Label: 0 oder 1 ($\rightarrow$ binäre Klassifikation)

Aus einer Stichprobe 'lernen' wir z.B. dass Setosa Blütenblätter von Länge < 2 hat, Versicolor hingegen meist Länge > 3.

Möglicher Klassifikator: $\texttt{prediction} = [\texttt{petal_length} < 2.5]$

Klassifikation vs. Clustering

Während mit Klassifikation stets Supervised Learning, also bekannte Ziel-Variable mit vorliegenden Labels in Trainingsdaten gemeint ist,

ist Clustering eine Zuordnung zu Gruppen, die nicht in den Daten vorliegt.

Klassifikation vs. Clustering

Während mit Klassifikation stets Supervised Learning, also bekannte Ziel-Variable mit vorliegenden Labels in Trainingsdaten gemeint ist,

ist Clustering eine Zuordnung zu Gruppen, die nicht in den Daten vorliegt.

Beim Clustering 'erfindet' man also Label bzw. die Labelvariable zählt nicht zu den beobachtbaren Variablen sondern ist latent (= nicht beobachtbar).
Clustering ist also Unsupervised Learning.

Klassifikation vs. Clustering

Während mit Klassifikation stets Supervised Learning, also bekannte Ziel-Variable mit vorliegenden Labels in Trainingsdaten gemeint ist,

ist Clustering eine Zuordnung zu Gruppen, die nicht in den Daten vorliegt.

Beim Clustering 'erfindet' man also Label bzw. die Labelvariable zählt nicht zu den beobachtbaren Variablen sondern ist latent (= nicht beobachtbar).
Clustering ist also Unsupervised Learning.

Supervised Learning ist viel einfacher zu evaluieren:
Unterschied Vorhersage/Ground Truth.

Regression

Regression ist ein Oberbegriff für Supervised Learning Methoden.

Regression

Regression ist ein Oberbegriff für Supervised Learning Methoden.

Ziel ist, aus einem Trainingsdatensatz (mit gegebenen Labels) den Zusammenhang zwischen allen anderen Variablen mit den Labels zu 'lernen', um so für neue Daten (ohne Labels) das Label vorherzusagen / zu schätzen.

Regression

Regression ist ein Oberbegriff für Supervised Learning Methoden.

Ziel ist, aus einem Trainingsdatensatz (mit gegebenen Labels) den Zusammenhang zwischen allen anderen Variablen mit den Labels zu 'lernen', um so für neue Daten (ohne Labels) das Label vorherzusagen / zu schätzen.

Um zu evaluieren, wie gut das 'lernen' geklappt hat, behalte einen Teil der Daten mit Label (train-test-split), vergleiche Vorhersage mit 'ground truth'.

Regression als Verallgemeinerung der Klassifikation

Heinrich Heine Universität Düsseldorf

Regression ist ein Oberbegriff für Supervised Learning Methoden.
→ Meist sind die Label kardinal skaliert, wenn man von Regression spricht.

Ziel ist, aus einem Trainingsdatensatz (mit gegebenen Labels) den Zusammenhang zwischen allen anderen Variablen mit den Labels zu 'lernen', um so für neue Daten (ohne Labels) das Label vorherzusagen / zu schätzen.

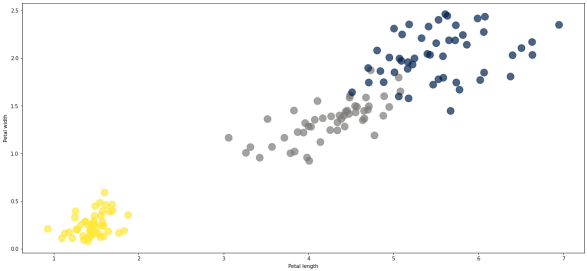
Um zu evaluieren, wie gut das 'lernen' geklappt hat, behalte einen Teil der Daten mit Label (train-test-split), vergleiche Vorhersage mit 'ground truth'.

Beispiel zur Regression

Anhand der Blütenblattlänge (petal length) wollen wir die Blütenblattbreite (petal width) vorhersagen.

Beispiel zur Regression

Anhand der Blütenblattlänge (petal length) wollen wir die Blütenblattbreite (petal width) vorhersagen.
Variable: eine reelle Zahl, die Blütenblattlänge (petal length).
Ziel/Label: die Blütenblattbreite (petal width).



Beispiel zur Regression

Heinrich Heine
Universität Düsseldorf

Anhand der Blütenblattlänge (petal length) wollen wir die Blütenblattbreite (petal width) vorhersagen.
Variable: eine reelle Zahl, die Blütenblattlänge (petal length).
Ziel/Label: die Blütenblattbreite (petal width).

Aus einer Stichprobe 'lernen' wir z.B. dass die Breite ungefähr die halbe Länge minus 1 ist.

Möglicher Prädiktor: $\texttt{predicted_petal_width} = \texttt{petal_length} * 0.5 - 1$

Regressionsmodell, formal (Herleitung)

Im Beispiel
$\texttt{predicted_petal_width} = \texttt{petal_length} * 0.5 - 1$
haben wir gesehen:

Vorhersage der Zielgröße = Funktion angewandt auf Einflussgröße

Regressionsmodell, formal (Herleitung)

Im Beispiel
$\texttt{predicted_petal_width} = \texttt{petal_length} * 0.5 - 1$
haben wir gesehen:

Vorhersage der Zielgröße = Funktion angewandt auf Einflussgröße

Parameter aus den Daten geschätzt, hier 0.5 und -1

Regressionsmodell, formal (Herleitung)

Im Beispiel
$\texttt{predicted_petal_width} = \texttt{petal_length} * 0.5 - 1$
haben wir gesehen:

Vorhersage der Zielgröße = Funktion angewandt auf Einflussgröße

Parameter aus den Daten geschätzt, hier 0.5 und -1

Dabei haben wir nicht perfekt geschätzt, es gibt einen Fehler
$\epsilon := \texttt{predicted_petal_width} - \texttt{petal_width}$

Regressionsmodell, formal

Heinrich Heine
Universität Düsseldorf

Ein Regressionsmodell besteht aus:

- Regressoren $\mathrm{X} = (\mathrm{X}_1, \ldots, \mathrm{X}_\mathrm{k})$, die 'unabhängige' Einflussgröße(n)
- Regressand Y, die 'abhängige' Zielgröße
- Parametern $\beta = (\beta_1, \ldots, \beta_\mathrm{l})$
- Störgröße ϵ
- $\mathrm{Y} = \mathrm{f}(\mathrm{X}; \beta) + \epsilon$ ist das eigentliche Modell.

Regressionsmodell, formal

Ein Regressionsmodell besteht aus:

- Regressoren $X = (X_1, \ldots, X_k)$, die 'unabhängige' Einflussgröße(n)
- Regressand Y, die 'abhängige' Zielgröße
- Parametern $\beta = (\beta_1, \ldots, \beta_l)$
- Störgröße ϵ
- $Y = f(X; \beta) + \epsilon$ ist das eigentliche Modell.

Für eine konkrete Stichprobe haben wir Instanzen $x_1, \ldots, x_N$ und Label $y_1, \ldots, y_N$, wobei x_{ij} der Wert von X_j bei Instanz i ist.

Regressionsmodell, formal

Heinrich Heine Universität Düsseldorf

Ein Regressionsmodell besteht aus:

- Regressoren $X = (X_1, \ldots, X_k)$, die 'unabhängige' Einflussgröße(n)
- Regressand Y, die 'abhängige' Zielgröße
- Parametern $\beta = (\beta_1, \ldots, \beta_l)$
- Störgröße ϵ
- $Y = f(X; \beta) + \epsilon$ ist das eigentliche Modell.

Für eine konkrete Stichprobe haben wir Instanzen $x_1, \ldots, x_N$ und Label $y_1, \ldots, y_N$, wobei x_{ij} der Wert von X_j bei Instanz i ist.
Die Vorhersage $y_i^{pred} := f(x_i; \beta)$ hängt von den Parametern ab.
Die Instanzen von ϵ sind die Residuen $\epsilon_i = y_i - y_i^{pred}$.

Regression als Schätzer

Heinrich Heine
Universität Düsseldorf

Gegeben eine Stichprobe von X, schätzen wir Parameter β um eine möglichst gute Vorhersage für Y zu erhalten.

- Die Regressionsmodelle unterscheiden sich in der Funktion f.
- Eine Regressionsanalyse durchführen heißt, ein Modell (d.h. eine Funktion f und damit eine Anzahl Parameter) festzulegen und dann eine Schätzung für die Parameter aus der Stichprobe zu berechnen.
- Meist soll β so gewählt werden, dass y_i^{pred} möglichst 'oft nah dran' ist an y_i.

Regression als Schätzer

Heinrich Heine Universität Düsseldorf

Gegeben eine Stichprobe von X, schätzen wir Parameter β um eine möglichst gute Vorhersage für Y zu erhalten.

- Die Regressionsmodelle unterscheiden sich in der Funktion f.
- Eine Regressionsanalyse durchführen heißt, ein Modell (d.h. eine Funktion f und damit eine Anzahl Parameter) festzulegen und dann eine Schätzung für die Parameter aus der Stichprobe zu berechnen.
- Meist soll β so gewählt werden, dass y_i^{pred} möglichst 'oft nah dran' ist an y_i.
- Beispiel: wenn β nur ein einzelner Parameter ist, und $f(x;\beta) = \beta$ die konstante Funktion, dann ist $Y = \beta + \epsilon$ das Modell (ein konstantes Modell).
  Mögliche Lösung: $\beta =$ `mean(X)`.

Achtung: Begriffe anderswo

- Eigentlich Klassifikation als Spezialfall der Regression
  Oftmals Regression = stetig vs. Klassifikation = diskret.

Achtung: Begriffe anderswo

- Eigentlich Klassifikation als Spezialfall der Regression
  Oftmals Regression = stetig vs. Klassifikation = diskret.
- Regression ganz allgemein, irgendein Modell mit Funktion f
  Oftmals Regression = lineare Regression, d.h. f ist eine lineare Funktion

Achtung: Begriffe anderswo

- Eigentlich Klassifikation als Spezialfall der Regression
  Oftmals Regression = stetig vs. Klassifikation = diskret.
- Regression ganz allgemein, irgendein Modell mit Funktion f
  Oftmals Regression = lineare Regression, d.h. f ist eine lineare Funktion
- Regression in vielen Dimensionen
  Oftmals Regression = in einer Dimension, Ergebnis ist eine Regressionsgerade.

Unsupervised Regression?!

Heinrich Heine
Universität Düsseldorf

So wie das Clustering die 'unsupervised Version' der Klassifikation ist, was ist die 'unsupervised Version' der Regression?

Unsupervised Regression?!

So wie das Clustering die 'unsupervised Version' der Klassifikation ist, was ist die 'unsupervised Version' der Regression?
→ Das Berechnen einer neuen (z.B. stetigen) Variable aus den alten.
Das ist eine Form von Feature Engineering.

Unsupervised Regression?!

So wie das Clustering die 'unsupervised Version' der Klassifikation ist, was ist die 'unsupervised Version' der Regression?
→ Das Berechnen einer neuen (z.B. stetigen) Variable aus den alten. Das ist eine Form von Feature Engineering.

Das 'ultimative' unsupervised learning ist das Lernen der Verteilung, um so neue Samples generieren zu können.

Unsupervised Regression?!

Heinrich Heine
Universität Düsseldorf

So wie das Clustering die 'unsupervised Version' der Klassifikation ist, was ist die 'unsupervised Version' der Regression?
→ Das Berechnen einer neuen (z.B. stetigen) Variable aus den alten.
Das ist eine Form von Feature Engineering.

Das 'ultimative' unsupervised learning ist das Lernen der Verteilung, um so neue Samples generieren zu können.
Das ist mehr als nur Parameterschätzen:
auch das Modell muss gewählt werden (→ model selection).



Heinrich Heine
Universität Düsseldorf

Vielen Dank für Ihre Aufmerksamkeit!