Data Science: Statistische Tests, Signifikanz

Dr. Konrad Völkel, Sommersemester 2026

Tests

In der explorativen Analyse

In der Kommunikation von Ergebnissen

Tests

Heinrich Heine
Universität Düsseldorf

In der explorativen Analyse:

Ist Attribut X normalverteilt?

Haben die Stichproben A und B bei Attribut X die gleiche Verteilung? Die gleichen Mittelwerte?

In der Kommunikation von Ergebnissen

Tests

In der explorativen Analyse:

Ist Attribut X normalverteilt?

Haben die Stichproben A und B bei Attribut X die gleiche Verteilung? Die gleichen Mittelwerte?

In der Kommunikation von Ergebnissen:

“Der Test zeigt, dass die Gruppen unterschiedlich verteilt sind, daher verwenden wir ein gemischtes Modell”

Sprechen über Gewissheit

mal was anderes als Wahrscheinlichkeit



“The oracle of Delphi strikes back”

Prognose ohne Intervall

Globale Erwärmung, Projektion

Rechts:

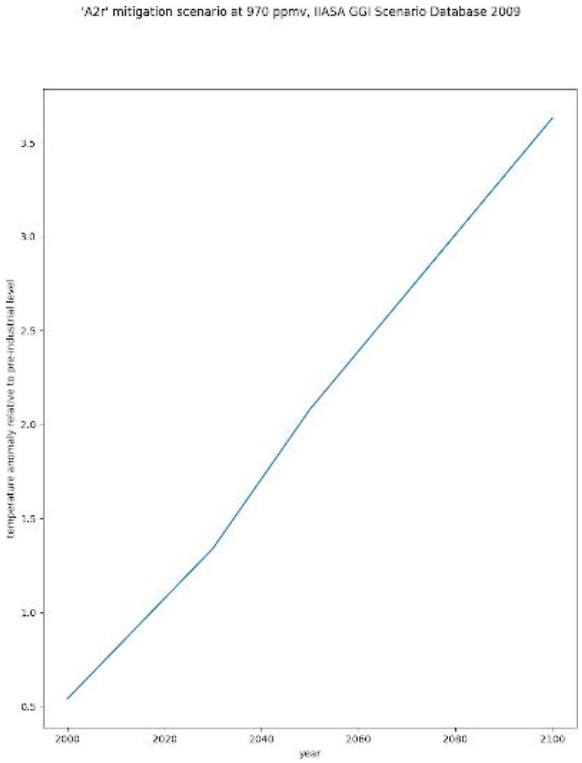
Vorhersage der globalen Erwärmung

(unter der Voraussetzung,
dass der CO_2-Gehalt der Atmosphäre
auf 970 ppmv steigt.)

Kontext:

1900 war 296 ppmv CO_2,

2022 war 421 ppmv CO_2



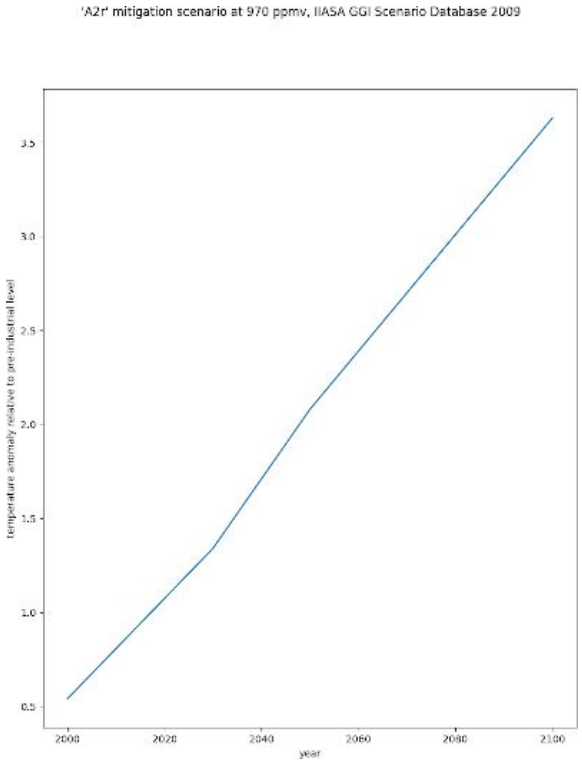
Prognose ohne Intervall

Globale Erwärmung, Projektion

Rechts:

Vorhersage der globalen Erwärmung

(unter der Voraussetzung,
dass der CO_2-Gehalt der Atmosphäre
auf 970 ppmv steigt.)



Kritik:

Kann so kommen,
kann auch anders kommen.

Man kann nicht wissen,
was letztlich passieren wird.

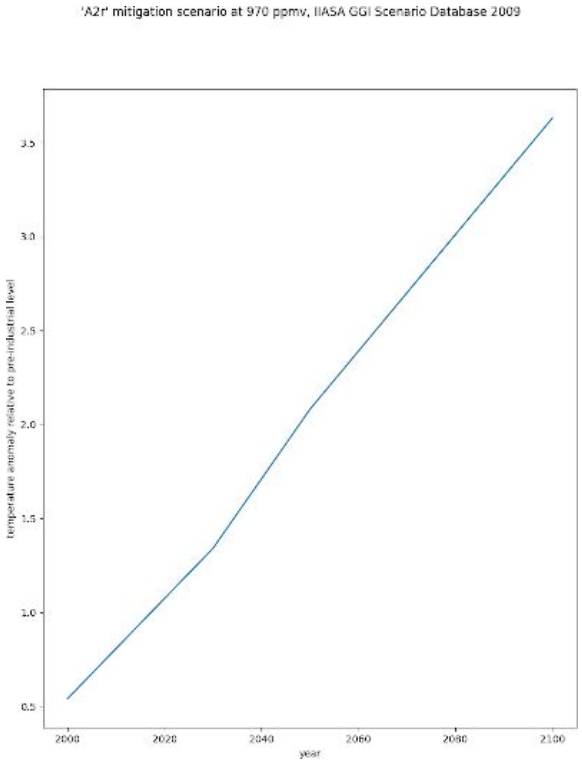
Prognose ohne Intervall

Globale Erwärmung, Projektion

Rechts:

Vorhersage der globalen Erwärmung

(unter der Voraussetzung,
dass der CO_2-Gehalt der Atmosphäre
auf 970 ppmv steigt.)



Kritik:

Kann so kommen,
kann auch anders kommen.

~~**Man kann nicht wissen,**~~
~~**was letztlich passieren wird.**~~

Prognose mit Intervall

Heinrich Heine Universität Düsseldorf

Globale Erwärmung, Projektion

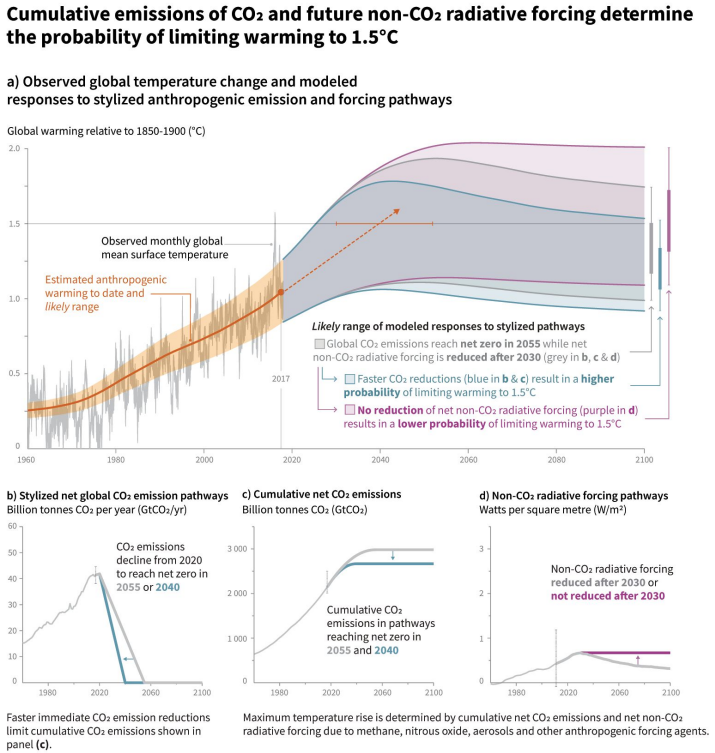
Kritik:

Man kann nicht wissen,
was letztlich passieren wird.

Antwort:

Man kann schätzen,
was passieren wird und
dabei **Gewissheit quantifizieren**
und visualisieren.

Rechts: Globale Erwärmung, Projektion
(IPCC SR15, Figure 1)



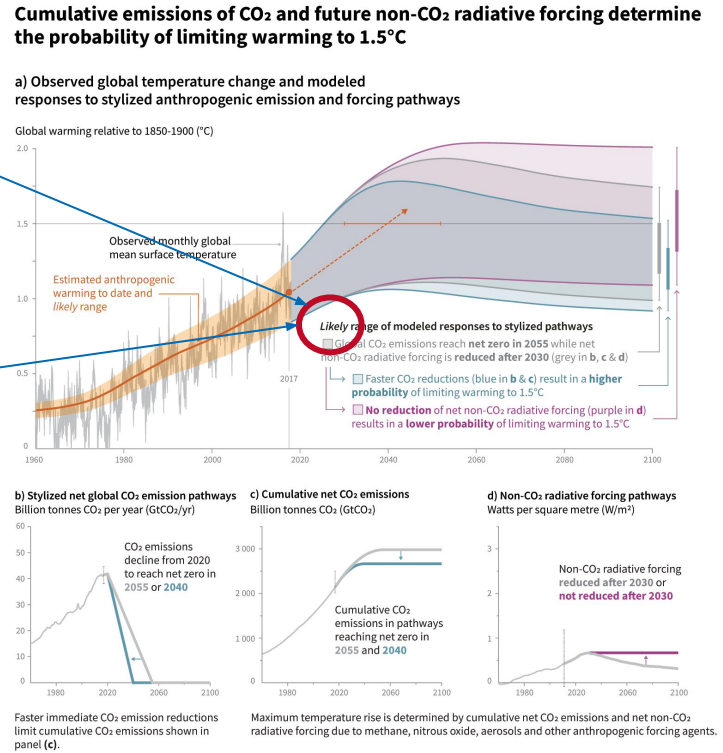
Kommunikation von Gewissheit(en)

Heinrich Heine Universität Düsseldorf

Calibrated Language

Table 1. Likelihood Scale	
Term*	**Likelihood of the Outcome**
Virtually certain	99-100% probability
Very likely	90-100% probability
Likely	66-100% probability
About as likely as not	33 to 66% probability
Unlikely	0-33% probability
Very unlikely	0-10% probability
Exceptionally unlikely	0-1% probability

* Additional terms that were used in limited circumstances in the AR4 (*extremely likely* – 95-100% probability, *more likely than not* – >50-100% probability, and *extremely unlikely* – 0-5% probability) may also be used in the AR5 when appropriate.



Statistische Tests

Entscheidungen mit Konfidenz



“C3PO weighing apples”

Statistische Tests

Definitionen

Gegeben ein statistisches Modell

$$(\mathcal{X}, P_\theta : \theta \in \Theta)$$

und eine disjunkte Zerlegung

$$\Theta = \Theta_0 \cup \Theta_1$$

in **Nullhypothese** $H_0 = (\theta \in \Theta_0)$

und **Alternative** $H_1 = (\theta \in \Theta_1)$

heißt jede Statistik $\phi : \mathcal{X} \to [0,1]$

ein **Test** von H_0 gegen H_1.

Statistische Tests

Definitionen

Gegeben ein statistisches Modell

$$(\mathcal{X}, P_\theta : \theta \in \Theta)$$

und eine disjunkte Zerlegung

$$\Theta = \Theta_0 \cup \Theta_1$$

in **Nullhypothese** $H_0 = (\theta \in \Theta_0)$

und **Alternative** $H_1 = (\theta \in \Theta_1)$

heißt jede Statistik $\phi : \mathcal{X} \to [0,1]$

ein **Test** von H_0 gegen H_1.

Beispiel:

Wir messen das Gewicht von Äpfeln, angenommen normalverteilt.

Die Äpfel sollen im Mittel 200g wiegen.

Nullhypothese:

die Äpfel wiegen im Mittel 150g oder weniger.

Alternative:

die Äpfel wiegen im Mittel mehr als 150g.

Test:

$\phi(x) = 0$ wenn $x/n \leq 150$, sonst $\phi(x) = 1$.

Statistische Tests

Definitionen

Gegeben ein statistisches Modell

$$(\mathcal{X}, P_\theta : \theta \in \Theta)$$

und eine disjunkte Zerlegung

$$\Theta = \Theta_0 \cup \Theta_1$$

in **Nullhypothese** $H_0 = (\theta \in \Theta_0)$

und **Alternative** $H_1 = (\theta \in \Theta_1)$

heißt jede Statistik $\phi : \mathcal{X} \to [0,1]$

ein **Test** von H_0 gegen H_1.

Beispiel:

Wir messen das Gewicht von Äpfeln, angenommen normalverteilt.

Die Äpfel sollen im Mittel 200g wiegen.

Nullhypothese:

die Äpfel wiegen im Mittel 150g oder weniger.

Alternative:

die Äpfel wiegen im Mittel mehr als 150g.

Ein anderer Test:

$\phi(x) = 0$ wenn $x/n \leq 160$, sonst $\phi(x) = 1$.

Statistische Tests

Definitionen

Gegeben ein statistisches Modell

$$(\mathcal{X}, P_\theta : \theta \in \Theta)$$

und eine disjunkte Zerlegung

$$\Theta = \Theta_0 \cup \Theta_1$$

in **Nullhypothese** $H_0 = (\theta \in \Theta_0)$

und **Alternative** $H_1 = (\theta \in \Theta_1)$

heißt jede Statistik $\phi : \mathcal{X} \to [0,1]$

ein **Test** von H_0 gegen H_1.

Anderes Beispiel:

Wir messen das Gewicht von Äpfeln, angenommen normalverteilt.

Die Äpfel sollen im Mittel 200g wiegen.

Nullhypothese:

die Äpfel wiegen im Mittel 150g.

Alternative:

die Äpfel wiegen im Mittel mehr oder weniger.

Ein besserer Test:

$\phi(x) = 0$ wenn 150 in einem Konfidenzintervall um x/n liegt, sonst $\phi(x) = 1$

Statistische Tests

Definitionen

Gegeben ein statistisches Modell

$$(\mathcal{X}, P_\theta : \theta \in \Theta)$$

und eine disjunkte Zerlegung

$$\Theta = \Theta_0 \cup \Theta_1$$

in **Nullhypothese** $H_0 = (\theta \in \Theta_0)$

und **Alternative** $H_1 = (\theta \in \Theta_1)$

heißt jede Statistik $\phi : \mathcal{X} \to [0,1]$

ein **Test** von H_0 gegen H_1.

Fehler 1. Art ist $\phi(x)=1$ obwohl H_0 gilt,

Fehler 2. Art ist $\phi(x)=0$ obwohl H_1 gilt.

Statistische Tests

Definitionen

Gegeben ein statistisches Modell

$$(\mathcal{X}, P_\theta : \theta \in \Theta)$$

und eine disjunkte Zerlegung

$$\Theta = \Theta_0 \cup \Theta_1$$

in **Nullhypothese** $H_0 = (\theta \in \Theta_0)$

und **Alternative** $H_1 = (\theta \in \Theta_1)$

heißt jede Statistik $\phi : \mathcal{X} \to [0,1]$

ein **Test** von H_0 gegen H_1.

Fehler 1. Art ist $\phi(x)=1$ obwohl H_0 gilt,

Fehler 2. Art ist $\phi(x)=0$ obwohl H_1 gilt.

Die Wahrscheinlichkeit, einen Fehler 1. Art zu machen, heißt effektives **Niveau** α.

Für $\theta \in \Theta_1$ heißt 1 - die Wahrscheinlichkeit für einen Fehler 2. Art auch **Macht** (power) von ϕ.

Statistische Tests

Definitionen

Gegeben ein statistisches Modell

$$(\mathcal{X}, P_\theta : \theta \in \Theta)$$

und eine disjunkte Zerlegung

$$\Theta = \Theta_0 \cup \Theta_1$$

in **Nullhypothese** $H_0 = (\theta \in \Theta_0)$

und **Alternative** $H_1 = (\theta \in \Theta_1)$

heißt jede Statistik $\phi : \mathcal{X} \to [0,1]$

ein **Test** von H_0 gegen H_1.

Fehler 1. Art ist $\phi(x)=1$ obwohl H_0 gilt,

Fehler 2. Art ist $\phi(x)=0$ obwohl H_1 gilt.

Die Wahrscheinlichkeit, einen Fehler 1. Art zu machen, heißt effektives **Niveau** α.

Für $\theta \in \Theta_1$ heißt 1 - die Wahrscheinlichkeit für einen Fehler 2. Art auch **Macht** (power) von ϕ.

ϕ heißt **gleichmäßig bester Test** zum Niveau α, wenn er effektives Niveau $\leq \alpha$ hat und jeder andere solche Test höchstens gleich mächtig ist.

Statistische Tests

Beste einfache Tests

Gegeben ein statistisches Modell

$$(\mathcal{X}, P_\theta : \theta \in \Theta)$$

mit $\Theta_0 = \{\theta_0\}$ und $\Theta_1 = \{\theta_1\}$, sodass $\Theta = \Theta_0 \cup \Theta_1$,
spricht man von einer **einfachen Hypothese**.

Statistische Tests

Heinrich Heine
Universität Düsseldorf

Der beidseitige Test auf Erwartungswerte von Normalverteilungen

$X \sim \mathcal{N}(\mu, \sigma^2)$

Der z-Test:

Betrachte σ als bekannt,
etwa $\sigma = \sigma^*(x)$ für große Stichproben,

aber μ ist unbekannt.

Nullhypothese: $\mu = \mu_0$

z-Statistik: $$Z(x) = \frac{\mathbf{mean}(x) - \mu_0}{\sigma/\sqrt{n}}$$

Finde z sodass $P(Z \leq z) = 1 - \alpha/2$

bzw. $P(-z \leq Z \leq z) = 1 - \alpha$.

Wenn $Z(x) \leq -z$ oder $z \leq Z(x)$, verwerfe H_0.

Statistische Tests

Der beidseitige Test auf Erwartungswerte von Normalverteilungen

$X \sim \mathcal{N}(\mu, \sigma^2)$

Der z-Test:

Betrachte σ als bekannt,
etwa σ = σ*(x) für große Stichproben,

aber μ ist unbekannt.

Nullhypothese: $\mu = \mu_0$

z-Statistik: $$Z(x) = \frac{\mathbf{mean}(x) - \mu_0}{\sigma/\sqrt{n}}$$

Finde z sodass P(Z ≤ z) = 1 - α/2
bzw. P(-z ≤ Z ≤ z) = 1 - α.

Wenn Z(x) ≤ -z oder z ≤ Z(x), verwerfe H_0.

Der t-Test:

Betrachte σ als unbekannt,
Berücksichtige Samplingfehler beim Schätzen von σ mit σ*(x).

Nullhypothese: $\mu = \mu_0$

t-Statistik: $$t(x) = \frac{\mathbf{mean}(x) - \mu_0}{\sigma^*(x)/\sqrt{n}}$$

Finde t sodass P(T ≤ t) = 1 - α/2
bzw. P(-t ≤ T ≤ t) = 1 - α.

Wenn T(x) ≤ -t oder t ≤ T(x), verwerfe H_0.

Statistische Tests

Der beidseitige Test auf Erwartungswerte von Normalverteilungen

Mit **Scipy.stats**:

```
scipy.stats.ttest_1samp(x, mu)
```

Der t-Test für $X \sim \mathcal{N}(\mu, \sigma^2)$:

Betrachte σ als unbekannt,

Berücksichtige Samplingfehler beim Schätzen von σ mit σ*(x).

Nullhypothese: $\mu = \mu_0$

t-Statistik: $t(x) = \frac{\mathbf{mean}(x) - \mu_0}{\sigma^*(x)/\sqrt{n}}$

Finde t sodass $P(T \leq t) = 1 - \alpha/2$

bzw. $P(-t \leq T \leq t) = 1 - \alpha$.

Wenn $T(x) \leq -t$ oder $t \leq T(x)$, verwerfe H_0.

Statistische Tests

Der beidseitige Test auf Erwartungswerte von Normalverteilungen

Mit **Scipy.stats**:

```
scipy.stats.ttest_1samp(x, mu)
```

Returns a test result object with attributes:

- **statistic**, the t-statistic
- **pvalue**,
- **df**, degrees of freedom
- **confidence_interval**(level=0.95)

Der t-Test für $X \sim \mathcal{N}(\mu, \sigma^2)$:

Betrachte σ als unbekannt,

Berücksichtige Samplingfehler beim Schätzen von σ mit σ*(x).

Nullhypothese: $\mu = \mu_0$

t-Statistik: $t(x) = \dfrac{\mathbf{mean}(x) - \mu_0}{\sigma^*(x)/\sqrt{n}}$

Finde t sodass $P(T \leq t) = 1 - \alpha/2$

bzw. $P(-t \leq T \leq t) = 1 - \alpha$.

Wenn $T(x) \leq -t$ oder $t \leq T(x)$, verwerfe H_0.

Statistische Tests

Der beidseitige Test auf Erwartungswerte von Normalverteilungen

Mit **Scipy.stats**:

```
scipy.stats.ttest_1samp(x, mu)
```

Returns a test result object with attributes:

- **statistic**, the t-statistic
- **pvalue**,
- **df**, degrees of freedom
- **confidence_interval**(level=0.95)

pvalue: $p = P(\text{“D”}|H_0) = P(|T| \leq t \mid H_0)$

Wenn $p < \alpha$, verwerfe H_0

Der t-Test für $X \sim \mathcal{N}(\mu, \sigma^2)$:

Betrachte σ als unbekannt,

Berücksichtige Samplingfehler beim Schätzen von σ mit σ*(x).

Nullhypothese: $\mu = \mu_0$

t-Statistik: $t(x) = \frac{\mathbf{mean}(x) - \mu_0}{\sigma^*(x)/\sqrt{n}}$

Finde t sodass $P(T \leq t) = 1 - \alpha/2$

bzw. $P(-t \leq T \leq t) = 1 - \alpha$.

Wenn $T(x) \leq -t$ oder $t \leq T(x)$, verwerfe H_0.

Statistische Tests

Der beidseitige Test auf Erwartungswerte von Normalverteilungen

Mit **Scipy.stats**:

```
scipy.stats.ttest_1samp(x, mu)
```

Returns a test result object with attributes:

- **statistic**, the t-statistic
- **pvalue**,
- **df**, degrees of freedom
- **confidence_interval**(level=0.95)

pvalue: $p = P(\text{“D”}|H_0) = P(T \leq t \mid H_0)$

Wenn $p < \alpha$, verwerfe H_0

Der t-Test für $X \sim \mathcal{N}(\mu, \sigma^2)$:

Betrachte σ als unbekannt,

Berücksichtige Samplingfehler beim Schätzen von σ mit σ*(x).

Nullhypothese: $\mu = \mu_0$

Je kleiner p ist, desto sicherer fühlen wir uns beim Verwerfen der Hypothese.

Sehr kleines p = hoch **signifikantes** Ergebnis.

Statistische Tests

Der beidseitige Test auf Erwartungswerte von Normalverteilungen

Mit **Scipy.stats**:

```
scipy.stats.ttest_1samp(x, mu)
```

oder

```
ttest_ind_from_stats(mean1, std1, nobs1,
                     mean2, std2, nobs2,
                     equal_var=True,
                     alternative="two-sided")
```

Statistische Tests

Test auf Erwartungswerte von Normalverteilungen mit mehr als 2 Gruppen

ANOVA = Analysis of Variance

Gleiche Voraussetzungen wie beim t-Test:

- Beobachtungen unabhängig voneinander
- Residuen (x_i-mean(x)) sind normalverteilt
- Homoskedastizität = Varianzen der Stichprobengruppen gleich

Nullhypothese: Die Erwartungswerte der Gruppen sind gleich.

Übliche Anwendung: kategorielle Variable mit k Ausprägungen,
etwa Clusterzugehörigkeit.

`scipy.stats.f_oneway`

Signifikanz

Ein signifikant schwerer Begriff



“Significantly significant signs of significance”

Signifikanz

Heinrich Heine
Universität Düsseldorf

Statistisch signifikant wird das Ergebnis eines statistischen Tests genannt, wenn Stichprobendaten so stark von der Nullhypothese abweichen, dass diese Annahme nach einer vorher festgelegten Regel verworfen wird.

Häufige Regel (Heuristik):

Signifikanz bei $p \leq 5\ \%$

Signifikanz

Heinrich Heine
Universität Düsseldorf

Statistisch signifikant wird das Ergebnis eines statistischen Tests genannt, wenn Stichprobendaten so stark von der Nullhypothese abweichen, dass diese Annahme nach einer vorher festgelegten Regel verworfen wird.

Häufige Regel (Heuristik):

Signifikanz bei $p \leq 5\ \%$

Eine normalverteilte Zufallsgröße nimmt nur mit einer Wahrscheinlichkeit von ≤ 5 % einen Wert an, der sich vom Erwartungswert um mehr als die 1,96-fache Standardabweichung unterscheidet.

$p \leq 1\ \%$ (2,3σ) - sehr signifikant

$p \leq 0{,}1\ \%$ (3,1σ) - hoch signifikant

p-Wert

Heinrich Heine
Universität Düsseldorf

Erinnerung:

Der p-Wert ist definiert als $p := P(\text{ Beobachtung } | H_0)$

Niedriger p-Wert = Wenn H_0 stimmen würde,
wäre die Beobachtung sehr unwahrscheinlich.

Das ist signifikant wenn p niedrig genug ist ($p < 0.05$).

p-Wert

Heinrich Heine
Universität Düsseldorf

Erinnerung:

Der p-Wert ist definiert als $p := P(\text{ Beobachtung } | H_0)$

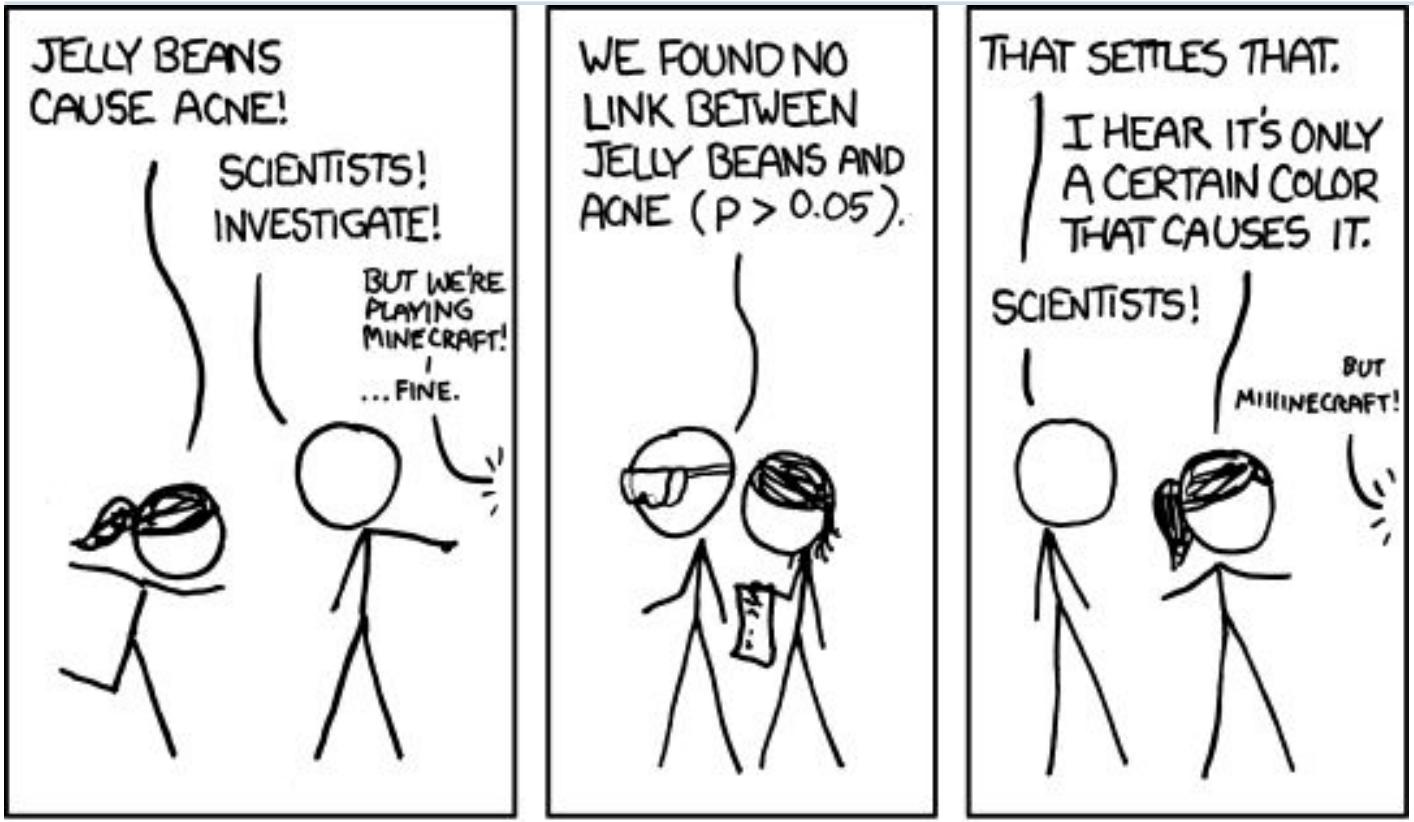
Niedriger p-Wert = Wenn H_0 stimmen würde,
wäre die Beobachtung sehr unwahrscheinlich.

Das ist signifikant wenn p niedrig genug ist ($p < 0.05$).

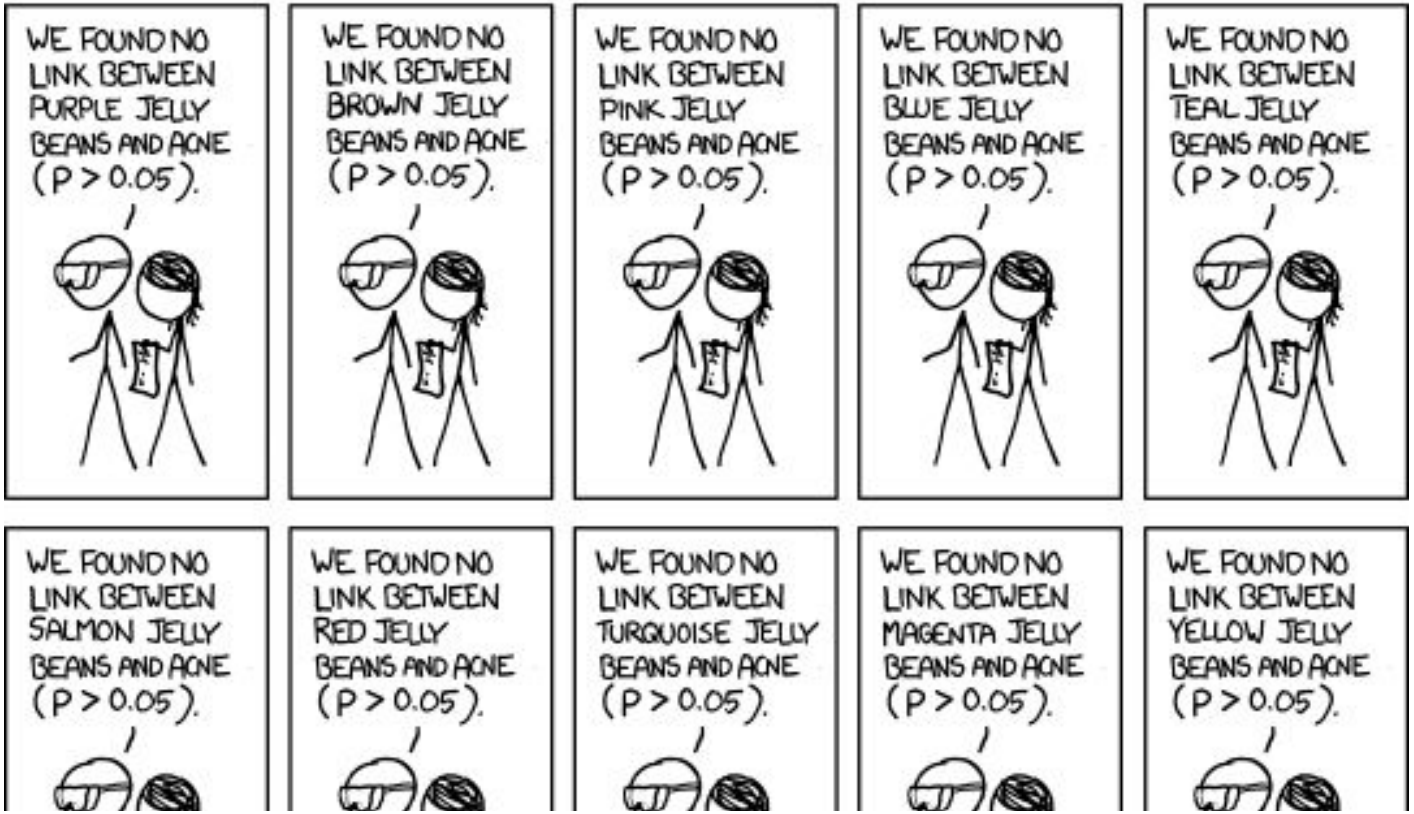
Hoher p-Wert = Wenn H_0 stimmen würde,
wäre die Beobachtung sehr wahrscheinlich.

Das ist nicht signifikant. Keine Aussagekraft über H_0.

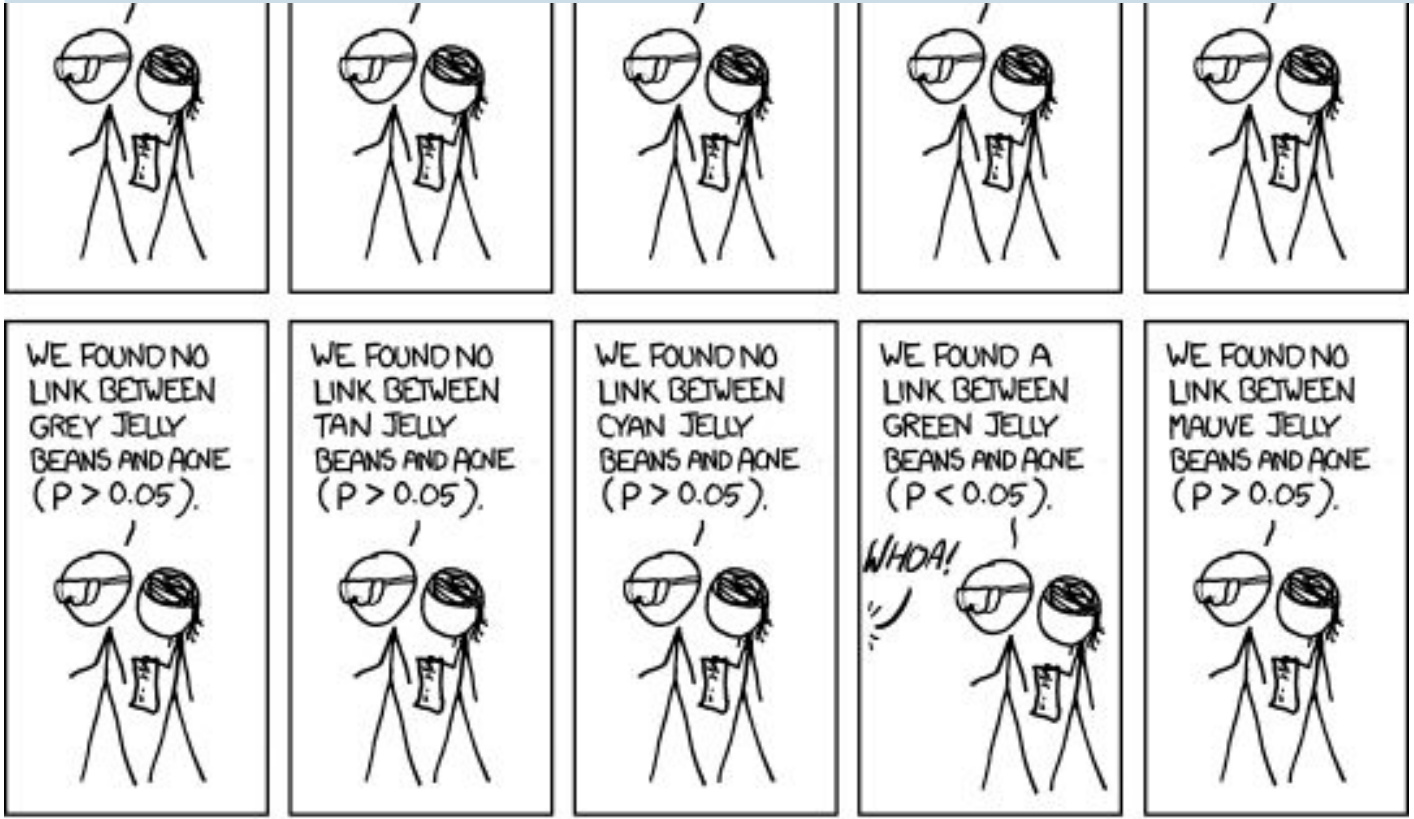
XKCD 882: Significant



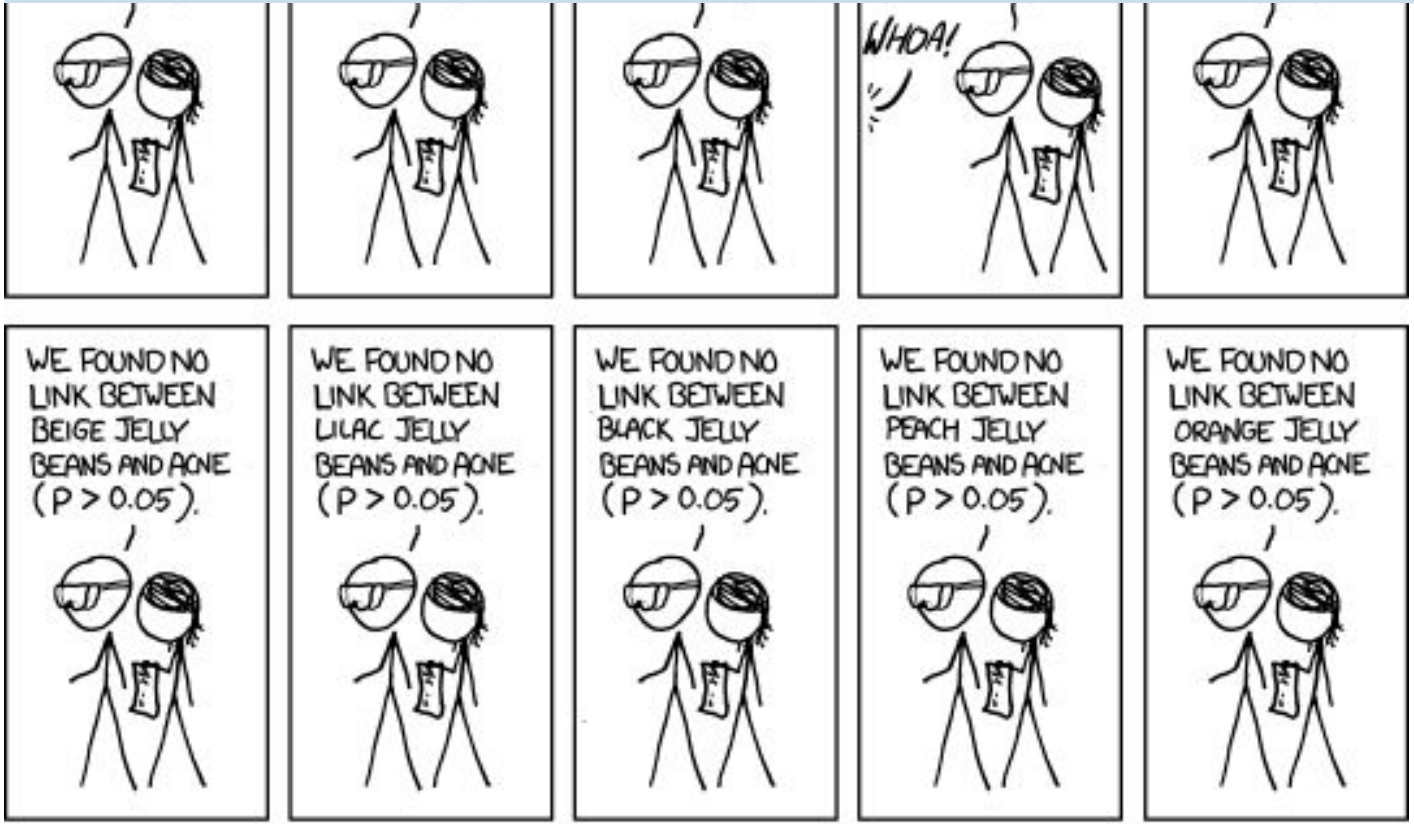
XKCD 882: Significant



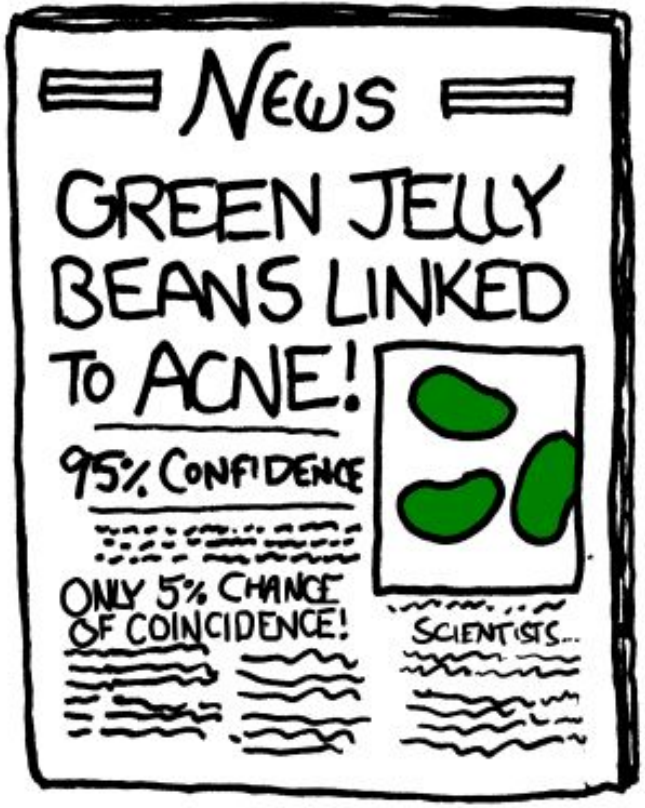
XKCD 882: Significant



XKCD 882: Significant



XKCD 882: Significant



Signifikanz

- auch signifikante Ergebnisse können völlig zufällig sein,
- auch nichtsignifikante Ergebnisse können wiss. relevant sein,

Signifikanz

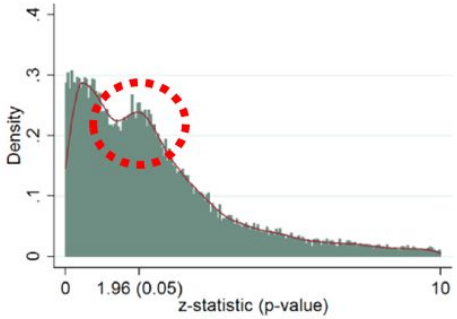
- auch signifikante Ergebnisse können völlig zufällig sein,
- auch nichtsignifikante Ergebnisse können wiss. relevant sein,
- der p-Wert wird häufig falsch interpretiert (vgl. Haller&Krauss 2002),

Signifikanz

Economics

Brodeur et al (AEJ:A, in press)

"Star Wars: The empirics strike back"

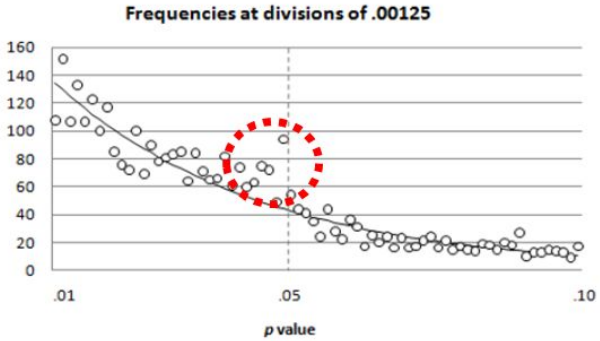


(b) De-rounded distribution of z-statistics.

Psychology

Masicampo Lalande (QJEP, 2012)

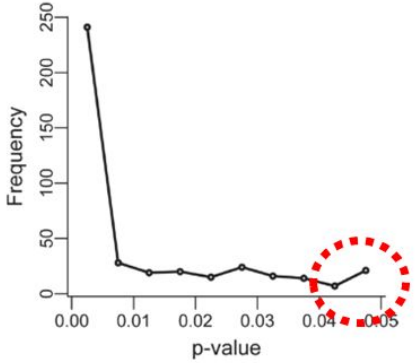
"A peculiar prevalence of p values just below .05"



Biology

Head et al (PLOS Biology 2015)

"Extent and Consequences of P-Hacking in Science"



- es gibt Tricks: p-value hacking,
  (vgl. Simonsohn 2015)

Most Published Research Findings Are False

Heinrich Heine
Universität Düsseldorf

Ioannidis 2005 (PLOS Medicine 2(8)):

“the probability that a research finding is indeed true depends on
the **prior probability** of it being true
(before doing the study),
the **statistical power** of the study,
and the level of **statistical significance**”

Danke für Ihre Aufmerksamkeit.