Relative Entropie

Dr. Konrad Völkel Heinrich-Heine Universität Düsseldorf

Vorlesungsaufzeichnung Entropie

Logarithmen

> **Lemma**
>
> Sei $l\colon \{1,\dots\} = \mathbb{N}_{>0} \to \mathbb{R}$ eine Funktion mit
>
> 1. $l(ab) = l(a) + l(b)$ -- "vollständig additiv"
> 2. $l(n+1) \geq l(n)$ -- "monoton wachsend" Dann existiert eine Konstante $c \in \mathbb{R}$ sodass $l(n) = c\ln(n)$.

> **Bemerkung**
>
> Aufgrund der Formel
>
> $$\ln(x) = \frac{\log_a(x)}{\log_a(e)} \tag{1}$$
>
> können wir die Konstante c interpretieren als $c = \log_a(e)$, d.h. die Funktion l ist ein Logarithmus zur Basis a.

Es ist auch gleich klar, dass das gleiche Lemma für $\log_2$ anstelle von $\ln$ gilt (lediglich die Konstante ist eine andere).

Wenn wir also etwas abzählen wollen, sodass der Zählwert eines Produkts die Summe der einzelnen Zählwerte ist, dann müssen wir das mit einem Logarithmus tun.

> **Beweis**

Wir wollen zeigen, dass für Funktionen $f, g\colon \mathbb{N}_{>0} \to \mathbb{R}$, die die Bedingungen aus dem Lemma erfüllen, stets

$$f(n)g(2) = f(2)g(n) \tag{2}$$

gilt, denn mit $g = \ln$ ist dann das Lemma bewiesen ($c = f(2)$).

Seien $n, k, l \in \mathbb{N}$ sodass $2^{l-1} \leq n^k \leq 2^l$. Aus der Monotonie folgt dann

$$f(2^{l-1}) \leq f(n^k) \leq f(2^l) \tag{3}$$

und aus der Additivität

$$(l-1)f(2) \leq kf(n) \leq lf(2) \tag{4}$$

ebenso die gleiche Ungleichungskette für g anstelle f, aber das multiplizieren wir noch mit -1:

$$-lg(2) \leq -kg(n) \leq -(l-1)g(2). \tag{5}$$

Die Summe dieser beiden Ungleichungsketten können wir nun vereinfachen zu

$$-f(2)g(2) \leq k\left(f(n)g(2) - f(2)g(n)\right) \leq f(2)g(2) \tag{6}$$

teilen wir durch k, und lassen dann $k \to \infty$ gehen, so sehen wir, dass $f(n)g(2) - f(2)g(n) \to 0$ geht (für $k \to \infty$, wovon es gar nicht abhängt).

Lemma

Wenn eine stetige Funktion $F\colon \mathbb{R} \to \mathbb{R}$ die Funktionalgleichung $F(xy) = xF(y) + F(x)y$ erfüllt und schneller wächst als x, so existiert eine Konstante $c \in \mathbb{R}$ sodass $F(x) = -x\log(x)c$.

Beweis

Die Funktion $g(x) := F(x)/x$ erfüllt $g(xy) = g(x) + g(y)$ und wächst monoton, also gibt es c' mit $g(x) = c'\log(x)$, und $c := -c'$ funktioniert.

Bemerkung

Wir sehen also, dass die Information $I(x) = -x\log(x)$ eine sehr natürliche Größe ist.

Lemma

Der Logarithmus ist eine *konkave* Funktion, d.h. für eine Konvexkombination $\lambda x + \mu y$ (d.h. $\lambda + \mu = 1$ und $0 \leq \lambda, \mu \leq 1$) gilt

$$\lambda\log(x) + \mu\log(y) \leq \log(\lambda x + \mu y) \tag{7}$$

Beweis

Idee: Die Ableitung von $\log(x)$ ist $\frac{1}{x}$ und das ist auf $(0, \infty)$ streng monoton fallend. Mit dem Mittelwertsatz kann man nun zeigen, dass $\log(x)$ streng konkav sein muss (also sogar $<$ statt $\leq$ in der Ungleichung oben).

Wir haben vorher schon ein heuristisches Argument verwendet, aber nun können wir rigoros zeigen:

Proposition

Wenn $p = (p_1, \ldots, p_n)$ eine diskrete Verteilung auf $\Omega = \{1, \ldots, n\}$ beschreibt, so gilt für die Entropie $H(p) \leq \log(n)$ (die Entropie der Gleichverteilung).

Beweis

Wir nutzen aus, dass die Summe in der Definition der Entropie eine Konvexkombination ist, und dass der Logarithmus konkav ist:

$H(p) = \sum_{i=1, p_i \neq 0}^{n} p_i \log \frac{1}{p_i}$

$\leq \log\left(\sum_{i=1, p_i \neq 0}^{n} p_i \frac{1}{p_i}\right)$

$\leq \log\left(\sum_{i=1}^{n} 1\right) = \log(n)$

Relative Entropie

Definition

Seien $p, r \in \Delta_n$ (der Menge der Wahrscheinlichkeitsvektoren in $\mathbb{R}^n$, also Vektoren, deren Einträge zwischen 0 und 1 liegen und deren Summe über alle Einträge genau 1 ist). Die *Entropie* (auch: Kullback-Leibler-Divergenz D_{KL}) von p relativ zu r ist

$$H(p\|r) := \sum_{i,\, p_i>0}^{n} p_i \log\left(\frac{p_i}{r_i}\right) \in \mathbb{R} \cup \{\infty\}.$$

Proposition

Schreibe $u_n = (\frac{1}{n}, \ldots, \frac{1}{n}) \in \Delta_n$ für die Gleichverteilung auf $\{1, \ldots, n\}$. Dann ist

$$H(p\|u_n) = H(u_n) - H(p) = \log(n) - H(p) \tag{8}$$

Proposition

$$H(p\|r) = 0 \text{ genau dann wenn } p = r \tag{9}$$

(ohne Beweis)

Proposition

$$H(p\|r) \geq 0 \tag{10}$$

Beweis

$$H(p\|r) = -\sum p_i \log\left(\frac{r_i}{p_i}\right) \geq -\log\left(\sum p_i \frac{r_i}{p_i}\right) \geq -\log\left(\sum r_i\right) = -\log 1 = 0$$

dabei haben wir wieder die Konkavität des Logarithmus ausgenutzt.

Beispiel

Die relative Entropie ist nicht symmetrisch und kann durchaus unendlich groß werden:

$$H\left(u_2 \middle\| \begin{pmatrix} t \\ 1-t \end{pmatrix}\right) = \frac{1}{2}\log\left(\frac{1}{2t}\right) + \frac{1}{2}\log\left(\frac{1}{2(1-t)}\right) \xrightarrow{t\to 0} \log(\infty) = \infty. \tag{11}$$

Wie zuvor besprochen ist $H\left(\begin{pmatrix} t \\ 1-t \end{pmatrix} \middle\| u_2\right) = \log(n) - H\left(\begin{pmatrix} t \\ 1-t \end{pmatrix}\right)$ und

$$H(u_2) = t\log(t) - (1-t)\log(1-t) \xrightarrow{t\to 0} 0 - 1\log(1) = 0 \tag{12}$$

Verbundentropie

Definition

Die *Verbundentropie* von zwei diskreten Zufallsvariablen X, Y ist

$$H(X,Y) := \mathbb{E}I_{X,Y} = -\sum_{i=1}^{n}\sum_{j=1}^{n} P(X = z_i, Y = z_j)\log P(X = z_i, Y = z_j) \tag{13}$$

Proposition

$$H(X) + H(Y) \geq H(X,Y) \geq \max\left(H(X), H(Y)\right) \tag{14}$$

Beispiel

$$H(X,X) = H(X) \tag{15}$$

denn in der Summe für den linken Ausdruck sind alle Summanden außerhalb der Diagonalen 0.

Proposition

Wenn X, Y unabhängige Zufallsvariablen sind, dann ist $H(X,Y) = H(X) + H(Y)$.

Beweis

Die Unabhängigkeit bedeutet für alle i, j:

$$P(X = z_i, Y = z_j) = P(X = z_i) \cdot P(Y = z_j) \tag{16}$$

das Logarithmieren wir:

$$\log P(X = z_i, Y = z_j) = \log P(X = z_i) + \log P(Y = z_j) \tag{17}$$

also haben wir insgesamt

$$\begin{aligned}
H(X,Y) &:= -\sum_{i=1}^{n}\sum_{j=1}^{n} P(X = z_i, Y = z_j) \log P(X = z_i, Y = z_j) \\
&= -\sum_{i=1}^{n}\sum_{j=1}^{n} P(X = z_i)P(Y = z_j) \left(\log P(X = z_i) + \log P(Y = z_j)\right) \\
&= -\sum_{i=1}^{n}\sum_{j=1}^{n} P(X = z_i)P(Y = z_j) \log P(X = z_i) \\
&\quad -\sum_{i=1}^{n}\sum_{j=1}^{n} P(X = z_i)P(Y = z_j) \log P(Y = z_j) \\
&= -\sum_{i=1}^{n} P(X = z_i) \log P(X = z_i) \\
&\quad -\sum_{j=1}^{n} P(Y = z_j) \log P(Y = z_j) \\
&= H(X) + H(Y)
\end{aligned} \tag{18}$$

Definition

Die *gemeinsame Information* von zwei Zufallsvariablen X, Y ist definiert als

$$I(X;Y) := H(X) + H(Y) - H(X,Y) = H(X,Y \| X \times Y) \tag{19}$$

Ein sehr häufiger Anwendungsfall der gemeinsamen Information liegt im Clustering: Wenn man zu einem Datensatz mit einer Methode der Wahl zu Clustern gekommen ist, also eine geschätzte Klassenzugehörigkeit (etwa $1, 2$ oder 3 als Label), und für einen Teildatensatz (zum Testen) von Hand eine Klasseneinteilung vorgenommen wurde, können wir von diesen Klassenvariablen die gemeinsame Information berechnen um zu quantifizieren, wie gut die Klassenbildung auf dem Testdatensatz funktionierte. Von Vorteil ist dabei, dass die konkreten Label nicht mehr relevant sind (d.h. die Methode ist invariant unter Permutation der Klassenbezeichnungen).

Die *bedingte Entropie* von X bedingt auf Y ist definiert als

$$H(X|Y) := H(X) - I(X;Y) \tag{20}$$

Beispiel

Die gemeinsame Information von X mit sich selbst ist genau die Entropie $I(X;X) = H(X)$.

Wenn X, Y unabhängig sind, ist $I(X,Y) = H(X) + H(Y) - (H(X) + H(Y)) = 0$.

Proposition

$$H(X|Y) = H(X,Y) - H(Y) \tag{21}$$

und wenn X, Y unabhängig sind, ist $H(X|Y) = H(X)$.

Satz

Entropischer Satz von Bayes

$$H(X|Y) = H(Y|X) + H(X) - H(Y) \tag{22}$$

Beispiel

Wenn X vollständig von Y abhängt (z.B. Y ein Würfelwurf und $X = f(Y)$ mit $f = \mod 2$), dann ist $H(X,Y) = H(Y)$ und $H(X|Y) = 0$.

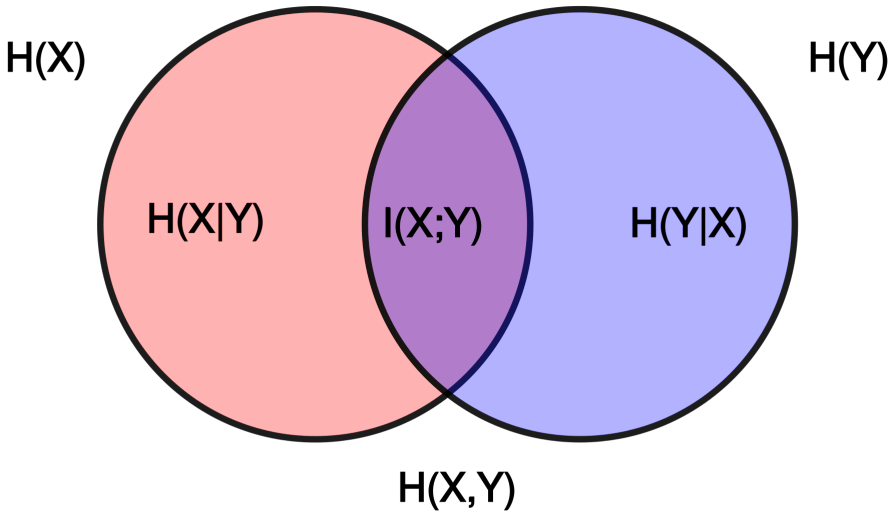


Figure 1: Entropie, bedingte Entropie, Verbundentropie und gemeinsame Information in einem Venn-Diagramm.

Definition

Die *Kreuzentropie* von X (verteilt nach $p \in \Delta^n$) und Y (verteilt nach $r \in \Delta^n$) ist

$$H(X;Y) = \mathbb{E}_X I(Y) = \sum_{i,\, r_i>0}^{n} p_i \log r_i \in \mathbb{R} \cup \{\infty\}. \tag{23}$$

Achtung: Leider wird die Kreuzentropie von manchen Autoren auch mit $H(X,Y)$ notiert, was man also leicht mit der Verbundentropie verwechseln kann.

Proposition

$$H(X;Y) = H(X) + H(X\|Y) \tag{24}$$

Wenn man X festhält und Y variiert, ist es das gleiche, ob man $H(X;Y)$ oder $H(X\|Y)$ minimiert, daher wird im maschinellen Lernen häufig das eine mit dem anderen substituiert. Die Maximum-Likelihood-Methode kann man auffassen als Minimierung einer

Kreuzentropie und damit als Minimierung der relativen Entropie. Das erklärt, wie und wieso Entropie für maschinelles Lernen relevant ist.

Ansonsten ist die Kreuzentropie eine in der Theorie deutlich seltener verwendete Größe als die relative Entropie (die meist Kullback-Leibler-Divergenz D_{KL} genannt wird).

Stetige Entropie

Hinweis: Dieses Unterkapitel ist nicht besonders klausurrelevant.

Man könnte meinen, dass sich die Formel $H(p) = -\sum p_i \log p_i$ verallgemeinert zu $H(P) = -\int \log P dP$, aber das ergibt so keinen Sinn. Man kann aber das folgende tun:

> **Definition**
>
> Sei P eine stetige Verteilung mit Dichtefunktion f, die auf einer Menge $\Omega \subseteq \mathbb{R}^n$ definiert ist. Dann heißt
>
> $$h(X) := \mathbb{E}\left(-\log(f(X))\right) = -\int_\Omega f(x) \log f(x) dx \tag{25}$$
>
> die *differentielle Entropie* von X (definiert ebenfalls von Claude Shannon).

Sie erfüllt bereits einige schöne Eigenschaften, die wir uns von einer stetigen Entropie vorstellen, z.B. Translationsinvarianz: $h(X) = h(X - v)$ für einen Vektor $v \in \mathbb{R}^n$.

Leider ist die differentielle Entropie nicht invariant unter beliebigen Transformationen, auch nicht Isomorphismen.

Jaynes hat vorgeschlagen, sich immer feiner werdende Histogramme vorzustellen, also eine Menge von N diskreten Punkten $\{x_i\}$, dann schreiben wir $M(a,b) = \lim_{N\to\infty} \frac{1}{n}(\text{Anzahl } x_i : a < x_i < b)$ und eine Dichte m mit $M(a,b) = \int_a^b m(x)dx$ nennen wir *invariantes Maß*. Damit schreiben wir nun

$$\lim_{N\to\infty} \log(N) - \int p(x) \log \frac{p(x)}{m(x)} dx \tag{26}$$

aber weil $\lim_{N\to\infty} \log(N) = \infty$ ist, lassen wir den Teil einfach frech weg, und erhalten so eine Größe, die sich ähnlich wie $h(x)$ verhält, aber skaleninvariant ist:

$$H(X) := -\int p(x) \log \frac{p(x)}{m(x)} dx \tag{27}$$

Zum Einen wollen wir festhalten, dass die "diskrete Entropie" einer stetigen Verteilung eigentlich ∞ ist. Zum Anderen, dass offensichtlich für einen sinnvollen Entropiebegriff zwangsläufig Bezug genommen werden muss auf eine weitere Verteilung (hier das "invariante Maß").

Wenn man vom theoretischen Standpunkt analysiert, was $h(X)$ und $H(X)$ sind, so kommt man zur allgemeinen relativen Entropie $H(P, Q)$, sodass $h(X) = H(f\lambda|\lambda)$ mit λ dem Lebesgue-Maß und f einer Dichte von X.

> **Definition**
>
> Seien P, R stetige Verteilungen. Die *relative Entropie* $H(P\|R)$ (auch: Kullback-Leibler-Divergenz $D_{KL}(P, R)$) ist
>
> $$H(P\|R) := -\int_\Omega \log\left(\frac{dR}{dP}\right) dP \tag{28}$$
>
> dabei ist $\frac{dR}{dP}$ die Radon-Nikodym-Ableitung eines Maßes bezüglich eines anderen.

Das wollen wir jetzt auch nicht weiter diskutieren, sondern lieber festhalten, dass das für P und R mit Dichtefunktionen $p, r\colon \mathbb{R}^n \to [0, 1]$ einfacher aussieht:

$$H(P\|R) = \int_\Omega p(x) \log \frac{p(x)}{r(x)} dx \tag{29}$$

Diesen Ausdruck wiederum dürfen wir (wenn die Dichtefunktionen hinreichend freundlich sind) über Riemann-Summen ausrechnen. Wenn z.B. $n = 1$ und $\Omega = \mathbb{R}$, dann können wir

$$H(P\|R) = \int_{\mathbb{R}} p(x) \log \frac{p(x)}{r(x)} dx = \sum_{k=-\infty}^{\infty} \int_k^{k+1} p(x) \log \frac{p(x)}{r(x)} dx$$

betrachten und die Integralterme rechts durch Werte abschätzen, um so $H(P\|R)$ abzuschätzen.

$$H(P\|R) \approx \sum_{k=-\infty}^{\infty} p(k) \log \frac{p(k)}{r(k)} \tag{30}$$

Die Unterteilung in Intervalle der Länge 1 können wir natürlich beliebig feiner wählen, um die Approximation beliebig genau zu bekommen. Das Ersetzen einer stetigen Verteilung durch eine solche diskrete Verteilung ist analog der Bildung eines Histogramms.

Wenn Sie noch Zweifel daran haben, welche Relevanz die abstrakte Informationstheorie für die praktische Arbeit von Data Scientists und Machine Learning Entwicklern haben soll, ist eine Reise in die Wikipedia-Seite zu Anwendungen der gemeinsamen Information bzw. bedingter Entropie ratsam.